공중전 인공지능의 성능-설명가능성 트레이드오프 검증 *

- 규칙 기반·학습 기반·하이브리드 모델의 행동 수준 비교를 중심으로 -

(Testing the Performance-Explainability Trade-off in Air-Combat AI: A Behavior-Level Comparison of Rule-based, Learning-based, and Hybrid Models)

4학년 생도 박 윤 준**
(Cadet 4th Class Park Yoonjoon)
4학년 생도 손 형 래***
(Cadet 4th Class Son Hyeongrae)
4학년 생도 이 성 재****
(Cadet 4th Class Lee Sungjae)
4학년 생도 이 준 서*****
(Cadet 4th Class Lee Junseo)
4학년 생도 뚜 언 닷*
(Cadet 4th Class Trinh Vu Tuan Dat)

---

* 본 논문은 한국해양연구소 기부로 시작된 2026년 공군사관학교 안보 논문경진대회를 위하여 제출된 논문임.

** Corresponding Author: 박윤준(Park Yoonjoon)
공군사관학교 생도대 6중대 컴퓨터과학과
E-mail: a7513714@afa.ac.kr
Tel: 043-000-0000
*** 공군사관학교 생도대 4중대 컴퓨터과학과
E-mail: a7513738@afa.ac.kr
Tel: 043-290-0000
**** 공군사관학교 생도대 2중대 컴퓨터과학과
E-mail: a7513771@afa.ac.kr
Tel: 043-290-0000
***** 공군사관학교 생도대 4중대 컴퓨터과학과
E-mail: a7513786@afa.ac.kr
Tel: 043-290-0000
* 공군사관학교 생도대 8중대 컴퓨터과학과
E-mail: a7513853@afa.ac.kr
Tel: 043-290-0000

- 요 약 문 -

공중전 인공지능은 성능이 높을수록 판단 근거를 설명하기 어렵다는 통념이 있다. 본 연구는 이 성능–설명가능성 트레이드오프가 실제로 존재하는지를 1대1 근접 기총 공중전 모의실험에서 검증하였다. 규칙 기반 행동트리, 진화전략으로 학습한 신경망, 두 모델을 네 가지 방식으로 결합한 하이브리드를 같은 관측·지령·상대로 비교하고, 설명가능성은 모델의 조종 기록을 재현하는 결정트리의 최소 깊이로 측정하였다. 트레이드오프는 성능이 높은 모델일수록 설명 비용이 큰지를 보는 연관성 검정과, 설명 비용에 상한을 두었을 때 잃는 성능을 재는 제약 비용 분석으로 검증하였다. 282개 조건, 112,800회 교전의 결과 성능과 설명 비용 사이에 강한 연관은 없었다($\rho = -0.02$). 설명 비용을 깊이 2 이하로 묶으면 성능 손실이 컸지만 깊이 5~6을 허용하면 손실은 대부분 사라졌다. 설명 비용을 가른 것은 성능이 아니라 전술이었으며, 네 결합 방식의 하이브리드는 어느 것도 절충점이 되지 못했다. 학습 기반 모델의 성능 우위는 학습 상대와의 대결에서만 뚜렷했고 보류 상대, 다른 교전 규칙, 6자유도 F-16 재평가에서는 약해지거나 사라졌다.

주제어 : 공중전 인공지능, 설명가능 인공지능, 트레이드오프, 행동트리, 대리모델

1. 서론

1.1. 연구 배경

2026년 2월 미 공군의 협동전투기 시제기 YFQ-42A는 자율비행 소프트웨어를 탑재한 채 지상 운용자의 감독 아래 반자율 임무비행을 수행하였고,[1] 국내에서도 KF-21과 협업 무인기를 연동한 유·무인 복합 공중전 체계가 공개되었다.[2] 강화학습 기반 인공지능(AI)이 모의 근접공중전에서 숙련 조종사를 이긴 지[3] 6년 만에 AI 조종은 전력화 단계에 들어섰다. 유인기가 무인기를 지휘하려면 조종사가 AI의 기동 이유를 이해하고 감독할 수 있어야 하며, 판단 근거를 확인할 수 없는 모델은 성능이 높더라도 교전 권한을 위임받기 어렵다.

이때 흔히 전제되는 것이 성능과 설명가능성의 트레이드오프이다. 사람이 규칙을 쓴 행동트리(BT: Behavior Tree)는 판단 근거를 읽을 수 있지만 성능이 낮고, 스스로 학습한 신경망은 성능이 높지만 설명할 수 없으며, 둘을 결합한 하이브리드가 그 절충점이라는 기대이다. 미 국방고등연구계획국의 설명가능 AI 사업도 이 반비례 관계에서 출발하였으나,[4] 그러한 트레이드오프가 항상 존재하지는 않는다는 반론도 있다.[5] 이를 공중전 AI에서 검증하려면 모델 종류와 무관하게 잴 수 있는 설명가능성 지표와, 트레이드오프를 판정하는 검정 방법이 필요하다. 설명가능성을 모델 종류로 정하면 행동트리는 정의상 설명 가능하고 신경망은 정의상 불가능하여 측정할 것이 남지 않기 때문이다.

1.2. 연구 목적과 연구 질문

본 연구의 목적은 1대1 근접공중전 모의 환경에서 규칙 기반·학습 기반·하이브리드

---

1) General Atomics Aeronautical Systems, "GA-ASI Achieves New Milestone With Semi-Autonomous CCA Flight," February 12, 2026. https://www.ga.com/ga-asi-achieves-new-milestone-with-semi-autonomous-cca-flight (검색일: 2026년 10월 22일)

2) "KF-21 옆에 무인기 세운 KAI, 유·무인 공중전 체계로 답했다," 『스마트비즈』, 2026년 6월 9일. https://www.smartbizn.com/news/articleView.html?idxno=145816 (검색일: 2026년 9월 28일)

3) Adrian P. Pope et al., "Hierarchical Reinforcement Learning for Air-to-Air Combat," in *2021 International Conference on Unmanned Aircraft Systems (ICUAS)* (Piscataway, NJ: IEEE, 2021), pp. 275~284.

4) David Gunning and David W. Aha, "DARPA's Explainable Artificial Intelligence (XAI) Program," *AI Magazine*, Vol. 40, No. 2 (Summer 2019), pp. 44~58.

5) Cynthia Rudin, "Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead," *Nature Machine Intelligence*, Vol. 1, No. 5 (May 2019), pp. 206~215.

모델의 성능과 행동 수준 설명가능성을 같은 잣대로 측정하여 성능–설명가능성 트레이드오프가 존재하는지를 검증하고, 설명 비용을 결정하는 요인을 밝히는 것이다. 연구 질문은 성능이 높은 모델일수록 행동을 재현하는 데 더 복잡한 규칙이 필요한가(RQ1), 모델 사이의 설명 비용 차이는 무엇으로 결정되는가(RQ2), 규칙과 학습을 결합한 하이브리드가 트레이드오프를 완화하는 절충점이 될 수 있는가(RQ3)이다.

2. 이론적 배경

2.1. 공중전 인공지능과 설명가능성

공중전 AI는 교범의 기본전투기동을 규칙으로 옮긴 모델에서 출발하였다. 미 항공우주국의 적응형 기동 논리는 사람이 몇 번의 모의비행만으로 다음 기동을 예측할 수 있다는 비판을 받았고,[6] 국내의 행동트리 교전 모델은 선택한 전술 행위를 화면에 보여 주어 판단을 검증할 수 있다는 점을 장점으로 내세웠다.[7] 연구가 강화학습으로 옮겨 간 뒤 규칙 기반 모델은 학습 에이전트의 성능 기준선으로 쓰였다.[8] 강화학습 에이전트의 설명을 다룬 연구는 결정트리로 정책을 단순화하면 트리를 깊게 해야 하므로 설명가능성의 이점이 사라진다며 이를 배제하였으나,[9] 트리가 얼마나 깊어야 하는지는 측정되지 않았다.

2.2. 행동 수준 설명가능성의 측정

원 모델의 입력과 출력을 흉내 내는 결정트리를 적합시키는 대리모델 방법은 강화학습 정책을 결정트리로 추출하는 VIPER로 이어졌다.[10] 본 연구는 이 발상을 측정 도구로 바꾸어, 모델의 행동 기록을 목표 수준 이상으로 재현하는 데 필요한 결정트리의 최소 깊이를 설명 비용으로 삼는다. 이 지표는 행동 기록만으로 계산되므로 행동트리, 신경망, 하이브리드에 똑같이 적용되지만, 사람 실험 없이 모델의 성질로 재

---

6) George H. Burgin and Laurent B. Sidor, *Rule-Based Air Combat Simulation*, NASA Contractor Report 4160 (Washington, D.C.: NASA, 1988), pp. viii, 6-1~6-2.

7) 이민석·오지현·김천영·배정호·김용덕·지철규, “공대공 전투 모의를 위한 규칙기반 AI 교전 모델 개발,” 『한국군사과학기술학회지』, 제25권 제6호 (2022), pp. 639, 645.

8) 황인수·배정호, “커리큘럼을 이용한 투서클 기반 항공기 헤드온 공중 교전 강화학습 기법 연구,” 『한국군사과학기술학회지』, 제26권 제4호 (2023), p. 356.

9) Emre Saldiran, Mehmet Hasanzade, Gokhan Inalhan and Antonios Tsourdos, “Towards Global Explainability of Artificial Intelligence Agent Tactics in Close Air Combat,” *Aerospace*, Vol. 11, No. 6 (2024), 415, p. 3.

10) Osbert Bastani, Yewen Pu and Armando Solar-Lezama, “Verifiable Reinforcement Learning via Policy Extraction,” in *Advances in Neural Information Processing Systems 31* (Red Hook, NY: Curran Associates, 2018).

는 기능 기반 평가이므로[11] 사람의 실제 이해도를 말해 주지는 않는다. 본 연구가 이 지표를 "행동 재현 간결성"으로 한정해 부르는 이유이다.

2.3. 트레이드오프의 검증과 하이브리드

트레이드오프라는 주장은 모델 집단에서 성능과 설명 비용이 함께 커진다는 연관성의 진술과, 설명 비용에 상한을 두면 도달할 수 있는 최고 성능이 낮아진다는 제약 비용의 진술로 나뉜다. 루딘은 해석 가능한 모델도 블랙박스와 비슷한 성능을 내는 경우가 많다고 반박하였고,[12] 세메노바 등은 비슷한 성능의 모델이 많을수록 그 안에 단순한 모델이 있을 가능성이 높음을 보였다.[13] 다만 이 논쟁은 대부분 정적인 분류·예측 과업에서 이루어졌다. 규칙과 학습의 결합으로는 안전 감독,[14] 잔차 학습,[15] 전문가 혼합[16]이 제안되었으나, 결합 결과가 얼마나 설명 가능한지는 평가되지 않았다. 본 연구는 순차 의사결정 과업인 공중전에서 두 진술을 각각 검정하고(RQ1), 설명 비용의 원인을 분석하며(RQ2), 네 결합 방식을 같은 잣대로 비교한다(RQ3).

3. 연구 방법

3.1. 모의 환경과 비교 모델

수만 회의 학습 교전과 10만 회가 넘는 평가 교전을 수행하기 위해 전용 모의 환경을 구현하였다.[17] 기체는 F-16급 공개 제원의 3자유도 점질량 모델이고, 모든 모델은 교전 기하로 표현된 관측 20개(상대 거리, 기수-시선각, 애스펙트각, 접근률, 고도차, 잔여 체력 등)를 받아 뱅크각·하중배수·스로틀의 지령 3개를 0.2초마다 낸다.

---

11) Finale Doshi-Velez and Been Kim, "Towards A Rigorous Science of Interpretable Machine Learning," arXiv:1702.08608 (2017).

12) Rudin, 2019.

13) Lesia Semenova, Cynthia Rudin and Ronald Parr, "On the Existence of Simpler Machine Learning Models," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency* (New York: ACM, 2022), pp. 1827~1858.

14) Mohammed Alshiekh et al., "Safe Reinforcement Learning via Shielding," *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32, No. 1 (2018).

15) Tobias Johannink et al., "Residual Reinforcement Learning for Robot Control," in *2019 International Conference on Robotics and Automation (ICRA)* (Piscataway, NJ: IEEE, 2019), pp. 6023~6029.

16) Robert A. Jacobs, Michael I. Jordan, Steven J. Nowlan and Geoffrey E. Hinton, "Adaptive Mixtures of Local Experts," *Neural Computation*, Vol. 3, No. 1 (1991), pp. 79~87.

17) 모의 환경·비교 모델·분석 코드의 구현과 실험 실행, 원고 초안 작성에는 생성형 인공지능 도구(Anthropic Claude)를 활용하였다. 연구 질문과 실험 설계, 결과의 해석, 최종 원고의 내용에 대한 책임은 저자에게 있다.

기총은 거리 120~1,200 m에서 상대가 명중 원추 안에 있으면 초당 체력 25를 깎고, 교전은 격추, 충돌, 또는 120초 경과 시 잔여 체력 비교로 끝난다. 최저 고도 1,000 m·하중배수 8 G 등의 안전규칙 위반은 기록만 한다.

규칙 기반 모델은 기본전투기동 교범의 표준 전술[18]을 사람이 옮겨 쓴 행동트리 3종이다. BT−v1은 수평 추격, BT−v2는 양력 방향을 상대 쪽으로 돌리는 최대 선회, BT−v3는 BT−v2에 하드덱 회복·8 G 상한·리드 추격을 더한 것이다. 학습 기반 모델은 가중치 1,827개의 다층 퍼셉트론으로, BT−v2의 교전 기록을 흉내 내도록 초기화한 뒤 진화전략[19]으로 300세대 학습하였다(학습 시드 20개). 학습 상대는 BT−v1과 BT−v2이며 BT−v3는 학습에 쓰지 않았다. 무작위 가중치에서 시작한 학습은 교전을 피해 도망가는 정책으로 수렴하였으므로, 이 모델은 규칙과 무관하게 학습된 모델이 아니라 규칙 모델의 행동에서 출발해 갈라져 나간 모델이다. 통제 조건으로 상수 9개만 학습으로 최적화한 행동트리(BTO)와 무작위 초기화에서 근위 정책 최적화(PPO)[20]로 학습한 모델을 두었다.

하이브리드는 BT−v2와 학습 기반 모델의 지령을 합치는 방식에 따라 네 종류로 나누었다. 선형 혼합형은 사람이 정한 비율 α(0.25·0.5·0.75)로 두 지령을 가중 평균하고, 감독형은 안전 조건에서만 BT−v3의 안전 규칙이 지령을 낸다(이상 300세대·20시드). 잔차형은 BT−v2 지령에 학습이 작은 보정치만 더하고, 게이팅형은 게이트 신경망이 상황마다 두 지령의 비율을 정한다(이상 200세대·3시드).

3.2. 측정 지표와 검증 방법

교전 결과를 승 1, 무 0.5, 패 0으로 매긴 평균을 점수로 삼았다. 트레이드오프의 검증은 고성능 모델의 존재를 전제하므로, 성능을 학습 상대 BT−v2에 대한 점수, 학습에 쓰지 않은 보류 상대 BT−v3에 대한 점수, 학습 기반 20개·행동트리 3종·BTO 3개의 전원 대전 점수로 따로 정의하였다. 설명 비용은 모델의 교전 기록에 깊이 d인 결정트리를 적합시켜 지령을 재현한 정도(R^2)가 0.95 이상이 되는 최소 깊이 D*로 정의하였다. D*는 조종을 95% 재현하는 데 필요한 if−then 규칙의 단계 수이며, 깊이 16에서도 이르지 못하면 17(절단)로 기록하였다. 90% 기준 D*와 깊이 4의 재현 실패율 1−F(4)를 보조 지표로 썼다. 90% 기준에서는 전체 조건의 91%가

18) Robert L. Shaw, *Fighter Combat: Tactics and Maneuvering* (Annapolis: Naval Institute Press, 1985).

19) Tim Salimans, Jonathan Ho, Xi Chen, Szymon Sidor and Ilya Sutskever, "Evolution Strategies as a Scalable Alternative to Reinforcement Learning," arXiv:1703.03864 (2017).

20) John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov, "Proximal Policy Optimization Algorithms," arXiv:1707.06347 (2017).

깊이 5 이하였고 95% 기준에서는 58%가 절단이었으므로, 모델 간 설명 비용의 차이는 대부분 행동의 마지막 5~10%를 재현하는 데서 생긴다.

연관성 검정은 성능 정의 3종과 설명 비용 정의 3종의 모든 조합에서 성능과 D*의 Spearman 순위상관을 구한다. 트레이드오프가 있다면 양수여야 하며, "상관이 작다"는 판단은 부트스트랩 90% 신뢰구간이 ±0.2 안에 드는지를 보는 동등성 검정으로 내렸다.[21] 제약 비용 분석은 D* ≤ k인 모델 가운데 가장 강한 모델과 전체에서 가장 강한 모델의 점수 차를 k의 비용으로 정의하고, 우연히 운이 좋았던 조건이 뽑히지 않도록 평가 초기조건을 둘로 나누어 한쪽으로 모델을 고르고 다른 쪽으로 점수 차를 재었다.

모든 모델은 두 상대와 초기조건 100개에서 진영을 바꿔 두 번씩, 모델당 400회 교전하였다. 본실험은 282개 조건, 112,800회 교전이며 잔차형·게이팅형은 별도로 7,200회를 평가하였다. 결론이 이 환경의 산물인지는 교전 규칙과 비행역학을 바꾼 환경, 그리고 JSBSim의 6자유도 F-16 모델[22]에서 같은 모델들을 다시 학습하지 않고 재평가하여 점검하였다.

4. 연구 결과

4.1. 평가 상대에 따라 달라진 성능

<표 4-1>에서 학습 기반 모델은 학습 상대 BT-v2를 상대로 0.687의 점수를 내어 20개 모두 0.5를 넘었다. 그러나 보류 상대 BT-v3에 대해서는 0.746으로 출발점인 복제본(0.840)과 BT-v2(0.843)보다 낮았고, 보류 상대에게 가장 강한 모델은 상수만 최적화한 BTO(0.882)였다. 학습 모델이 고성능인지는 무엇을 상대로 재느냐에 따라 달라졌다.

---

21) Donald J. Schuirmann, "A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability," *Journal of Pharmacokinetics and Biopharmaceutics*, Vol. 15, No. 6 (1987), pp. 657~680.

22) Jon Berndt, "JSBSim: An Open Source Flight Dynamics Model in C++," in *AIAA Modeling and Simulation Technologies Conference and Exhibit* (Providence, RI: AIAA, 2004), AIAA Paper 2004-4923.

<표 4-1> 계열별 성능과 설명 비용

계열	모델 수	학습 상대	보류 상대	D* 95%(범위)	D* 90%
행동트리 BT-v1·v2·v3	3	0.250·(0.500)·0.158	0.233·0.843·(0.500)	1·4·5	1·2·3
상수 최적화 행동트리	3	0.321	0.882	3 (3~5)	3
학습 기반(300세대)	20	0.687	0.746	6 (3~17)	2
무작위 초기화 PPO	6	0.390	0.380	5 (4~7)	3
선형 혼합형(α 0.25~0.75)	60	0.531~0.687	0.691~0.755	17 (5~17)	3~4
감독형	20	0.487	0.600	11 (6~17)	4.5
잔차형·게이팅형(200세대)	3·3	0.565·0.647	0.690·0.797	6·17	3·3

註: 점수는 승 1, 무 0.5, 패 0의 평균이며 괄호는 자기 자신과의 대전이다. D*는 중앙값이고 17은 절단값이다.
出處: 저자 작성.

4.2. 트레이드오프 검정(RQ1)

<표 4-2>에서 282개 조건 전체의 상관은 −0.13~−0.01로 0이거나 음수였다. 학습 상대 점수와 95% 기준 D*의 상관은 −0.02였고 90% 신뢰구간 [−0.14, 0.09]가 ±0.2 안에 들어와 "상관의 크기가 0.2보다 작다"가 성립하였으며, 학습 시드 임의효과 혼합모형에서도 D*의 계수는 유의하지 않았다($p = 0.82$). 혼합 정책을 뺀 79개 조건에서는 학습 상대 점수에서만 약한 양의 상관($\rho = 0.25$)이 나타났고 보류 상대 점수에서는 반대 방향($\rho = -0.22$)이었으며, 다중비교를 보정하면 어느 조합도 유의하지 않았다.

<표 4-2> 성능과 설명 비용의 순위상관

모델 집합	성능 정의	D* 95%	D* 90%	1−F(4)
전체(282)	학습 상대	−0.02	−0.11	−0.01
	보류 상대	−0.07	−0.10	−0.11
혼합 제외(79)	학습 상대	0.25	−0.16	0.23
	보류 상대	−0.22	−0.10	−0.25
전원 대전(26)	전원 대전 점수	0.13	−0.15	0.17

註: Spearman 순위상관 ρ이며 양수가 트레이드오프 방향이다.
出處: 저자 작성.

제약 비용은 <표 4-3>과 같다. 설명 비용을 깊이 2 이하로 묶으면 0.15~0.34의 큰 손실이 있었지만, 상한을 3~5로 풀면 0.03~0.11로 줄었고, 6으로 풀면 보류 상대와 평균 점수 기준의 손실은 0에 가까워져 학습 상대 기준으로만 0.07이 남았다. 90% 기준 D*로는 상한 5 이상에서 손실이 0이었다. 강한 트레이드오프는 없었고, 매우 엄격한 설명 제약에서만 대가가 있었다.

<표 4-3> 설명 비용 상한에 따른 성능 손실

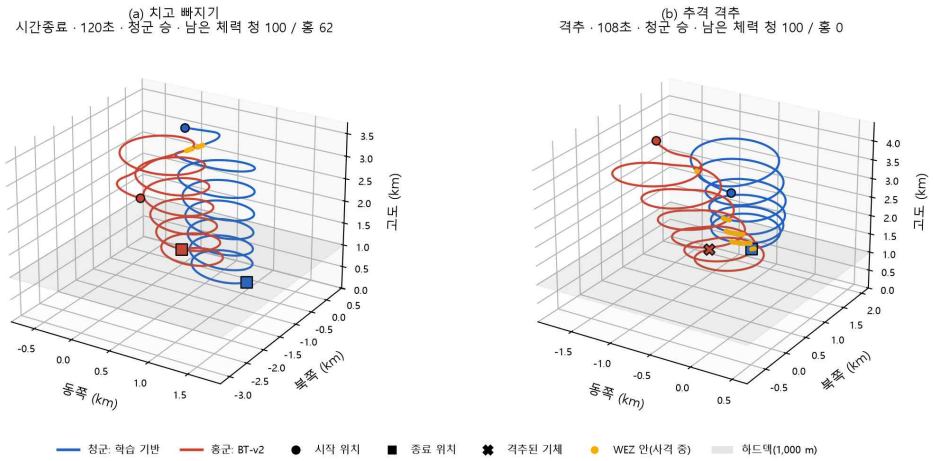
성능 정의	D* ≤ 2	D* ≤ 3	D* ≤ 5	D* ≤ 6
학습 상대	0.338	0.055	0.028	0.065
보류 상대	0.150	0.108	0.108	0.013
상대 2종 평균	0.175	0.038	0.038	−0.033

註: 평가 초기조건의 절반으로 모델을 고르고 나머지 절반에서 잰 점수 차(95% 기준 D*)이다. 음수는 모델 선택에 남는 0.03 안팎의 우연 변동이다.
出處: 저자 작성.

4.3. 설명 비용의 결정 요인(RQ2)

계열 사이의 D* 범위는 겹쳤다. 학습 기반 모델 20개 중 9개는 D*가 5 이하였고, 점수 2위인 모델은 D* = 3으로 BT-v2(4)보다 간결하였다. 학습 과정에서 D*는 복제본의 2에서 25세대에 약 7로 오른 뒤 300세대까지 평평했으나 점수는 0.54에서 0.71로 꾸준히 올라, 설명 비용은 성능과 함께 커지지 않았다.

같은 예산의 모델 20개에서 D*를 가른 것은 전술이었다(<그림 4-1>). 16개는 초반에 한 번 사격해 체력 우위를 만든 뒤 다시 붙지 않고 시간종료로 이기는 '치고 빠지기'로 D* 중앙값이 5였고, 4개는 끝까지 추격해 26~35%를 격추로 이기는 '추격 격추'로 D*가 8~17이었다. 종료 사유와 사격 시간으로 군집화한 가우시안 혼합모형도 같은 구분을 골랐으며, 군집 사이의 D* 차이는 유의했지만 군집 안에서는 점수와 D*의 상관이 없었다.



<그림 4-1> 두 전술의 교전 궤적

註: 직접 구현한 모의 환경의 교전 기록이다. (a) 치고 빠지기는 초반에 한 번 사격한 뒤 시간종료 체력 우위로, (b) 추격 격추는 끝까지 추격해 108초에 격추로 이겼다. 노란 점은 사격 구간, 회색 면은 최저 고도 1,000 m이다.

出處: 저자 작성.

4.4. 하이브리드 결합 방식(RQ3)

선형 혼합형은 순수 학습 기반 모델의 점수를 넘지 못하면서 D*는 대부분 절단값이었다. 감독형은 위반율을 0.009로 낮추었으나 점수가 학습 상대 0.487, 보류 상대 0.600으로 떨어지고 D*는 평균 12로 커졌다. 잔차형은 평균 11° 안팎의 작은 보정만으로 D*가 BT-v2의 4에서 6~17로 늘었고 보류 상대에게는 오히려 약해졌다. 게이팅형은 점수가 순수 학습 모델에 근접했지만 게이트가 상황과 무관한 고정 비율(0.36~0.61)로 수렴하였고, D* 3과 4인 두 모델을 섞은 결과의 95% 기준 D*는 17이었다. 90% 기준에서는 하이브리드의 D*도 2~4였으므로 결합이 늘린 것은 세부 행동의 복잡성이었고, 어느 방식도 원 모델 하나를 두 축에서 동시에 앞서지 못했다.

4.5. 평가 조건을 바꾼 재평가

제한시간을 240초로 늘리거나 시간종료를 무승부로 처리하면 학습 기반 모델의 BT-v2 상대 점수는 0.592와 0.498로 떨어졌다. 시간이 길어지면 초반의 체력 우위로 버티는 '치고 빠지기'가 통하지 않기 때문이다. 비행역학을 바꾼 설정에서도 점수와 D*의 상관은 다중비교 보정 후 모두 유의하지 않았다. 6자유도 F-16 재평가에서는 학습 기반 모델이 BT-v2에게 20개 모두 졌고(평균 0.371) 3자유도 점수 순위도

유지되지 않았으나(ρ = 0.12), 점수와 D*의 상관은 0.13에서 −0.47로 바뀌어 트레이드오프는 여기서도 나타나지 않았다.

5. 논의

5.1. 트레이드오프의 형태와 '고성능'의 조건

결과는 성능과 설명가능성이 언제나 맞바꿔야 하는 관계라는 통념을 지지하지 않지만, 둘이 무관하다는 뜻도 아니다. 설명 비용을 매우 엄격하게 묶으면 성능을 잃었고, 그 손실은 깊이 5~6의 규칙을 허용하면 대부분 사라졌다. 근접공중전의 좋은 조종이 상대의 방향, 사거리, 고도 같은 몇 개의 기하학적 판단으로 상당 부분 결정되기 때문으로 보인다. 약한 트레이드오프가 학습 상대 성능에서만 나타나고 보류 상대 성능에서는 반대였다는 점은, 특정 상대에 맞춘 세밀한 행동은 규칙으로 요약하기 어렵고 처음 보는 상대에게도 통하는 행동은 오히려 단순했음을 뜻한다. 학습 모델의 우위도 학습 상대, 120초 제한과 체력 비교 규칙, 3자유도 역학 안에서만 뚜렷했다. 따라서 본 연구는 "고성능 학습 모델도 설명 가능하다"고 주장하지 않으며, 어떤 정의로 성능을 재더라도 성능이 높을수록 설명 비용이 크다는 일관된 관계가 없었고 누가 고성능인가 자체가 평가 조건에 따라 바뀌었다고 말할 수 있을 뿐이다.

5.2. 시사점과 한계

설명 비용은 모델 종류가 아니라 전술의 성질이었다. 같은 구조의 신경망이라도 이긴 방식에 따라 3단계 규칙으로 재현되기도 하고 16단계로도 재현되지 않기도 했다. 따라서 공중전 AI를 평가할 때는 설명가능성을 모델 종류로 가정하지 말고 실제 행동으로 측정해야 하며, 성능은 훈련에 쓴 상대와 규칙 밖의 조건에서 따로 검증해야 한다. 하이브리드는 네 방식 모두 결합의 대가를 성능으로 보상받지 못했으므로, 지령을 섞기보다 규칙이 기동을 고르고 학습은 그 안의 세부 조종만 맡는 식으로 역할을 나누는 구조를 검토할 필요가 있다.

본 연구의 결과는 3자유도 점질량 모델에서 얻은 것이며, 6자유도 재평가에서 성능 순위와 D* 순위가 유지되지 않았으므로 성능과 개별 모델의 D* 값은 이 환경에 한정된다. 교전은 1대1 근접 기총 교전이고, 학습 모델은 BT−v2의 복제본에서 출발하였으며, 잔차형과 게이팅형은 학습 시드 3개의 소규모 실험이다. 무엇보다 D*는 행동 재현의 간결성이며 사람이 그 규칙을 실제로 이해하는지는 검증하지 않았다.

6. 결론

본 연구는 1대1 근접 기총 공중전 모의 환경에서 규칙 기반, 학습 기반, 하이브리드 모델을 같은 관측·지령·상대로 비교하고, 성능–설명가능성 트레이드오프를 연관성과 제약 비용의 두 검정으로 검증하였다. 성능이 높을수록 설명 비용이 크다는 강한 트레이드오프는 어떤 성능 정의에서도 관측되지 않았고, 설명 비용을 깊이 2 이하로 엄격하게 묶을 때만 뚜렷한 성능 손실이 있었다. 같은 예산의 모델 사이에서 설명 비용을 가른 것은 성능이 아니라 전술이었으며, 네 결합 방식의 하이브리드는 어느 것도 절충점이 되지 못했다. 이 결과는 공중전 AI의 설명가능성을 모델 종류로 가정하지 말고 행동으로 측정해야 하며, 성능은 평가 조건과 함께 보고해야 함을 시사한다. 후속 연구로는 사람의 이해도 실험, 6자유도 환경에서의 학습, 다수기·미사일 교전으로의 확장, 역할을 나눈 계층형 하이브리드를 제안한다.

- 참 고 문 헌 -

이민석·오지현·김천영·배정호·김용덕·지철규. 2022. “공대공 전투 모의를 위한 규칙기반 AI 교전 모델 개발.” 『한국군사과학기술학회지』, 제25권 제6호, pp. 637~647.

황인수·배정호. 2023. “커리큘럼을 이용한 투서클 기반 항공기 헤드온 공중 교전 강화학습 기법 연구.” 『한국군사과학기술학회지』, 제26권 제4호, pp. 352~360.

『스마트비즈』. 2026년 6월 9일. “KF-21 옆에 무인기 세운 KAI, 유·무인 공중전 체계로 답했다.” https://www.smartbizn.com/news/articleView.html?idxno=145816 (검색일: 2026년 9월 28일)

Alshiekh, Mohammed et al. 2018. “Safe Reinforcement Learning via Shielding.” *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32, No. 1.

Bastani, Osbert, Yewen Pu and Armando Solar-Lezama. 2018. “Verifiable Reinforcement Learning via Policy Extraction,” in *Advances in Neural Information Processing Systems 31*. Red Hook, NY: Curran Associates.

Berndt, Jon. 2004. “JSBSim: An Open Source Flight Dynamics Model in C++,” in *AIAA Modeling and Simulation Technologies Conference and Exhibit*, AIAA Paper 2004-4923. Providence, RI: AIAA.

Burgin, George H. and Laurent B. Sidor. 1988. *Rule-Based Air Combat Simulation*. NASA Contractor Report 4160. Washington, D.C.: NASA.

Doshi-Velez, Finale and Been Kim. 2017. “Towards A Rigorous Science of Interpretable Machine Learning.” arXiv:1702.08608.

General Atomics Aeronautical Systems. 2026. “GA-ASI Achieves New Milestone With Semi-Autonomous CCA Flight.” (February 12). https://www.ga.com/ga-asi-achieves-new-milestone-with-semi-autonomous-cca-flight (검색일: 2026년 10월 22일)

Gunning, David and David W. Aha. 2019. “DARPA’s Explainable Artificial Intelligence (XAI) Program.” *AI Magazine*, Vol. 40, No. 2, pp. 44~58.

Jacobs, Robert A., Michael I. Jordan, Steven J. Nowlan and Geoffrey E. Hinton. 1991. “Adaptive Mixtures of Local Experts.” *Neural Computation*, Vol. 3, No. 1, pp. 79~87.

Johannink, Tobias et al. 2019. “Residual Reinforcement Learning for Robot Control,” in *2019 International Conference on Robotics and Automation (ICRA)*, pp. 6023~6029. Piscataway, NJ: IEEE.

Pope, Adrian P. et al. 2021. “Hierarchical Reinforcement Learning for Air-to-Air Combat,” in *2021 International Conference on Unmanned Aircraft Systems (ICUAS)*, pp. 275~284. Piscataway, NJ: IEEE.

Rudin, Cynthia. 2019. “Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead.” *Nature Machine Intelligence*, Vol. 1, No. 5, pp. 206~215.

Saldiran, Emre, Mehmet Hasanzade, Gokhan Inalhan and Antonios Tsourdos. 2024. “Towards Global Explainability of Artificial Intelligence Agent Tactics in Close Air Combat.” *Aerospace*, Vol. 11, No. 6, 415.

Salimans, Tim, Jonathan Ho, Xi Chen, Szymon Sidor and Ilya Sutskever. 2017. “Evolution

Strategies as a Scalable Alternative to Reinforcement Learning." arXiv:1703.03864.
Schuirmann, Donald J. 1987. "A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability." *Journal of Pharmacokinetics and Biopharmaceutics*, Vol. 15, No. 6, pp. 657~680.
Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov. 2017. "Proximal Policy Optimization Algorithms." arXiv:1707.06347.
Semenova, Lesia, Cynthia Rudin and Ronald Parr. 2022. "On the Existence of Simpler Machine Learning Models," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*, pp. 1827~1858. New York: ACM.
Shaw, Robert L. 1985. *Fighter Combat: Tactics and Maneuvering*. Annapolis: Naval Institute Press.

Testing the Performance-Explainability Trade-off in Air-Combat AI: A Behavior-Level Comparison of Rule-based, Learning-based, and Hybrid Models

Cadet 4th Class Park Yoonjoon
Cadet 4th Class Son Hyeongrae
Cadet 4th Class Lee Sungjae
Cadet 4th Class Lee Junseo
Cadet 4th Class Trinh Vu Tuan Dat

- Abstract -

It is widely assumed that better-performing air-combat AI is harder to explain. This study tests whether such a performance-explainability trade-off exists in a simulated one-on-one within-visual-range gun engagement. Hand-written behavior trees, neural policies trained by evolution strategies, and hybrids that combine the two in four ways were compared under identical observations, commands, and opponents. Explainability was measured as the minimum depth of a decision tree that reproduces a policy's commands, interpreted as behavioral conciseness rather than human understanding. The trade-off was tested in two ways: whether higher-performing policies require deeper trees, and how much performance is lost when tree depth is capped. Across 282 conditions and 112,800 engagements, no strong association between performance and explanation cost was found (Spearman $\rho = -0.02$). Capping depth at two cost substantial performance, but allowing five to six levels removed most of the loss. Explanation cost was determined by tactics rather than performance, and none of the four hybrid designs outperformed one of its parent models on both axes. The learned policies' advantage held mainly against the training opponent and weakened or vanished against a held-out opponent, under altered engagement rules, and in a six-degree-of-freedom F-16 re-evaluation.

Keywords : Air-Combat AI, Explainable AI, Trade-off, Behavior Tree, Surrogate Model

보안성 검토에 대한 저자 의견서

논문 저자	소속	생도대	계급	00기 생도 (0학년)	성명	김공군
논문 제목	공중전 인공지능의 성능-설명가능성 트레이드오프 검증					

저자 의견

1. 항공우주연구소 주관 '26년 공사 생도 안보 논문경진대회 참가를 위해 작성된 논문임.

2. 위 논문은 공개 제원 기반 모의실험으로 공중전 인공지능 모델의 설명가능성과 전투성능의 관계를 연구하는 내용으로, 보안 위규 사항을 포함하고 있지 않으며, 군 내부 기밀 유출 등 보안에 저촉한 사례가 없음을 확인함.

년 월 일

계급 성명 (서명)

논문 유사도 검사 결과서

논문 제목 : 공중전 인공지능의 성능-설명가능성 트레이드오프 검증

(Testing the Performance-Explainability Trade-off in Air-Combat AI: A Behavior-Level Comparison of Rule-based, Learning-based, and Hybrid Models)

KCI 논문 유사도 검사* 결과 붙임

- https://check.kci.go.kr (KCI 문헌 유사도 검사 서비스) 활용

* KCI 논문유사도 검사시스템은 국민 누구나 무료로 이용 가능한 시스템으로써 이용자가 업로드하는 문헌과 KCI에 등록되어 있는 약200만여건의 KCI 및 국내 학술대회 논문을 비교하여 유사도 검사결괄ㄹ 보여주는 시스템입니다.

20 년 월 일

계급 성명 (서명)