

공중전 인공지능 모델의 설명가능성과 전투성능 트레이드오프 분석*

- 1대1 도그파이트에서 규칙 기반 · 학습 기반 · 하이브리드 모델
비교를 중심으로 -

(Explainability-Performance Trade-off in Combat AI: A
Comparison of Rule-based, Learning-based, and Hybrid Models
in a Simulated 1v1 Dogfight)

4학년 생도 박 윤 준**

(Cadet 4th Class Park Yoonjoon)

4학년 생도 손 형 래***

(Cadet 4th Class Son Hyeongrae)

4학년 생도 이 성 재****

(Cadet 4th Class Lee Sungjae)

4학년 생도 이 준 서*****

(Cadet 4th Class Lee Junseo)

4학년 생도 뚜 언 닷*

(Cadet 4th Class Trinh Vu Tuan Dat)

* 본 논문은 한국해양연구소 기부로 시작된 2026년 공군사관학교 안보 논문경진대회를 위하여 제출된 논문임.

** Corresponding Author: 박윤준(Park Yoonjoon)

공군사관학교 생도대 6중대 컴퓨터과학과

E-mail: a7513714@afa.ac.kr

Tel: 043-000-0000

*** 공군사관학교 생도대 4중대 컴퓨터과학과

E-mail: a7513738@afa.ac.kr

Tel: 043-290-0000

**** 공군사관학교 생도대 2중대 컴퓨터과학과

E-mail: a7513771@afa.ac.kr

Tel: 043-290-0000

***** 공군사관학교 생도대 4중대 컴퓨터과학과

E-mail: a7513786@afa.ac.kr

Tel: 043-290-0000

* 공군사관학교 생도대 8중대 컴퓨터과학과

E-mail: a7513853@afa.ac.kr

Tel: 043-290-0000

- 요약 문 -

본 연구는 “성능이 높은 공중전 인공지능일수록 설명하기 어렵다”는 통념을 1대1 근접 기총 공중전 모의 환경에서 측정하였다. 규칙 기반 행동트리, 진화전략으로 학습한 신경망, 두 모델을 네 가지 방식으로 결합한 하이브리드를 같은 관측·지령·상대로 비교하고, 설명가능성은 모델의 조종 기록을 95% 재현하는 결정트리의 최소 깊이(D^*)로 측정하였다. 282개 조건, 112,800회 교전의 결과 강한 트레이드오프는 관측되지 않았으며($\rho = -0.02$), 설명 비용을 가른 것은 모델 종류나 성능이 아니라 전술이었다. 학습 기반 모델은 학습 상대와의 직접 대결에서는 규칙 기반 모델을 이겼으나, 보류 상대·다른 교전 규칙·6자유도 F-16 재평가에서는 우위가 약해지거나 사라졌다. 네 결합 방식의 하이브리드는 모두 성능과 설명가능성의 절충점이 되지 못했다. 이 결과는 공중전 인공지능의 설명가능성을 모델 종류로 가정하지 말고 행동으로 측정해야 하며, 성능은 평가 조건과 함께 보고해야 함을 시사한다.

주제어 : 공중전 인공지능, 설명가능 인공지능, 행동트리, 하이브리드 모델, 대리모델

1. 서론

1.1. 연구 배경 및 문제 제기

2026년 2월 미 공군의 협동전투기(CCA: Collaborative Combat Aircraft) 시제기 YFQ-42A는 자율비행 소프트웨어를 탑재한 채 지상 운용자의 감독 아래 4시간이 넘는 반자율 임무비행을 수행하였다.¹⁾ 국내에서도 2026년 6월 한국항공우주산업(KAI: Korea Aerospace Industries)이 KF-21과 협업 무인기를 연동한 유·무인 복합 공중전 체계를 공개하며, 유인 전투기가 후방에서 작전을 지휘하고 무인기가 전방의 위험 임무를 맡는 운용 개념을 제시하였다.²⁾ 2020년 미 국방고등연구계획국(DARPA: Defense Advanced Research Projects Agency)이 주관한 알파독파이트 트라이얼(AlphaDogfight Trials)에서 강화학습(RL: Reinforcement Learning) 기반 인공지능(AI: Artificial Intelligence)이 숙련 조종사를 이긴 지³⁾ 불과 6년 만에, AI 조종은 시연의 대상에서 전력화의 대상으로 바뀌고 있다.

그러나 유인기가 무인기를 "지휘"한다는 개념에는 한 가지 전제가 깔려 있다. 지휘하는 조종사가 무인기의 AI가 왜 그렇게 기동했는지를 이해하고 감독할 수 있어야 한다는 것이다. YFQ-42A 시험에서 비행 안전 기능과 상위 임무 자율 논리를 분리한 "감독된 자율(supervised autonomy)"이 강조된 것도 같은 맥락이다.⁴⁾ 판단 근거를 확인할 수 없는 모델은 성능이 높더라도 교전 권한을 위임받기 어렵다.

이 문제에 대해서는 널리 받아들여지는 통념이 있다. 첫째, 사람이 규칙을 직접 작성한 행동트리(BT: Behavior Tree) 같은 규칙 기반 모델은 설명은 되지만 성능이 떨어진다. 둘째, 신경망 기반의 학습 모델은 성능은 높지만 내부를 읽을 수 없는 블랙박스다. 셋째, 둘을 결합한 하이브리드 모델은 설명이 되면서 성능은 그 중간쯤일 것이다. 본 연구는 이 세 명제를 출발 가설(H1~H3)로 삼는다. 그러나 이 명제들이 같은 과업·같은 조건에서 정량적으로 측정된 적은 드물며, 성능과 해석가능성 사이의

1) "General Atomics YFQ-42A Collaborative Combat Aircraft Completes First Semi-Autonomous Mission," Army Recognition, February 17, 2026. <https://www.armyrecognition.com/news/aerospace-news/2026/general-atomics-yfq-42a-collaborative-combat-aircraft-completes-first-semi-autonomous-mission> (검색일: 2026년 9월 28일)

2) "KF-21 옆에 무인기 세운 KAI, 유·무인 공중전 체계로 답했다," 『스마트비즈』, 2026년 6월 9일. <https://www.smartbizn.com/news/articleView.html?idxno=145816> (검색일: 2026년 9월 28일)

3) Adrian P. Pope et al., "Hierarchical Reinforcement Learning for Air-to-Air Combat," in *2021 International Conference on Unmanned Aircraft Systems (ICUAS)* (Piscataway, NJ: IEEE, 2021), pp. 275~284.

4) "General Atomics YFQ-42A Collaborative Combat Aircraft Completes First Semi-Autonomous Mission," 2026.

트레이드오프가 항상 존재하는 것은 아니라는 반론도 제기되어 왔다.⁵⁾ 기존 공중전 AI 연구는 강화학습 단일 계열의 성능 향상이나 학습이 끝난 모델에 대한 사후 설명에 집중해 왔으나, 규칙 기반·학습 기반·하이브리드 모델을 같은 조건에서 같은 잣대로 비교한 연구는 찾기 어렵다. 특히 하이브리드는 규칙과 학습을 어떤 방식으로 결합하느냐에 따라 전혀 다른 모델이 될 수 있음에도, 결합 방식 자체를 비교한 연구는 확인되지 않는다.

1.2. 설명가능성의 두 층위

위 가설들을 그대로 측정하려고 하면 곧바로 벽에 부딪힌다. 설명가능성을 "모델 내부를 사람이 읽을 수 있는가", 즉 내재적(intrinsic) 설명가능성으로 정의하면 행동 트리는 정의상 설명 가능하고 신경망은 정의상 블랙박스이다. 이 경우 설명가능성은 측정값이 아니라 모델 종류에 붙은 이름표가 되어, H1·H2는 성능만 비교하면 끝나고 H3의 하이브리드는 "얼마나" 설명 가능한지를 잴 방법이 없다.

따라서 본 연구는 설명가능성을 두 층위로 구분한다. 내재적 설명가능성은 모델 종류로 이미 정해지는 전제로 받아들이고, 본 연구가 측정하는 것은 행동 수준(behavioral) 설명가능성, 즉 모델이 실제로 수행한 조종을 몇 단계의 if-then 규칙으로 옮겨 적을 수 있는가이다. 이를 위해 각 모델이 남긴 행동 로그에 결정트리 대리모델(surrogate model)을 적합시키고, 원 행동을 목표 수준 이상으로 재현하는 데 필요한 최소 트리 깊이(D*)를 구한다.⁶⁾ D*가 작을수록 그 행동을 더 간결한 규칙으로 재현할 수 있다는 뜻이다. 이 지표는 모델 내부 구조와 무관하게 행동 로그만으로 계산되므로 규칙 기반·학습 기반·하이브리드 모델에 동일하게 적용된다. 다만 D*는 행동을 얼마나 간결하게 재현할 수 있는지를 나타낼 뿐, 사람이 그 규칙을 실제로 이해하는지를 직접 측정하지는 않는다. 설명가능 인공지능의 평가 분류로 보면 사람 실험 없이 모델의 성질로 재는 기능 기반(functionally-grounded) 평가에 해당하며,⁷⁾ 사람 대상 이해도 검증은 본 연구의 한계로 남긴다. 비유하자면 내재적 설명가능성은 "조종사가 교범을 외웠는가"를, 행동 수준 설명가능성은 "그 조종사가 오늘 한 기동

5) Cynthia Rudin, "Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead," *Nature Machine Intelligence*, Vol. 1, No. 5 (May 2019), pp. 206~215.

6) Osbert Bastani, Yewen Pu and Armando Solar-Lezama, "Verifiable Reinforcement Learning via Policy Extraction," in Samy Bengio et al. (eds.), *Advances in Neural Information Processing Systems 31* (Red Hook, NY: Curran Associates, 2018), pp. 2494~2504.

7) Finale Doshi-Velez and Been Kim, "Towards A Rigorous Science of Interpretable Machine Learning," arXiv:1702.08608 (2017). <https://arxiv.org/abs/1702.08608> (검색일: 2026년 9월 28일)

을 교범 몇 줄로 적을 수 있는가"를 묻는 것이다.

1.3. 연구 목적 및 연구 질문

본 연구의 목적은 F-16급 1대1 근접공중전(WVR: Within Visual Range) 도그파이트 시뮬레이션에서 규칙 기반 모델, 학습 기반 모델, 그리고 네 가지 결합 방식의 하이브리드 모델을 전투 성능·행동 수준 설명가능성·규칙 준수의 세 축에서 통제 비교하여, 성능과 설명가능성의 관계를 정량적으로 검증하는 것이다. 하이브리드는 두 모델의 지령을 고정 비율로 섞는 선형 혼합형, 안전 조건에서만 규칙이 개입하는 감독형, 규칙 지령 위에 학습 모델이 작은 보정치만 더하는 잔차형, 상황에 따라 혼합 비율을 스스로 정하는 게이팅형으로 나누어 비교한다. 연구 질문(RQ: Research Question)은 다음과 같다.

첫째(RQ1), 규칙 기반·학습 기반·하이브리드 모델의 전투 성능과 설명가능성 사이에는 어떤 관계가 있는가. 둘째(RQ2), 학습량이 늘어날 때 두 축은 어떻게 함께 움직이는가. 셋째(RQ3), 규칙 준수는 이 관계에서 어떤 위치에 있는가. 넷째(RQ4), 하이브리드의 결합 방식에 따라 성능-설명가능성 관계가 달라지는가.

본 연구의 기여는 네 가지이다. 첫째, 모델 계열에 무관하게 행동 로그만으로 계산되는 행동 재현 간결성 지표를 공중전 과업에 적용하여 서로 다른 계열을 한 축 위에 놓았다. 둘째, 동일한 초기조건에서 양 진영을 교대하여 두 번 교전시키는 짝지은 평가 설계로 초기조건 편향을 제거하였다. 셋째, 학습량과 하이브리드 결합 방식을 독립변수로 두어, 몇 개의 점이 아니라 성능-설명가능성 관계의 형태를 제시한다. 넷째, 교전 규칙과 비행역학을 바꾼 재평가, 그리고 판정 기준을 미리 정해 둔 6자유도 F-16 교차검증으로 결론이 성립하는 범위를 점검하였다.

이하 2장에서는 관련 연구를, 3장에서는 실험 환경과 비교 모델 및 평가 방법을 기술한다. 4장에서 실험 결과를 제시하고, 5장에서 결과의 의미와 한계를 논의한 뒤, 6장에서 결론을 맺는다.

2. 이론적 배경 및 선행연구

2.1. 공중전 인공지능 연구 동향

공중전 인공지능은 교범의 기본전투기동을 "조건이면 행동" 형태의 규칙으로 옮긴 규칙 기반 모델에서 출발하였다. 미 항공우주국(NASA: National Aeronautics and Space Administration)의 적응형 기동 논리(AML: Adaptive Maneuvering Logic)는

지면 회피를 최우선으로 두고, 상대를 향한 기수 지향과 리드·래그 추격을 차례로 판단하는 결정 계층을 갖추었다.⁸⁾ 그러나 이 규칙 기동은 사람이 몇 번의 모의비행만으로 다음 기동을 예측할 수 있다는 비판을 받았고, 개발자들은 일부 기동을 난수로 고르도록 바꾸었다.⁹⁾ 국내에서도 행동트리와 퍼지 기반 상황 판단을 결합한 규칙 기반 교전 모델이 개발되었는데, 행동트리가 고른 전술 행위를 교전 중 화면에 보여 주어 판단 과정을 검증할 수 있다는 점을 블랙박스인 기계학습 모델과 구별되는 장점으로 내세웠다.¹⁰⁾ 이 연구에서도 교전이 반복될수록 조종사가 인공지능의 기동에 적응하는 모습이 관찰되었다.¹¹⁾ 30여 년의 간격을 둔 두 연구는 같은 현상을 보고한다. 규칙 기반 모델의 투명성은 아군의 검증을 쉽게 하지만 상대의 예측도 쉽게 만든다.

기동 전략을 사람이 직접 쓰지 않고 계산하려는 시도는 근사 동적계획법을 거쳐¹²⁾ 강화학습으로 이어졌다. 알파독과이트 트라이얼에서 계층형 강화학습 에이전트는 8개 팀 중 2위를 기록하며 미 공군 F-16 무기교관과정 수료 조종사를 이겼다.¹³⁾ 국내 연구는 주로 학습이 되게 만드는 방법에 집중하여, 조준각 기반 커리큘럼을 적용해 커리큘럼 없이는 제한된 시간 안에 학습되지 않던 조준각 60° 이상의 초기 상황까지 180°의 범위에서 학습을 완료하거나¹⁴⁾ 투서클 기반 커리큘럼으로 규칙 기반 상대에게 거의 100%의 승률을 얻었다.¹⁵⁾ 후자에서 규칙 기반 모델은 학습 에이전트의 "성능 비교의 이정표"로 쓰였다.¹⁶⁾ 이후 연구는 실제 비행으로도 넓어져, 미 국방고등연구계획국의 공중전 진화(ACE: Air Combat Evolution) 사업은 2023년 인공지능이 조종하는 X-62A와 유인 F-16의 실제 가시거리 내 교전 시험을 수행하였다.¹⁷⁾

8) George H. Burgin and Laurent B. Sidor, *Rule-Based Air Combat Simulation*, NASA Contractor Report 4160 (Washington, D.C.: NASA Scientific and Technical Information Division, September 1988), pp. i, 3-4~3-5. <https://ntrs.nasa.gov/citations/19890018022> (검색일: 2026년 9월 30일)

9) Burgin and Sidor, 1988, pp. viii, 6-1~6-2.

10) 이민석·오지현·김천영·배정호·김용덕·지철규, “공대공 전투 모의를 위한 규칙기반 AI 교전 모델 개발,” 『한국군사과학기술학회지』, 제25권 제6호 (2022), pp. 639, 645.

11) 이민석 외, 2022, p. 644.

12) James S. McGrew, Jonathan P. How, Brian Williams and Nicholas Roy, “Air-Combat Strategy Using Approximate Dynamic Programming,” *Journal of Guidance, Control, and Dynamics*, Vol. 33, No. 5 (2010), pp. 1641~1654.

13) Pope et al., 2021.

14) 배정호·강운성·윤석민·김용덕·김성호, “커리큘럼 러닝을 이용한 항공기 강화학습,” 『정보과학회논문지』, 제48권 제6호 (2021), pp. 707~712.

15) 황인수·배정호, “커리큘럼을 이용한 투서클 기반 항공기 헤드온 공중 교전 강화학습 기법 연구,” 『한국군사과학기술학회지』, 제26권 제4호 (2023), p. 359.

16) 황인수·배정호, 2023, p. 356.

17) DARPA, “ACE Program Achieves World First for AI in Aerospace,” April 17, 2024.

성능이 실비행 단계에 이르면서 과제는 "이길 수 있는가"에서 "믿고 맡길 수 있는가"로 옮겨 가고 있다. ACE 사업은 전투 자율성에 대한 인간의 신뢰를 측정·보정·향상·예측하는 방법을 사업 목표로 명시하였다.¹⁸⁾ 근접공중전 강화학습 에이전트의 설명가능성을 직접 다룬 살디란(Emre Saldiran) 등은 보상 분해를 이용해 심층 Q-네트워크(DQN: Deep Q-Network) 에이전트가 어떤 보상을 중시했는지를 전술 영역별로 제시하였다. 이들은 결정트리로 정책을 단순화하는 방법을 배제하였는데, 성능을 맞추려고 트리를 깊게 하면 설명가능성의 이점이 사라진다는 이유였다.¹⁹⁾ 정리하면 공중전 인공지능은 승률, 타격량, 교전 시간 같은 성능 지표로 평가되어 왔고, 설명은 규칙 모델 내부의 가시화나 특정 학습 구조에서만 쓸 수 있는 보상 분해로 제공되었다. 규칙 기반·학습 기반·하이브리드 모델의 행동을 하나의 척도로 재고 이를 전투 성능과 나란히 비교한 연구는 확인되지 않는다. "트리를 깊게 해야 하면 설명가능성이 사라진다"는 전제도 그 깊이가 실제로 얼마인지 측정되지 않은 채 받아들여져 있으며, 본 연구의 D*는 바로 이 깊이를 잴다.

2.2. 설명가능 인공지능과 그 평가

설명가능 인공지능(XAI: Explainable Artificial Intelligence)의 방법은 크게 두 갈래로 나뉜다. 하나는 결정트리나 규칙 목록처럼 구조 자체를 읽을 수 있는 모델을 처음부터 사용하는 내재적 방법이고, 다른 하나는 이미 학습된 모델의 판단을 사후에 풀어내는 사후(post-hoc) 방법이다. 사후 방법 가운데 LIME(Local Interpretable Model-agnostic Explanations)과 샤프리 가법 설명(SHAP: SHapley Additive exPlanations)은 모델 종류를 가리지 않고, 특정 판단에 어떤 입력이 얼마나 기여했는지를 계산한다.²⁰⁾²¹⁾ 강화학습 분야에서는 보상을 생존, 공격처럼 의미 있는 성분으로 나누어 에이전트가 어떤 행동을 왜 선호했는지를 보여주는 보상 분해 기법이

<https://www.darpa.mil/news/2024/ace-ai-aerospace> (검색일: 2026년 9월 30일)

18) DARPA, "Air Combat Evolution (ACE)." <https://www.darpa.mil/research/programs/air-combat-evolution> (검색일: 2026년 9월 30일)

19) Emre Saldiran, Mehmet Hasanzade, Gokhan Inalhan and Antonios Tsourdos, "Towards Global Explainability of Artificial Intelligence Agent Tactics in Close Air Combat," *Aerospace*, Vol. 11, No. 6 (2024), 415, p. 3.

20) Marco Tulio Ribeiro, Sameer Singh and Carlos Guestrin, "Why Should I Trust You?": Explaining the Predictions of Any Classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (New York: ACM, 2016), pp. 1135~1144.

21) Scott M. Lundberg and Su-In Lee, "A Unified Approach to Interpreting Model Predictions," in Isabelle Guyon et al. (eds.), *Advances in Neural Information Processing Systems 30* (Red Hook, NY: Curran Associates, 2017), pp. 4765~4774.

제안되었다.²²⁾

그러나 이 기법들은 본 연구의 질문, 즉 "서로 다른 계열의 모델 가운데 어느 쪽의 행동이 더 간결하게 설명되는가"에 답하기에는 적합하지 않다. LIME과 SHAP은 개별 판단 하나하나에 대한 국소적 기여도를 주기 때문에, 모델 전체의 행동이 얼마나 단순한지를 하나의 수치로 비교하는 데 쓰기 어렵다. 보상 분해는 보상이 성분별로 설계되어 있고 가치 함수(Q-함수)를 학습하는 에이전트에만 적용되므로, 행동트리나 진화전략으로 학습한 정책에는 쓸 수 없다. 즉 기존 기법들은 한 모델의 판단을 풀어내는 데는 유용하지만, 여러 계열을 같은 잣대로 비교하는 도구는 아니다.

이 공백을 메울 수 있는 방법이 대리모델이다. 학습된 모델의 입력과 출력을 훑어내는 결정트리를 따로 적합시키고, 그 트리가 원 모델을 얼마나 충실하게 재현하는지(충실도)를 보는 방식으로, 신경망에서 트리 구조를 추출하려는 연구에서 시작되었다.²³⁾ 바스타니(Osbert Bastani) 등은 이를 강화학습 정책에 적용하여 신경망 정책을 결정트리 정책으로 추출하는 VIPER(Verifiability via Iterative Policy ExtRaction)를 제안하였다.²⁴⁾ 다만 VIPER의 목적은 추출한 트리를 신경망 대신 사용하면 그 안전성을 검증하는 데 있었고, 서로 다른 계열의 설명가능성을 비교하지는 않았다. 본 연구는 같은 발상을 측정 도구로 바꾸어, "원 행동을 95% 이상 재현하는 데 필요한 최소 트리 깊이"를 모든 계열에 동일하게 적용한다.

이러한 지표의 성격은 도시-벨레스(Finale Doshi-Velez)와 김(Been Kim)의 평가 분류로 정리할 수 있다.²⁵⁾ 이들은 설명가능성 평가를 실제 임무 환경에서 사람과 함께 검증하는 응용 기반 평가, 단순화한 과제로 사람을 실험하는 사람 기반 평가, 사람 없이 모델의 성질로 채는 기능 기반 평가로 나누었다. 본 연구의 D*는 기능 기반 평가에 해당한다. 비용이 적고 수백 개 조건에 반복 적용할 수 있다는 장점이 있지만, 사람이 실제로 이해하는지까지는 말해주지 않는다. 본 연구가 D*를 "행동 재현 간결성"으로 한정해 해석하는 이유이다.

22) Zoe Juozapaitis, Anurag Koul, Alan Fern, Martin Erwig and Finale Doshi-Velez, "Explainable Reinforcement Learning via Reward Decomposition," in *Proceedings of the IJCAI 2019 Workshop on Explainable Artificial Intelligence* (2019).

23) Mark W. Craven and Jude W. Shavlik, "Extracting Tree-Structured Representations of Trained Networks," in David S. Touretzky, Michael C. Mozer and Michael E. Hasselmo (eds.), *Advances in Neural Information Processing Systems 8* (Cambridge, MA: MIT Press, 1996), pp. 24~30.

24) Bastani, Pu and Solar-Lezama, 2018.

25) Doshi-Velez and Kim, 2017.

2.3. 성능-해석가능성 트레이드오프 논쟁과 하이브리드 제어

"성능이 높은 모델일수록 설명하기 어렵다"는 트레이드오프는 XAI 논의의 출발점처럼 여겨져 왔다. 미 국방고등연구계획국의 XAI 사업도 학습 기법들의 성능과 설명가능성이 반비례하는 개념도를 제시하고, 둘을 함께 높이는 것을 목표로 삼았다.²⁶⁾ 반면 루딘(Cynthia Rudin)은 이 트레이드오프가 실증되지 않은 통념에 가깝고, 의미 있는 특징으로 구성된 데이터에서는 해석 가능한 모델도 블랙박스 모델과 비슷한 성능을 내는 경우가 많다고 반박하였다.²⁷⁾ 그런데 이 논쟁은 대부분 한 번의 분류나 예측을 내리는 정적 과업을 두고 이루어졌다. 매 순간 연속 지령을 내려야 하는 공중전 같은 순차 의사결정 과업에서 트레이드오프가 실제로 존재하는지를 측정한 사례는 드물다.

규칙과 학습의 결합은 이 트레이드오프를 피하는 실용적 방법으로 제안되어 왔다. 행동트리는 모듈 단위로 조립하기 쉽고 사람이 읽을 수 있어 게임 AI와 로봇 제어에서 널리 쓰이며, 학습 모듈과 결합하기도 쉽다.²⁸⁾ 결합 방식은 목적에 따라 다양하다. 학습 정책의 행동을 감시하다가 안전 명세를 어길 때만 수정하는 안전 감독(shield),²⁹⁾ 기존 제어기의 출력 위에 학습 정책이 보정치만 더하는 잔차 학습,³⁰⁾ 상황에 따라 여러 전문가 모델의 비중을 게이트가 정하는 전문가 혼합³¹⁾이 대표적이다. 본 연구의 감독형·잔차형·게이팅형 하이브리드는 각각 이 세 계보를 공중전 과업에 맞게 단순화한 것이며, 여기에 두 지령을 고정 비율로 섞는 가장 단순한 선형 혼합형을 기준으로 더하였다.

그러나 이 결합 방식들은 각자의 목적에 따라 안전성, 학습 효율, 성능으로 평가되었을 뿐, 결합한 결과가 얼마나 설명 가능한지는 평가되지 않았다. 서로 다른 결합 방식을 같은 과업에서 같은 잣대로 나란히 비교한 연구도 찾기 어렵다. "규칙과 학습을 섞으면 설명도 되고 성능도 난다"는 기대는 이처럼 검증되지 않은 채 남아 있다.

26) David Gunning and David W. Aha, "DARPA's Explainable Artificial Intelligence (XAI) Program," *AI Magazine*, Vol. 40, No. 2 (Summer 2019), pp. 44~58.

27) Rudin, 2019.

28) Michele Colledanchise and Petter Ögren, *Behavior Trees in Robotics and AI: An Introduction* (Boca Raton: CRC Press, 2018).

29) Mohammed Alshiekh et al., "Safe Reinforcement Learning via Shielding," *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32, No. 1 (2018).

30) Tobias Johannink et al., "Residual Reinforcement Learning for Robot Control," in *2019 International Conference on Robotics and Automation (ICRA)* (Piscataway, NJ: IEEE, 2019), pp. 6023~6029.

31) Robert A. Jacobs, Michael I. Jordan, Steven J. Nowlan and Geoffrey E. Hinton, "Adaptive Mixtures of Local Experts," *Neural Computation*, Vol. 3, No. 1 (1991), pp. 79~87.

2.4. 본 연구의 차별성

이상을 정리하면 기존 연구는 세 가지 공백을 남긴다. 첫째, 공중전 AI 연구는 성능 향상에 집중했을 뿐 설명가능성을 정량적으로 측정하지 않았다. 둘째, XAI 기법은 한 모델의 판단을 풀어내는 데 초점을 두어 규칙 기반·학습 기반·하이브리드 모델을 같은 잣대로 비교하지 못했다. 셋째, 하이브리드 결합 방식은 각자 안전성이나 효율로만 평가되었고 결합 방식끼리 비교되지 않았다. 본 연구는 행동 로그만으로 계산되는 행동 재현 간결성 지표를 모든 계열에 동일하게 적용하고, 하이브리드 결합 방식 자체를 실험 변수로 두어 이 세 공백을 하나의 통제 실험 안에서 다룬다. <표 2-1>은 이를 요약한 것이다.

<표 2-1> 선행 연구와 본 연구의 비교

연구	대상 모델	설명가능성을 무엇으로 보는가	계열 간 정량 비교	하이브리 드 결합 방식 비교
규칙 기반 교전 모델(이민석 외, 2022)	규칙 기반	행동트리 결정의 실시간 가시화(정성)	×	×
공중전 강화학습(포프 외, 2021; 황인수·배정호, 2023)	학습 기반(규칙 기반은 성능 기준선)	측정하지 않음(승률·타격량·교 전 시간)	×	×
공중전 전역 설명(살디란 외, 2024)	학습 기반(DQN)	보상 성분별 기여의 전술 영역별 집계	×	×
LIME·SHAP	모델 무관	개별 판단에 대한 입력 기여도	×	×
보상 분해(주오자파이티스 외, 2019)	가치 기반 강화학습	보상 성분별 기여	×	×
VIPER(바스타니 외, 2018)	학습 기반 → 결정트리 추출	추출한 트리의 성능·검증 가능성	×	×
안전 감독·잔차 학습·전문가 혼합	하이브리드(각 1종)	측정하지 않음(안전성·효율 평가)	×	×
본 연구	규칙 기반·학습 기반·하이브리드 4종	행동 재현 간결성(D*)	○	○


註: ○ 해당, × 해당 없음.

出處: 각 선행연구를 바탕으로 저자 작성.

3. 연구 방법

3.1. 연구 설계 개요

본 연구는 모델링 및 시뮬레이션(M&S: Modeling and Simulation) 기반의 통제 실험이다. 규칙 기반·학습 기반·하이브리드 모델이 같은 모의 환경에서 같은 관측을 받아 같은 종류의 지령을 내도록 맞춘 뒤, 같은 상대·같은 초기조건에서 교전시키고, 그 기록으로 전투 성능·행동 수준 설명가능성·규칙 준수의 세 축을 측정한다. 전체 흐름은 <그림 3-1>과 같고, 실험의 변인은 <표 3-1>과 같다.



<그림 3-1> 연구 프레임워크

出處: 저자 작성.

<표 3-1> 실험 변인

구분	변인	수준
독립변인	모델 계열	규칙 기반(행동트리 3종), 학습 기반, 하이브리드
	하이브리드 결합 방식	선형 혼합형, 감독형, 잔차형, 게이팅형
	학습 예산	0(복제본)·100·200·300세대 ^a
	혼합계수 α (선형 혼합형)	0.25, 0.5, 0.75 (1.0은 순수 학습 기반)
종속변인	전투 성능	점수, 순수승률, 종료 사유
	행동 수준 설명가능성	최소 트리 깊이 D^* , 깊이 4 층실도 $F(4)$
	규칙 준수	스텝당 안전규칙 위반율
통제변인	모의 환경·교전 규칙	전 조건 동일(<표 3-2>)
	관측·지령 공간	관측 20개, 지령 3개로 전 모델 동일
	평가 상대·초기조건	상대 2종, 고정된 초기조건 100개, 진영 교대
	학습 방법·적합도	학습이 필요한 모든 모델에 같은 진화전략·같은 적합도

註: a: 잔차형·게이팅형은 100·200세대.

出處: 저자 작성.

3.2. 모의실험 환경

연구 계획 단계에서는 항공대 AI 파일럿 경진대회의 F-16 시뮬레이션 환경을 사용하려 하였다. 그러나 이 환경은 조종간·페달·스로틀을 직접 제어하는 고차원 입력을 쓰고 교전 1회에 수 초가 걸려, 수만 회 교전이 필요한 학습과 10만 회가 넘는 평가를 제출 기한 안에 수행할 수 없었다. 따라서 본 연구는 같은 교전 개념을 축소 재현한 전용 모의 환경을 구현하였다.³²⁾ 교전 1회의 계산 시간은 약 0.02초이다.

기체는 F-16급 공개 제원을 사용한 3자유도 점질량 모델이다. 모든 모델은 원시 위치·속도 대신 교전 기하로 표현된 관측 20개(상대 거리, 기수-시선각(ATA: Antenna Train Angle), 애스펙트각(AA: Aspect Angle), 접근률, 고도차, 비에너지차, 양측 잔여 체력, 경과 시간 등)를 받고, 뱅크각·하중배수·스로틀의 지령 3개를 낸다. 세 계열이 같은 관측과 같은 지령 공간을 공유한다는 점이 3.4.2절의 설명가능성 비교를 공정하게 만드는 전제이다. 주요 설정은 <표 3-2>와 같다.

32) 모의 환경·비교 모델·분석 코드의 구현과 실험 실행, 원고 초안 작성에는 생성형 인공지능 도구 (Anthropic Claude)를 활용하였다. 연구 질문과 실험 설계, 결과의 해석, 최종 원고의 내용에 대한 책임은 저자에게 있다.

<표 3-2> 모의 환경의 주요 설정

항목	값
기체 모델	3자유도 점질량, 질량 9,300 kg, 주익 면적 27.87 m ² , 최대 양력계수 1.6, 해면 최대추력 106 kN, 구조 한계 9 G
지령 응답	1차 지연(뱅크 0.35초, 하중배수 0.30초, 스로틀 1.2초)
시간 간격	적분 0.05초, 제어 주기 0.2초, 교전 제한 120초
기총	무장 유효 교전 구역(WEZ: Weapon Engagement Zone) 거리 120~1,200 m, 명중 원추 반각 3°→10°(시간에 따라 확대), 초당 체력 25 감소(체력 100)
종료 조건	격추, 지면 충돌(패), 거리 60 m 미만 공중 충돌(무승부), 120초 경과 시 잔여 체력 비교(같으면 무승부)
초기 조건	거리 1.5~3.5 km, 고도 3~5 km, 속도 180~260 m/s를 양측 동일하게, 기수 방위만 무작위
안전 규칙	최저 고도(하드텍) 1,000 m, 하중배수 8 G, 최소 이격 150 m (위반해도 교전은 계속되며 기록만 함)

出處: 저자 작성.

점질량 모델은 받음각, 실속·스핀, 탄도를 모사하지 않고, 롤 운동도 뱅크 지령의 1차 지연으로만 근사한다. 그럼에도 이 수준을 택한 이유는 두 가지다. 첫째, 본 연구가 묻는 것은 조종면 조작이 아니라 "어느 쪽으로, 몇 G로 선회하고, 추력을 얼마나 쓰는가"라는 전술 판단 수준의 설명가능성이다. 조종면 입력을 직접 내는 환경에서 대리모델을 적합시키면 D*에 자세 제어의 고주파 성분까지 섞여 측정하려는 대상이 흐려진다. 공중전 기동 의사결정 연구에서도 같은 이유로 자세 운동을 무시한 3자유도 질점 모델이 널리 쓰인다.³³⁾³⁴⁾³⁵⁾ 둘째, 가용 하중배수를 양력 한계와 구조 한계 중 작은 값으로 두었기 때문에, 선회율이 최대가 되는 코너 속도나 에너지를 잃으면 선회가 둔해지는 현상처럼 근접공중전의 핵심 성질이 모델 안에서 나타난다. 다만 행동트리의 "양력 방향을 상대 쪽으로" 같은 규칙이나 학습 기반 모델이 찾은 전술은 모두 이 역학에 맞춰져 있으므로, 단순화가 특정 계열에 유리하게 작용할 가능성은

33) Qiming Yang, Jiandong Zhang, Guoqing Shi, Jinwen Hu and Yong Wu, "Maneuver Decision of UAV in Short-Range Air Combat Based on Deep Reinforcement Learning," *IEEE Access*, Vol. 8 (2020), pp. 364~365.

34) Weiren Kong, Deyun Zhou, Zhen Yang, Yiyang Zhao and Kai Zhang, "UAV Autonomous Aerial Combat Maneuver Strategy Generation with Observation Error Based on State-Adversarial Deep Deterministic Policy Gradient and Inverse Reinforcement Learning," *Electronics*, Vol. 9, No. 7 (2020), 1121, p. 5.

35) Hyunju Park, Byung-Yoon Lee, Min-Jea Tahk and Dong-Wan Yoo, "Differential Game Based Air Combat Maneuver Generation Using Scoring Function Matrix," *International Journal of Aeronautical and Space Sciences*, Vol. 17, No. 2 (2016), p. 205.

배제할 수 없다. 이를 점검하기 위해 비행역학 파라미터를 바꾼 재평가와 6자유도 F-16 모델 교차검증을 수행하였다(3.5절, 4.8절).

3.3. 비교 모델

3.3.1. 규칙 기반 모델: 행동트리 3종

행동트리는 "이 조건이면 이 행동"이라는 규칙을 우선순위 순서로 엮은 나무 구조로, 매 제어 주기마다 위에서부터 조건을 확인해 처음 맞는 행동을 실행한다. 세 트리는 기본전투기동(BFM: Basic Fighter Maneuvers) 교범의 표준 전술³⁶⁾만을 사람이 규칙으로 옮겨 쓴 것이며, 데이터로 상수를 맞추지 않았다. 세 트리는 성숙도의 단계가 아니라 서로 다른 교리를 대표한다(<표 3-3>).

<표 3-3> 규칙 기반 모델 3종

모델	노드 수	교리	규칙(우선순위 순)
BT-v1	8	수평 추격	① 정면 합류 회피 ② 기수 정렬 시 날개 수평·4 G ③ 그 밖에는 상대 쪽 75° 뱅크·4 G
BT-v2	5	3차원 최대 선회	① 정면 합류 회피 ② 양력 방향을 상대 쪽으로 돌리고 가용 최대 G·최대 추력
BT-v3	11	BT-v2 + 안전규칙	① 정면 합류 회피 ② 하드텍+400 m 아래면 날개 수평·상승 ③ 사거리 안이면 리드 추격(8 G 상한) ④ 그 밖에는 BT-v2와 같은 추격(8 G 상한)

註: 정면 합류 회피는 거리 1 km 이내에서 서로 정면으로 빠르게 접근할 때 반대쪽으로 75° 뱅크해 비켜 가는 규칙이다. 이 규칙이 없을 때는 순수 추격 트리끼리 교전의 45~53%가 공중 충돌로 끝나 세 트리 모두에 추가하였다.

出處: 저자 작성.

BT-v3를 조종사의 말로 옮기면 네 문장이 된다. "정면으로 빠르게 다가오면 옆으로 비켜라. 낮으면 먼저 고도를 회복하라. 사거리 안에 상대가 들어오면 상대 앞을 겨누고 8 G 안에서 당겨라. 그 밖에는 상대 쪽으로 선회하라." 이처럼 사람이 그대로 읽을 수 있다는 것이 규칙 기반 모델의 내재적 설명가능성이다.

3.3.2. 학습 기반 모델

학습 기반 모델은 관측 20개를 받아 지령 3개를 내는 다층 퍼셉트론(MLP: Multi-Layer Perceptron)이다(은닉층 32·32, 가중치 1,827개). 내부가 숫자의 묶음

36) Robert L. Shaw, *Fighter Combat: Tactics and Maneuvering* (Annapolis: Naval Institute Press, 1985).

이므로 사람이 읽을 수 없다.

이 신경망은 두 단계로 만들었다. 먼저 BT-v2가 교전한 기록 161,694개를 흉내 내도록 가중치를 맞추는 행동복제로 초기화하였다(뱅크 지령 재현도 R^2 0.95). 이어서 진화전략(ES: Evolution Strategies)³⁷⁾으로 다듬었다. 진화전략은 가중치를 조금씩 다르게 흔든 후보 32개를 각각 8회 교전시키고, 잘 싸운 후보 쪽으로 가중치를 옮기는 과정을 한 세대로 삼아 반복한다(탐색 폭 σ 0.05, 학습률 0.01). 여기에 갱신 전후를 같은 초기조건으로 비교해 나빠지면 갱신을 거부하는 수용 검사를 더하였다. 학습 상대는 BT-v1과 BT-v2를 번갈아 사용하였고, BT-v3는 학습에 한 번도 쓰지 않았다. 학습 예산은 300세대, 학습 시드는 20개이다.

교전 결과를 하나의 수치로 평가하는 적합도는 가한 피해와 받은 피해의 차, WEZ 체류 시간, 종료 결과에 따른 보상(격추승 +10, 시간종료승 +5, 지면 충돌 -15 등), 상대를 향한 정도를 나타내는 포텐셜 항,³⁸⁾ 안전규칙 위반 벌점(위반율 $\times -3$), 양측 무피해 시간종료 벌점(-8)의 합으로 정의하였다.

이 설계에 이르기까지 세 번의 실패가 있었다. 첫 적합도로 학습한 정책은 싸우지 않고 멀리 도망가 기수만 상대 쪽으로 두는 방식으로 점수를 챙겼다. 적합도를 고친 뒤에도 무작위 가중치에서 시작하면 회피로 수렴하였고, 행동복제로 시작하자 이번에는 진화전략의 갱신이 복제된 행동을 100세대 만에 지워 버렸다. 각각 포텐셜 항의 근접 가중, 행동복제 초기화, 수용 검사로 해결하였다. 무작위 초기화가 회피로 수렴한 것은, 교전을 시도하면 BT-v2에게 격추되어 큰 손실을 보고 도망가면 작은 손실만 보는 보상 구조에서 진화전략이 싸우는 정책을 우연히 발견하기 어렵기 때문이다.

이 모델은 누적 보상을 최대화하는 순차 의사결정 과업, 즉 강화학습 과업을 진화 전략이라는 기울기 없는 방법으로 푼 것이다. 표준 강화학습 알고리즘과의 차이를 확인하기 위해 3.3.4절에서 근위 정책 최적화(PPO: Proximal Policy Optimization)³⁹⁾ 조건을 함께 둔다.

37) Tim Salimans, Jonathan Ho, Xi Chen, Szymon Sidor and Ilya Sutskever, “Evolution Strategies as a Scalable Alternative to Reinforcement Learning,” arXiv:1703.03864 (2017). <https://arxiv.org/abs/1703.03864> (검색일: 2026년 9월 30일)

38) Andrew Y. Ng, Daishi Harada and Stuart Russell, “Policy Invariance under Reward Transformations: Theory and Application to Reward Shaping,” in *Proceedings of the Sixteenth International Conference on Machine Learning* (San Francisco: Morgan Kaufmann, 1999), pp. 278~287.

39) John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov, “Proximal Policy Optimization Algorithms,” arXiv:1707.06347 (2017). <https://arxiv.org/abs/1707.06347> (검색일: 2026년 9월 30일)

3.3.3. 하이브리드 모델 4종

하이브리드는 규칙 기반 지령과 학습 기반 지령을 합치는 방식에 따라 네 종류로 나누었다(<표 3-4>). 2.3절의 세 계보(안전 감독, 잔차 학습, 전문가 혼합)에 가장 단순한 선형 혼합을 기준으로 더한 구성이다.

<표 3-4> 하이브리드 결합 방식

방식	혼합 비율을 누가 정하나	지령	학습
선형 혼합형	사람이 α 를 고정	$a = (1-\alpha) \cdot a_{BT} + \alpha \cdot a_L$	학습 기반 모델과 함께(α 를 관측으로 입력), 300세대·20시드
감독형	사람이 쓴 안전 조건	안전 조건이면 BT-v3 안전 규칙, 아니면 a_L (8 G 상한)	추가 학습 없음, 300세대 학습 기반 모델 20개에 적용
잔차형	규칙이 빠대, 학습은 보정	$a = a_{BT} + \beta \cdot \delta(o)$, $\beta = 0.35$	8만 학습, 200세대·3시드
게이팅형	게이트 신경망이 상황마다	$a = (1-g(o)) \cdot a_{BT} + g(o) \cdot a_L$	게이트만 학습, 200세대·3시드

註: a_{BT} 는 BT-v2의 지령, a_L 은 학습 기반 모델의 지령, o 는 관측이다. 뱃크 지령은 각도이므로 모든 방식에서 원형 평균·원형 합으로 계산한다. 잔차형의 $\beta = 0.35$ 는 뱃크 최대 $\pm 63^\circ$, 하중배수 최대 $\pm 1.6 G$, 스로틀 최대 $\pm 17.5\%$ 의 보정에 해당한다. 게이팅형의 a_L 은 학습 시드 11의 300세대 모델(20개 중 점수 2위, $D^* = 3$)을 고정해 사용하였다.

出處: 저자 작성.

감독형은 학습 모델이 무엇을 할지 정하고 규칙은 하지 말아야 할 것만 막는 안전 감독 개념을,⁴⁰⁾ 잔차형은 기존 제어기 위에 학습이 보정만 엮는 잔차 학습 개념을,⁴¹⁾ 게이팅형은 상황에 따라 여러 모델의 비중을 정하는 전문가 혼합 개념을⁴²⁾ 공중전 과업에 맞게 단순화한 것이다. 잔차형과 게이팅형은 선형 혼합형과 감독형의 결과를 본 뒤 "결합 방식을 잘못 골라서가 아닌가"라는 반론을 확인하기 위해 추가한 확장 실험으로, 본실험보다 규모가 작다(3시드·200세대).

3.3.4. 통제 조건

주요 반론 두 가지를 확인하기 위해 통제 조건을 두었다. 첫째, "규칙 기반 모델이

40) Alshiekh et al., 2018.

41) Johannink et al., 2019.

42) Jacobs, Jordan, Nowlan and Hinton, 1991.

약한 것은 사람이 상수를 손으로 정했기 때문"이라는 반론을 확인하기 위해, BT-v3와 구조는 같게 두고 상수 9개만 학습 기반 모델과 같은 진화전략·적합도·예산으로 최적화한 상수 최적화 행동트리(BTO)를 3시드 만들었다. 결과물은 여전히 사람이 읽을 수 있는 규칙이다. 둘째, "학습 방법이 진화전략 하나뿐"이라는 반론을 확인하기 위해, 행동복제 없이 무작위 초기화에서 PPO로 150만 스텝 학습한 모델을 2시드 만들었다.

3.4. 평가 지표

3.4.1. 전투 성능

주 지표는 점수(승 1, 무 0.5, 패 0의 평균)이며 0.5가 대등이다. 무승부가 적지 않으므로(BT-v2 자기 대전의 49%) 무승부를 뺀 순수승률과 종료 사유(격추, 시간 종료, 지면·공중 충돌)의 분포를 함께 보고한다.

3.4.2. 행동 수준 설명가능성

각 모델이 교전 중 남긴 (관측, 지령) 기록에 깊이 d 인 결정트리 회귀모형을 적합시키고, 적합에 쓰지 않은 기록에서 원래 지령을 얼마나 재현하는지를 결정계수(R^2)로 측정한다. 이를 깊이 d 의 충실도 $F(d)$ 라 하며, 지령 3개의 R^2 는 각 지령의 분산으로 가중 평균한다. 분산 가중은 스로틀을 항상 최대로 두는 모델처럼 변하지 않는 지령이 충실도를 부풀리는 것을 막기 위한 것이다.

D^* 는 $F(d)$ 가 0.95 이상이 되는 가장 작은 깊이이다. 깊이 d 인 결정트리는 "if-then 질문을 최대 d 번 연달아 던져 지령을 정하는 규칙"이므로, D^* 는 "이 모델의 조종을 95% 재현하려면 규칙이 몇 단계 필요한가"를 뜻한다. D^* 가 작을수록 행동을 더 간결한 규칙으로 재현할 수 있다. 깊이 16까지 검사해 0.95에 이르지 못하면 17로 기록하고 절단으로 표기한다. 앞서 밝힌 대로 D^* 는 행동 재현의 간결성을 재는 기능 기반 지표이며, 사람의 이해도를 직접 측정하지 않는다.

기록은 평가 교전 가운데 상대별 초기조건 30개의 교전에서 0.2초마다 수집하였고 (모델당 약 28,000~35,000개), 70%로 트리를 적합하고 30%로 충실도를 계산하였다. 목표 충실도 하나에 결론이 좌우되지 않도록 $D^*(0.90)$, $D^*(0.99)$, $F(4)$ 를 보조 지표로 함께 보고한다.

이 지표는 모델의 내부가 아니라 행동을 잴다. "행동트리는 원래 트리라서 결정트리로 재현하기 쉽다"는 반론이 가능하지만, 대리모델은 모델의 구조가 아니라 관측된 행동에 적합되며, 실제로 노드 5개인 BT-v2는 양력 방향을 연속 함수로 계산하기 때문에 $D^* = 4$ 인 반면 BT-v2를 흉내 낸 신경망 복제본은 $D^* = 2$ 였다.

3.4.3. 규칙 준수

<표 3-2>의 안전규칙 세 가지 가운데 하나라도 어긴 적분 스텝(0.05초)의 비율을 위반율로 정의한다. 교전 1회는 최대 2,400스텝이므로, 위반율 0.05는 2,400스텝 중 120스텝 동안 규칙을 어기고 있었다는 뜻이다. 사람의 해석이 들어가지 않는 객관적 지표이다. 위반율이 0인 경우는 "평가 교전에서 위반이 관측되지 않았다"는 뜻으로만 해석하며, 안전이 보장된다는 뜻으로 해석하지 않는다.

3.5. 평가 절차와 통계 분석

상대와 진영 교대. 모든 모델은 두 상대와 교전한다. BT-v2는 학습에 사용한 상대이고, BT-v3는 학습에 한 번도 쓰지 않은 보류 상대이다. 보류 상대에 대한 성능은 학습 기반 모델이 학습 상대에만 맞춰진 것이 아닌지를 보여준다. 성능은 상대별로 따로 보고하고 두 상대의 평균은 보조로만 쓴다. BT-v2 자신의 평균 점수에는 자기 자신과의 대전(항상 0.500)이 포함되어 다른 모델의 평균과 그대로 비교할 수 없기 때문이다.

초기조건은 평가용으로 고정한 100개를 쓰고, 같은 초기조건에서 청군과 홍군을 바꿔 한 번 더 교전한다. 한쪽 자리가 유리한 초기조건이라도 두 판을 합치면 그 효과가 상쇄된다. 실제로 BT-v2끼리 교전시켰을 때 진영 교대 전에는 한쪽 점수가 0.59였으나 교대 후에는 정확히 0.500이 되었다. 따라서 모델 하나는 상대 2종 $\times$ 초기조건 100개 $\times$ 진영 2 = 400회 교전으로 평가된다.

조건 격자. 본실험은 규칙 기반 3개, 학습 기반·선형 혼합형 244개(학습 예산 100·200·300세대 $\times$ α 4수준 $\times$ 학습 시드 20개 = 240개, 여기에 예산 0인 복제본을 α 4수준으로 평가한 4개), 통제 조건 35개(BTO 9개, 감독형 20개, PPO 6개)의 282조건 $\times$ 400회 = 112,800회 교전이다. 잔차형·게이팅형 확장 실험은 두 방식 각 6조건(3시드 $\times$ 100·200세대)에 비교 기준 6조건(규칙 기반 3개, 학습 시드 11의 순수 학습 기반·선형 혼합형(α 0.5)·감독형)을 더한 18조건 $\times$ 400회 = 7,200회 교전이다. 확장 실험의 비교 기준 조건은 본실험과 점수·D*가 소수점 셋째 자리까지 같아, 두 평가가 같은 조건에서 이루어졌음을 확인하였다.

분석 단위. 표본의 독립성을 지키기 위해 분석 단위를 세 층으로 구분한다. 첫째, 진영만 바꾼 두 교전은 독립이 아니므로 초기조건 단위로 묶는다. 둘째, 282개 조건은 같은 학습 시드에서 파생된 조건이 많아 서로 독립이 아니므로, 조건 단위의 순위 상관관계의 형태를 요약하는 데만 쓴다. 셋째, 모델 계열 간 주장의 독립 표본은 학습 시드(본실험 20개)이며, 학습 시드를 임의효과로 넣은 혼합모형과 학습 시드

단위 상관을 주 분석으로 삼는다. 확장 실험은 학습 시드가 3개뿐이므로 통계 검정 없이 기술적으로 비교한다.

통계 기법. 점수의 신뢰구간은 Wilson 95% 구간,⁴³⁾ 같은 초기조건을 공유하는 두 모델의 비교는 대응표본 Wilcoxon 부호순위 검정,⁴⁴⁾ 여러 비교의 오류 누적은 Holm 보정⁴⁵⁾으로 처리하였다. 성능과 D*의 관계는 Spearman 순위상관 ρ 로 측정하였는데, D*에 절단값(17)이 있어 값보다 순위를 쓰는 방법이 적합하기 때문이다. "유의한 상관이 없다"를 넘어 "상관이 작다"고 말할 수 있는지는 양측 단측 검정(TOST: Two One-Sided Tests)⁴⁶⁾으로 확인하였다.

강건성 점검. 주 결론이 측정 방식이나 특정 설정의 산물이 아닌지 확인하기 위해 다음 분석을 더하였다. 첫째, D*와 점수의 반분 신뢰도와 감쇠 보정 상관, 학습 시드를 통째로 재추출하는 클러스터 부트스트랩이다.⁴⁷⁾ 둘째, 모든 조건의 기록에서 고르게 뽑은 관측 40,000개를 모든 모델에 똑같이 질의해 켜 공통 상태 D*이다. 기본 D*는 각 모델이 스스로 겪은 상황으로 계산하므로, 좁은 범위의 상황만 겪는 모델이 간결해 보일 수 있기 때문이다. 셋째, 종료 사유와 WEZ 체류 시간으로 전술을 분류한 가우시안 혼합모형 군집(군집 수는 BIC로 선택)이다.⁴⁸⁾ 넷째, 학습 시드 12개를 25세대 간격으로 평가한 세밀 분석과, 학습 기반 모델 20개와 규칙 기반 모델 6개의 전원 대전이다. 다섯째, 같은 26개 모델을 교전 규칙(제한시간 240초, 시간종료 무승부)이나 비행역학(최대 양력계수·최대추력·지령 지연 $\pm 20\%$, 롤 속도 상한 $180\cdot 90^\circ/\text{s}$)을 바꾼 환경에서 다시 학습하지 않고 재평가한 민감도 분석이다. 여섯째, 31개 모델을 공개 비행역학 라이브러리 JSBSim의 6자유도 F-16 모델로 옮겨 평가한 교차검증이다.⁴⁹⁾ 이때 모델이 낸 뱅크각·하중배수·스로틀 지령은 새로 구현한 추

43) Edwin B. Wilson, "Probable Inference, the Law of Succession, and Statistical Inference," *Journal of the American Statistical Association*, Vol. 22, No. 158 (June 1927), pp. 209~212.

44) Frank Wilcoxon, "Individual Comparisons by Ranking Methods," *Biometrics Bulletin*, Vol. 1, No. 6 (December 1945), pp. 80~83.

45) Sture Holm, "A Simple Sequentially Rejective Multiple Test Procedure," *Scandinavian Journal of Statistics*, Vol. 6, No. 2 (1979), pp. 65~70.

46) Donald J. Schuirmann, "A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability," *Journal of Pharmacokinetics and Biopharmaceutics*, Vol. 15, No. 6 (1987), pp. 657~680.

47) Bradley Efron, "Bootstrap Methods: Another Look at the Jackknife," *The Annals of Statistics*, Vol. 7, No. 1 (1979), pp. 1~26.

48) Gideon Schwarz, "Estimating the Dimension of a Model," *The Annals of Statistics*, Vol. 6, No. 2 (1978), pp. 461~464.

49) Jon Berndt, "JSBSim: An Open Source Flight Dynamics Model in C++," in *AIAA Modeling and Simulation Technologies Conference and Exhibit* (Providence, RI: AIAA, 2004), AIAA Paper

중 제어기가 조종간 입력으로 바뀌며, D*는 두 환경 모두 모델이 낸 지령으로 계산하므로 정의가 같다. 6자유도 교차검증의 판정 기준은 평가 전에 문서로 정해 두었다.

3.6. 연구 가설과 판정 기준

1.1절의 출발 가설을 본 연구의 지표로 판정할 수 있게 다음과 같이 정의하였다. 모든 판정은 행동 수준 설명가능성(D*)에 대한 것이다.

- H1(규칙 기반은 설명되지만 약하다): 규칙 기반 모델은 학습 기반 모델보다 D*가 작고 점수가 낮다.
- H2(학습 기반은 강하지만 설명되지 않는다): 학습 기반 모델은 규칙 기반 모델보다 점수가 높고 D*가 크다.
- H3(하이브리드는 설명되면서 성능은 중간이다): 하이브리드는 D*가 규칙 기반 수준이면서 점수는 규칙 기반과 학습 기반 사이이다.

연구 질문 4(하이브리드 결합 방식)에 대해서는 방향을 정한 가설 대신 판정 기준을 두었다. 잔차형·게이팅형 가운데 하나라도 점수가 학습 기반에 가깝고 D*가 규칙 기반 수준인 영역에 들어오면 "H3은 결합 방식에 따라 성립한다"로, 두 방식 모두 그렇지 않으면 "H3의 기각이 네 결합 방식으로 확장된다"로 판정한다. 이 기준은 확장 실험의 결과가 산출되기 전인 2026년 9월 23일 연구 기록에 먼저 정해 두었다.

4. 실험 결과

4.1. 학습 기반 모델의 학습 결과

순수 학습 기반 모델($\alpha = 1$)은 학습 예산이 늘수록 학습 상대를 더 잘 이겼다(<표 4-1>). BT-v2와의 직접 대결 점수는 행동복제 초기 모델(이하 복제본)의 0.438에서 300세대 0.687로 올랐고, 300세대 모델 20개 모두 0.5를 넘었다. 무승부를 뺀 순수승률은 20개 중 18개가 Holm 보정 후에도 0.5보다 유의하게 높았다. 상대 2종 평균 점수와 학습 예산의 순위상관은 $\rho = 0.45$ ($p = 0.0003$, $n = 61$)였고, 학습 시드를 임의효과로 넣은 혼합모형에서도 예산의 효과가 유의하였다($p = 0.0001$). 같은 기간 위반율은 0.096에서 0.050으로 줄었다.

그러나 학습에 한 번도 쓰지 않은 보류 상대 BT-v3에 대해서는 결과가 달랐다. 300세대 모델의 BT-v3 상대 점수는 평균 0.746(0.60~0.84)으로 출발점인 복제본

(0.840)보다 낮았고, 같은 상대에 대한 BT-v2의 점수(0.843)를 넘은 모델은 없었다. 즉 학습 기반 모델은 학습 상대를 직접 이기는 법은 익혔지만, 제3의 상대를 다루는 능력에서는 규칙 기반 최강 모델을 넘지 못했다. 한편 학습 기반 모델 20개, 행동트리 3종, BTO 3개를 한 풀에 넣고 서로 전부 교전시킨 전원 대전(초기조건 30개)에서는 학습 기반 모델 20개 모두(풀 점수 0.48~0.58)가 BT-v2(0.43)보다 높았고, 풀 점수와 본실험 점수의 순위상관은 0.90이었다.

<표 4-1> 학습 예산에 따른 순수 학습 기반 모델의 변화

구분	0세대 (복제본)	100세대	200세대	300세대
점수(BT-v2 상대)	0.438	0.581 ± 0.093	0.639 ± 0.065	0.687 ± 0.057
점수(BT-v3 상대)	0.840	0.711 ± 0.101	0.710 ± 0.075	0.746 ± 0.058
D*	2	8.1 ± 4.5	7.2 ± 3.8	7.6 ± 4.6
깊이 4 층실도 F(4)	0.975	0.926	0.932	0.929
위반율	0.096	0.062	0.046	0.050

註: 학습 시드 20개의 평균 ± 표준편차이며, 0세대는 복제본 1개의 값이다. 점수는 승 1, 무 0.5, 패 0의 평균이다.

出處: 저자 작성.

4.2. 계열별 전투 성능·설명가능성·규칙 준수

<표 4-2>는 계열별 결과를, <그림 4-1>은 최종 예산의 모델들을 성능-설명가능성 평면에 나타낸 것이다. 세 방향으로 읽을 수 있다.

전투 성능. BT-v2와의 직접 대결에서는 학습 기반 모델(0.687), 선형 혼합형 α 0.75(0.687), 게이팅형(0.647)이 앞섰고, BTO(0.321), PPO(0.390), BT-v1·BT-v3는 BT-v2에 졌다. 보류 상대 BT-v3에 대해서는 BTO(0.882), BT-v2(0.843), 복제본(0.840)이 가장 높았고, 학습 기반 모델과 하이브리드는 0.60~0.80이었다.

설명가능성. D*는 BT-v1(1), 복제본(2), BTO(3~5), BT-v2(4), BT-v3(5)가 가장 작았다. 학습 기반 모델은 중앙값 6(3~17)으로 20개 중 9개가 5 이하였고 3개가 절단이었다. 하이브리드는 감독형이 중앙값 11, 선형 혼합형과 게이팅형은 대부분이 절단이었다.


규칙 준수. BT-v3(0.008), 감독형(0.009), PPO(0.002)의 위반율이 가장 낮았고, 학습 기반 모델(0.050)은 BT-v2(0.100)의 절반이었다.

<표 4-2> 계열별 전투 성능·설명가능성·규칙 준수

계열	모델 수	점수 (BT-v2 상대)	점수 (BT-v3 상대)	D* 중앙값 (범위)	위반율
BT-v1	1	0.250	0.233	1	0.005
BT-v2	1	(0.500)	0.843	4	0.100
BT-v3	1	0.158	(0.500)	5	0.008
상수 최적화 행동트리(BTO)	3	0.321	0.882	3 (3~5)	0.057
복제본(학습 예산 0)	1	0.438	0.840	2	0.096
학습 기반(300세대)	20	0.687	0.746	6 (3~17)	0.050
무작위 초기화 PPO	6	0.390	0.380	5 (4~7)	0.002
선형 혼합형 α 0.25	20	0.531	0.707	17 (5~17)	0.069
선형 혼합형 α 0.5	20	0.586	0.691	17 (6~17)	0.061
선형 혼합형 α 0.75	20	0.687	0.755	17 (5~17)	0.051
감독형	20	0.487	0.600	11 (6~17)	0.009
잔차형(200세대)	3	0.565	0.690	6 (6~17)	0.064
게이팅형(200세대)	3	0.647	0.797	17 (17)	0.066

註: 점수는 계열 안 모델들의 평균이며, 괄호 안 값은 자기 자신과의 대전이다. 선형 혼합형과 감독형은 300세대 학습 기반 모델에 적용한 값이다. D* = 17은 깊이 16까지 목표 충실도에 이르지 못한 절단값이다.

出處: 저자 작성.



<그림 4-1> 최종 예산 모델의 성능-설명가능성 평면

註: 가로축은 상대 2중 평균 점수, 세로축은 D^* 이다. 같은 값의 점이 겹치지 않도록 세로 방향으로 작게 흘려 뒀다. 학습 기반·선형 혼합형·감독형은 300세대, 잔차형·게이팅형은 200세대, PPO는 150만 스텝 모델이다.
出處: 저자 작성.

4.3. 성능과 설명가능성의 관계(RQ1)

트레이드오프가 있다면 점수가 높은 모델일수록 D^* 가 커야 하므로 순위상관 ρ 는 양수여야 한다. <표 4-3>은 이 관계를 여러 방식으로 측정한 결과이다. 282개 조건 전체의 순위상관은 $\rho = -0.02$ ($p = 0.75$)였고, 조건 단위와 학습 시드 단위 부트스트랩의 90% 신뢰구간이 모두 ± 0.2 안에 들어와 동등성 검정으로 "상관의 크기가 0.2보다 작다"가 성립하였다. 주 분석으로 정한 학습 시드 임의효과 혼합모형에서 D^* 의 계수는 0.001 ($p = 0.82$)이었고, 학습 시드 단위 순위상관도 -0.13 ($p = 0.59$)이었다. D^* 만 설명변수로 넣으면 D^* 가 클수록 점수가 낮은 유의한 관계가 나왔으나, 혼합계수 α 와 학습 예산을 함께 넣자 사라졌다. 선형 혼합형이 순수 학습 기반 모델

보다 점수는 낮고 D*는 커서 α 가 두 변수를 함께 움직였기 때문이다.

D*의 측정 잡음이 상관을 0으로 끌어내렸을 가능성도 확인하였다. 전반과 후반 교전으로 나누어 켄 반분 신뢰도는 D* 0.82, 점수 0.96이었고, 이를 보정한 상관도 -0.02 였다. 모든 모델에 같은 관측 40,000개를 질의해 켄 공통 상태 D*는 점수와 $\rho = 0.19$ ($p = 0.001$)의 약한 양의 상관을 보였지만, 점수가 높은 모델일수록 방문하는 상황의 폭이 좁았고($\rho = -0.24$) 이 폭을 통제한 편상관은 0.00 ($p = 0.98$)이었다.

다만 혼합 정책을 제외하면 결과가 달라진다. 282개 조건 가운데 183개(65%)가 선형 혼합형이고 그중 80%가 절단값이어서, 전체 상관은 이 덩어리의 영향을 크게 받는다. 행동트리·BTO·학습 기반·PPO만으로 이루어진 79개 조건에서는 $\rho = 0.17$ ($p = 0.14$)로 유의하지 않았지만 90% 신뢰구간이 $-0.03 \sim 0.35$ 에 걸쳐, 동등성 기준 (± 0.2)을 충족하지 못하였다. 이 부분집합에서는 약한 양의 관계를 배제할 수 없다.

<표 4-3> 점수와 D*의 관계

분석	표본	결과
조건 단위 순위상관(전체)	282개 조건	$\rho = -0.02$ ($p = 0.75$), 90% 구간 $[-0.12, 0.08]$
학습 시드 클러스터 부트스트랩	282개 조건, 시드 20개	90% 구간 $[-0.18, 0.15]$
혼합모형(점수 $\sim$ D* + 예산 + α)	244개 조건, 시드 20개	D* 계수 0.001 ($p = 0.82$)
혼합모형(점수 $\sim$ D*)	244개 조건, 시드 20개	D* 1 표준편차당 -0.014 ($p = 0.0006$)
학습 시드 단위 순위상관	학습 시드 20개	$\rho = -0.13$ ($p = 0.59$)
감쇠 보정 상관	282개 조건	$\rho = -0.02$
공통 상태 D*와 점수	282개 조건	$\rho = 0.19$ ($p = 0.001$), 방문 범위 통제 시 0.00
학습 기반·하이브리드만	244개 조건	$\rho = -0.18$ ($p = 0.006$)
혼합 정책 제외	79개 조건	$\rho = 0.17$ ($p = 0.14$), 90% 구간 $[-0.03, 0.35]$

註: 혼합모형은 학습 시드를 임의절편으로 둔 선형 혼합모형이다. 학습 시드 단위 상관은 순수 학습 기반 모델을 시드별로 평균한 값이다. 혼합 정책 제외는 행동트리 3개, BTO 9개, 학습 기반 61개(예산 0~300세대), PPO 6개이다.


出處: 저자 작성.

실험을 진행하며 학습 시드를 3개, 5개, 8개, 20개로 늘리는 동안 전체 순위상관은 0.38 ($p = 0.011$), 0.06 , -0.16 , -0.02 로 움직였다. 시드 3개일 때는 통계적으로 유

의한 트레이드오프가 관측되었으나 반복을 늘리자 사라졌다.

4.4. 학습량에 따른 변화(RQ2)

<표 4-1>에서 D^* 는 학습 예산에 따라 한 방향으로 움직이지 않았다(예산과 D^* 의 순위상관 $\rho = -0.03$, $p = 0.83$). 변화의 모양을 보기 위해 학습 시드 12개(8~19번)를 25세대 간격으로 평가하였다(<그림 4-2>). 점수는 복제본을 떠난 직후인 25세대에 0.537로 내려갔다가 300세대 0.705까지 꾸준히 올랐다($\rho = 0.46$, $p < 0.0001$, $n = 144$). 반면 자기 기록으로 켜 D^* 는 복제본의 2에서 25세대에 7.2로 뛰어오른 뒤 300세대까지 6.2~8.6 사이에서 평평하였다($\rho = 0.04$, $p = 0.60$). 같은 시드 안에서 초기(50~100세대)와 후기(250세대 이상)의 D^* 는 7.8 대 8.4로 유의한 차이가 없었다(Wilcoxon $p = 0.73$, $n = 12$). 8시드 시점의 분석에서 보였던 "증가 후 감소" 형태는 이 해상도에서 재현되지 않았다. 공통 상태 D^* 는 다른 모양을 보였다. 복제본의 4에서 25세대 10.0, 275세대 16.0까지 대체로 올랐고, 그동안 상태 방문 범위는 좁아졌다(예산과 방문 범위 $\rho = -0.32$, $p = 0.0001$).



<그림 4-2> 학습 예산에 따른 점수와 D^* 의 변화

註: 학습 시드 8~19번(12개)의 25세대 간격 체크포인트를 상대 2종 $\times$ 초기조건 50개 $\times$ 진영 2 = 200회 교전으로 평가한 평균이다. 0세대는 본실험의 복제본 값이며, 음영은 ± 1 표준편차이다.

出處: 저자 작성.

4.5. 같은 예산, 다른 전술

300세대 학습 기반 모델 20개는 점수가 비슷해도 D^* 가 3에서 17까지 갈랐다. 종로 방식을 보면 두 전술이 나타났다. 다수인 16개는 교전 초반에 한 번 스치듯 사격해 체력 우위를 만든 뒤 상대와 어긋난 선회를 유지하며 다시 붙지 않고 시간종료

체력 우위로 이겼다(이하 '치고 빠지기', 격추 비율 2~14%, 시간종료 82~96%). 교전 규칙상 정당한 승리 방식이다. 이 16개의 D*는 중앙값 5였고 16개 중 15개가 3~9였다. 나머지 4개(시드 1, 10, 12, 14)는 끝까지 붙어 격추로 이기는 비율이 26~35%였고(이하 '추격 격추'), D*는 8~17이었다.

이 구분이 결과를 본 뒤 붙인 이름이 아님을 가우시안 혼합모형 군집으로 확인하였다. 300세대 학습 기반 모델 20개를 종료 사유 비율, WEZ 체류 시간, 교전 시간으로 군집화하자 BIC가 3개 군집을 골랐고, 사람이 나눈 두 전술과 같은 구분이 나왔다(<표 4-4>). 학습 기반·하이브리드 264개 조건 전체로 넓히면 4개 군집이 선택되었고 군집 사이의 D* 차이는 유의하였다(Kruskal-Wallis $H = 30.6$, $p < 0.0001$).⁵⁰⁾ 그러나 네 군집 각각의 안에서는 점수와 D*의 상관이 없었다($\rho = -0.17 \sim -0.08$, 모두 $p > 0.19$). 연속 축으로 보아도 격추승 비율과 D*는 양의 상관을 보였다($\rho = 0.21$, $p = 0.0007$, $n = 264$).

<표 4-4> 300세대 학습 기반 모델의 전술 군집

군집	모델 수	격추승 비율	시간종료 비율	점수	D* 평균 (중앙값)
치고 빠지기	16	0.044	0.907	0.706	6.2 (5)
추격 격추 A	2	0.246	0.653	0.737	14.0 (14)
추격 격추 B	2	0.289	0.659	0.777	12.5 (12.5)

註: 종료 사유 비율, WEZ 체류 시간, 교전 시간을 표준화하여 가우시안 혼합모형으로 군집화하였고, 군집 수는 BIC가 최소인 3을 택하였다. 점수는 상대 2종 평균이다.

出處: 저자 작성.

'치고 빠지기'가 적합도 설계(시간종료승 +5)의 산물인지 확인하기 위해, 격추승 +25, 시간종료승 +1, WEZ 체류 가중 2배인 격추 우선 적합도로 학습 시드 2개를 다시 학습하였다. 격추 비율은 올랐지만 시간종료승이 여전히 60~96%로 주된 승리 방식이었고, 격추를 강하게 쫓은 모델 하나(시드 1, 300세대)는 지면 충돌 18%, 위반율 0.128, D* 17(절단)로 성능·안전·설명가능성이 함께 나빠졌다.

4.6. 하이브리드 결합 방식(RQ4)

선형 혼합형. 선형 혼합형은 점수에서 같은 예산의 순수 학습 기반 모델을 넘지 못했고(α 0.75, 300세대만 비슷한 수준), D*는 14~16으로 순수 학습 기반 모델(7~8)

50) William H. Kruskal and W. Allen Wallis, "Use of Ranks in One-Criterion Variance Analysis," *Journal of the American Statistical Association*, Vol. 47, No. 260 (1952), pp. 583~621.

과 BT-v2(4) 어느 쪽보다도 컸다(<표 4-5>). 선형 혼합형 조건의 대부분이 절단 값이었다.

<표 4-5> 선형 혼합형의 학습 예산·혼합계수별 점수와 D*

혼합계수 α	100세대	200세대	300세대
0.25	0.621 / 14.8	0.599 / 15.3	0.619 / 14.3
0.5	0.637 / 14.0	0.610 / 16.1	0.639 / 15.9
0.75	0.674 / 15.8	0.680 / 16.0	0.721 / 15.0
1.0(순수 학습 기반)	0.646 / 8.1	0.674 / 7.2	0.716 / 7.6

註: 각 칸은 학습 시드 20개의 평균 점수(상대 2중 평균) / 평균 D*이다. 두 값 모두 같은 상대에 대한 것이므로 칸끼리 직접 비교할 수 있다.

出處: 저자 작성.

감독형. 감독형은 위반율을 0.009로 낮추었지만(대부분 최소 이격 위반), 하드텍 위반을 완전히 없애지는 못했다. 20개 중 16개는 하드텍 위반이 관측되지 않았으나 4개에서 짧은 침범이 기록되었다(평균 0.0005). 그 대가로 점수는 BT-v2 상대 0.687에서 0.487로, BT-v3 상대 0.746에서 0.600으로 떨어졌고, D*는 평균 7.6에서 12.0으로 커졌다.

잔차형. 잔차형 200세대 모델의 점수는 BT-v2 상대 0.56~0.57, BT-v3 상대 0.65~0.71이었다(<표 4-6>). 출발점인 BT-v2와 비교하면 학습 상대인 BT-v2에는 조금 강해졌지만(자기 대전 0.50) 보류 상대 BT-v3에는 약해졌다(BT-v2의 0.84). 100세대에서 200세대로 가며 BT-v3 상대 점수가 평균 0.78에서 0.69로 내려간 것도 같은 현상이다. 평가 교전에서 학습이 더한 보정의 크기는 실제 지령으로 정규화 단위 0.06 안팎(뱅크각 약 11°)에 불과했지만, D*는 BT-v2의 4에서 6, 17, 6으로 커졌다. 위반율(0.057~0.070)은 BT-v2(0.100)보다 낮았다.

게이팅형. 게이팅형 200세대 모델의 점수는 BT-v2 상대 0.58~0.70, BT-v3 상대 0.76~0.82로, 같은 학습 기반 모델(시드 11)을 고정 비율 0.5로 섞은 선형 혼합형(0.56, 0.72)보다 높았고 순수 학습 기반 모델(0.72, 0.83)에 근접하였다. 그러나 200세대 세 모델의 D*는 모두 17(절단)이었다. 게이트가 섞은 두 정책은 D* 3인 학습 기반 모델과 D* 4인 BT-v2였다. 평가 교전에서 게이트 값의 평균은 시드별로 0.36, 0.59, 0.61이었고 한 교전 안의 표준편차는 0.03, 값의 90%가 평균 ± 0.05 안에 있었다. 게이트는 상황에 따라 규칙과 학습을 골라 쓰지 않고 시드마다 하나의 고정 비율을 학습한 것이다.

<표 4-6> 잔차형·게이팅형 결과와 비교 기준

조건	점수 (BT-v2 상대)	점수 (BT-v3 상대)	D*	위반율
잔차형 100세대	0.53/0.50/0.55	0.87/0.77/0.71	17/17/5	0.090/0.084/0.060
잔차형 200세대	0.57/0.56/0.57	0.71/0.65/0.71	6/17/6	0.070/0.057/0.064
게이팅형 100세대	0.54/0.65/0.59	0.75/0.80/0.77	6/17/17	0.081/0.070/0.085
게이팅형 200세대	0.58/0.67/0.70	0.76/0.81/0.82	17/17/17	0.082/0.055/0.061
(기준) BT-v2	(0.50)	0.84	4	0.100
(기준) 학습 기반 시드 11	0.72	0.83	3	0.049
(기준) 선형 혼합형 시드 11, α 0.5	0.56	0.72	17	0.073
(기준) 감독형 시드 11	0.47	0.71	17	0.008

註: 잔차형·게이팅형은 학습 시드 0 / 1 / 2의 값이다. 기준 조건은 같은 평가 실행에 포함하였으며, 점수와 D*가 본실험과 소수점 셋째 자리까지 같았다.

出處: 저자 작성.

4.7. 규칙 준수(RQ3)

안전규칙을 트리 전체에 명시한 BT-v3는 하드텍과 과하중 위반이 한 번도 관측되지 않았다(<표 4-7>). 학습 기반 모델은 적합도의 약한 벌점(위반율 $\times -3$)만으로 위반율을 BT-v2의 절반으로 낮추면서 성능은 올렸지만(학습 예산과 위반율 $p = -0.17$, $p = 0.009$), 위반이 0은 아니었다. 하드텍 위반은 20개 중 8개에서 관측되지 않았고 가장 높은 모델은 0.039(시드 14)였다. 감독형은 하드텍 위반을 평균 0.0005로 크게 줄였으나 4개 모델에서 짧은 침범이 남았다. 전체 조건에서 D*와 위반율은 양의 상관을 보였다($p = 0.29$, $p < 0.0001$). 규칙을 많이 어기는 모델일수록 규칙으로 설명하기도 어려웠다.

<표 4-7> 모델별 안전규칙 위반율

모델	하드텍	과하중	합계	하드텍 위반 미관측
BT-v2	0.049	0.044	0.100	0 / 1
BT-v3	0	0	0.008	1 / 1
BTO	0	0.049	0.057	3 / 3
학습 기반(300세대)	0.005	0.036	0.050	8 / 20
감독형	0.0005	0.0000	0.009	16 / 20

註: 적분 스텝당 위반 비율의 평균이다. 합계에는 최소 이격(150 m) 위반이 포함된다. 감독형의 과하중 위반은 소수점 넷째 자리 아래에서만 관측되었다.

出處: 저자 작성.

4.8. 통제 조건과 강건성 점검

4.8.1. 통제 조건

상수 최적화 행동트리(BTO). 같은 예산으로 상수 9개를 최적화한 BTO는 보류 상대 BT-v3에 모든 모델 가운데 가장 강했지만(0.87~0.89), BT-v2에는 졌다(0.32~0.33). D*는 3~5로 가장 간결한 축에 속했고, 하드텍 위반은 0, 격추로 끝난 교전은 45%로 BT-v2(32%)보다 많았다.

무작위 초기화 PPO. 행동복제 없이 PPO로 150만 스텝 학습한 모델은 진화전략의 초기 실패와 똑같이 원거리 회피로 수렴하였다. 교전의 98%가 시간종료였고 WEZ 체류 시간은 0초, 점수는 상대 2중 평균 0.385였다.

4.8.2. 교전 규칙과 비행역학 민감도

학습 기반 300세대 모델 20개, 행동트리 3종, BTO 3개의 26개 모델을 다시 학습하지 않고, 교전 규칙이나 비행역학 파라미터를 하나씩 바꾼 환경에서 같은 초기조건으로 재평가하였다(<표 4-8>). 바꾸지 않은 설정으로 다시 실행하면 본실험이 교전 단위까지 그대로 재현되었다.

학습 기반 모델이 BT-v2와의 직접 대결에서 앞서는 결과는 시간종료를 무승부로 처리한 규칙(평균 0.498, 20개 중 4개만 0.5 초과)을 제외한 모든 3자유도 설정에서 유지되었다. 그러나 그 폭은 제한시간 240초(0.592), 최대 양력계수 -20%(0.592), 롤 속도 상한 90°/s(0.552)에서 크게 줄었다. 보류 상대 BT-v3에 대한 점수는 모든 설정에서 BT-v2가 학습 기반 모델 평균보다 높았고, 제한시간을 240초로 늘리면 그 차이가 0.955 대 0.651로 벌어졌다. 시간이 길어지면 초반의 체력 우위로 버티는 '치고 빠지기'가 통하지 않기 때문이다. 비행역학을 바꾸었을 때 점수 순위(0.77~0.95)와 D* 순위(0.76~0.92)는 대체로 유지되었으나, 교전 규칙을 바꾸면 점수 순위는 크게 달라졌다(0.49, 0.23). 본실험 환경에서 실제 롤 속도를 재 보면 180°/s를 넘는 롤은 오히려 행동트리가 더 자주 썼으므로(적분 스텝의 4.2% 대 2.7%), 롤 속도 상한에서 학습 기반의 우위가 줄어든 것은 빠른 롤에 의존해서라기보다 학습에 쓴 역학에 맞춰진 기동이 바뀐 역학에서 덜 통했기 때문으로 보인다.

설정 안에서 26개 모델의 점수와 D*의 순위상관은 0.06~0.43으로 모두 양수였다. 최대추력을 바꾼 두 설정은 보정 전 $p < 0.05$ 였지만, 여덟 비행역학 설정에 Holm 보정을 적용하면 모두 유의하지 않았다(보정 $p \geq 0.23$). 혼합 정책이 없는 이 26개 모델에서는 4.3절의 결과와 마찬가지로 약한 양의 관계를 배제할 수 없다.

<표 4-8> 교전 규칙·비행역학을 바꾼 재평가

설정	학습 기반 vs BT-v2	학습 기반 vs BT-v3	BT-v2 vs BT-v3	점수 순위 유지	D* 순위 유지	설정 안 ρ(점수, D*)
본실험	0.687 (20)	0.746	0.843	-	-	0.22
제한시간 240초	0.592 (16)	0.651	0.955	0.49	0.77	0.20
시간종료 = 무승부	0.498 (4)	0.559	0.792	0.23	1.00	0.14
최대 양력계수 ×0.8	0.592 (17)	0.693	0.925	0.78	0.89	0.07
최대 양력계수 ×1.2	0.718 (20)	0.762	0.792	0.90	0.86	0.32
최대추력 ×0.8	0.672 (20)	0.734	0.863	0.91	0.89	0.41 ^a
최대추력 ×1.2	0.677 (20)	0.746	0.777	0.93	0.76	0.43 ^a
지령 지연 ×0.8	0.714 (20)	0.773	0.912	0.92	0.91	0.06
지령 지연 ×1.2	0.652 (20)	0.719	0.792	0.95	0.92	0.34
롤 속도 상한 180°/s	0.622 (19)	0.671	0.853	0.80	0.81	0.10
롤 속도 상한 90°/s	0.552 (17)	0.595	0.650	0.77	0.82	0.32

註: 학습 기반 점수는 300세대 모델 20개의 평균이며, 괄호 안은 0.5를 넘은 모델 수이다. 순위 유지는 본실험과 해당 설정 사이의 26개 모델 순위상관이다. a: 보정 전 $p < 0.05$, Holm 보정 후 유의하지 않음.

出處: 저자 작성.

4.8.3. 6자유도 F-16 교차검증

3자유도에서 학습한 31개 모델(4.8.2절의 26개와 선형 혼합형·감독형·잔차형·게이팅형·PPO 대표 각 1개)을 다시 학습하지 않고 JSBSim의 F-16 모델에서 평가하였다. 관측, 지령 변환, 초기조건, 교전 규칙은 3자유도와 같고 비행역학만 바뀐다. 교전 전 계단 응답 시험에서 추종 제어기는 기체가 낼 수 있는 범위 안에서 지령을 오버슈트 2% 이내로 따랐지만, F-16 모델은 비행제어계와 받음각 제한 때문에 저속 롤 속도(180 m/s에서 약 77°/s)와 가용 하중배수(180 m/s에서 4.4 G, 220 m/s에서 5.9 G)가 3자유도 모델보다 크게 낮았다. 판정 기준은 평가 전에 문서로 정해 두었고, 같은 문서에 "학습 기반 모델의 성능 우위는 6자유도에서 줄거나 사라질 것"이라는 예상도 적어 두었다(<표 4-9>).


<표 4-9> 6자유도 교차검증의 사전 판정 기준과 결과

기준	지표	사전 기준	결과	판정
점수 순위 유지	ρ (3자유도 점수, 6자유도 점수)	0.7 이상	0.12 ($p = 0.52$)	유지되지 않음
D* 순위 유지	ρ (3자유도 D*, 6자유도 D*)	0.7 이상	0.57 ($p = 0.0007$)	유지되지 않음
트레이드오프 출현	6자유도 ρ (점수, D*)의 90% 구간 하한, 3자유도 대비 증가	하한 0 초과, 증가 0.2 초과	하한 -0.67, 증가 -0.60	출현하지 않음
규칙 준수 구조	BT-v3·감독형의 하드텍 위반율	0	0, 0.0003	유지되지 않음

註: 31개 모델 $\times$ 400회 교전. 판정 기준과 판정 코드는 평가 전에 저장소에 기록하였다.

出處: 저자 작성.

결과는 네 가지다(<그림 4-3>). 첫째, 성능 순위가 크게 달라졌다. 학습 기반 모델은 BT-v2와의 직접 대결에서 평균 0.371로 20개 모두 졌고, BT-v3 상대 점수도 0.404로 BT-v2(0.787)에 크게 못 미쳤다. 학습 기반 모델이 3자유도에서 찾은 치고 빠지기는 6자유도에서 통하지 않아 교전당 주는 피해가 20.6에서 4.1로 줄고 받는 피해가 6.0에서 16.8로 늘었다. 행동트리 계열의 점수는 거의 그대로였다(행동트리 3중 평균 0.414 $\rightarrow$ 0.454, BTO 0.602 $\rightarrow$ 0.595). 둘째, 트레이드오프는 6자유도에서도 나타나지 않았다. 같은 31개 모델에서 점수와 D*의 순위상관은 3자유도 0.13(90% 구간 -0.20~0.44)에서 6자유도 -0.47($p = 0.008$, 90% 구간 -0.67~-0.20)로, 트레이드오프와 반대 방향의 유의한 음의 관계가 되었다. 셋째, D* 순위는 부분적으로만 유지되었다($p = 0.57$). 대부분 모델의 D*가 작아졌고(학습 기반 평균 7.6 $\rightarrow$ 4.1), 3자유도에서 절단값이던 6개 모델(학습 기반 시드 1·10·16, 선형 혼합형, 감독형, 게이팅형)이 2~8이 되었다. 지령의 분포(채널별 표준편차, 포화 비율)는 두 환경에서 거의 같았으므로 차이는 모델이 방문한 상황의 분포에서 온 것으로 보이나, 원인은 확인하지 못했다. 넷째, BT-v3는 하드텍 위반 0을 유지했지만 감독형은 0.0003으로 사전 기준(0)을 넘었다. 과하중 위반율은 6자유도에서 크게 늘었는데(예: BT-v3 0 $\rightarrow$ 0.39), 8 G 지령을 추종할 때 생기는 미세한 출렁임까지 위반으로 세기 때문이어서 사전에 참고 지표로만 정해 두었다.



<그림 4-3> 3자유도와 6자유도에서의 점수와 D* 비교

註: 점선은 두 환경의 값이 같은 선($y = x$)이다. 점수는 상대 2종 평균이며, (b)는 같은 값의 점이 겹치지 않도록 작게 흘뜨렸다.

出處: 저자 작성.

4.9. 가설 판정

3.6절의 판정 기준에 따른 결과는 <표 4-10>과 같다.

<표 4-10> 가설과 판정 기준에 대한 결과

가설	관측 결과	판정
H1 규칙 기반은 설명되지만 약하다	D*는 1~5로 작았다. BT-v2는 학습 기반 모델과의 직접 대결에서 졌으나, 보류 상대 BT-v3에는 모든 학습 기반 모델보다 강했고 6자유도에서는 학습 기반 모델을 모두 이겼다.	설명 쪽은 지지, 성능 쪽은 상대와 환경에 따라 달라짐
H2 학습 기반은 강하지만 설명되지 않는다	직접 대결에서는 강했으나 보류 상대와 6자유도에서는 아니었다. D* 중앙값은 6으로 규칙 기반(4~5)보다 다소 컸지만 20개 중 9개가 5 이하였고, 설명 비용은 성능이 아니라 전술에 따라 갈랐다.	부분 지지
H3 하이브리드는 설명되면서 성능은 중간이다	선형 혼합형 D* 14~16, 감독형 12(평균), 잔차형 6~17, 게이팅형 17. 어느 방식도 BT-v2보다 간결하면서 강하지 않았다.	기각
RQ4 판정 기준	잔차형은 점수가 학습 기반 모델에 못 미쳤고, 게이팅형은 점수는 학습 기반에 근접했으나 D*가 17이었다.	H3 기각이 네 결합 방식으로 확장

出處: 저자 작성.

5. 논의

5.1. 트레이드오프는 왜 강하게 나타나지 않았는가

본 연구의 첫째 결과는 "성능이 높은 공중전 인공지능일수록 설명하기 어렵다"는 강한 트레이드오프가 행동 수준에서는 관측되지 않았다는 것이다. 내재적 의미에서 "행동트리는 읽을 수 있고 신경망은 읽을 수 없다"는 여전히 참이지만, 그 차이가 행동의 설명 비용으로 그대로 이어지지는 않았다. 점수 2위인 학습 기반 모델(시드 11)은 $D^* = 3$ 으로 BT-v2(4)보다 간결했다. 가중치 1,827개로 이루어진 신경망의 조종이 if-then 규칙 3단계로 95% 재현된 것이다. 근접공중전의 좋은 조종은 "상대가 어느 쪽에 있는가, 사거리 안인가, 고도가 충분한가" 같은 몇 개의 기하학적 판단으로 상당 부분 결정되기 때문으로 보인다. 신경망은 이 판단을 복잡한 방식으로 계산하지만 그 결과인 행동은 간결하게 요약될 수 있고, 반대로 행동트리도 연속 함수로 지령을 계산하면 요약에 여러 단계가 필요하다.

다만 이 결론의 강도는 정확히 한정해야 한다. 282개 조건 전체에서 상관이 0에 가까운 데에는 혼합 정책이 "점수는 중간, D^* 는 최대"라는 한 덩어리를 이룬 영향도 있다. 혼합 정책을 뺀 79개 조건과 비행역학을 바꾼 재평가의 26개 모델에서는 p 가 0.06~0.43으로 모두 양수였고, 개별적으로는 유의하지 않았다. 따라서 본 연구가 말

할 수 있는 것은 "강한 트레이드오프는 없다"이며, 순수한 규칙 기반·학습 기반 모델 사이의 약한 양의 관계(p 0.2~0.4 수준)는 배제하지 못한다. 주 분석인 학습 시드 단위 분석과 혼합모형에서 D^* 의 효과가 없었고 6자유도에서는 오히려 음의 관계가 나타났다는 점은, 그러한 관계가 있더라도 약하며 환경에 따라 방향이 바뀔 수 있음을 보여 준다.

방법론적 교훈도 있다. 학습 시드가 3개일 때는 유의한 트레이드오프($p = 0.38$)가 관측되었으나 20개로 늘리자 사라졌다. 학습 기반 모델은 같은 설정에서도 시드마다 전혀 다른 전술을 익히므로, 적은 반복으로 성능과 설명가능성의 관계를 주장하면 우연한 결과를 일반 법칙으로 오인할 수 있다.

5.2. 설명 비용을 정한 것은 전술이다

학습량이 늘면서 성능은 꾸준히 올랐지만 자기 기록 D^* 는 복제본을 떠나는 첫 순간에 한 번 올라간 뒤 평평하였다. "복잡해진 것"과 "강해진 것"이 서로 다른 시기에 일어난 것이다. 같은 예산과 비슷한 점수에서 D^* 를 가른 것은 전술이었다. 추격 격추는 상대의 기동에 계속 반응해야 하므로 지령이 상황에 따라 잘게 나뉘고, 치고 빠지기 한 번 사격한 뒤 정해진 선회를 유지하면 되기 때문이다. 전술 군집 안에서는 성능과 D^* 의 상관성이 없었으므로, 설명 비용의 원인은 성능이 아니라 어떤 전술로 이기는가에 있다. 이는 공중전 인공지능을 평가할 때 승률 하나가 아니라 어떤 방식으로 이겼는지를 함께 보고해야 함을 뜻한다.

공통 상태 D^* 는 다른 측면을 보여 준다. 모든 모델에 같은 상황을 물으면 학습이 진행될수록 규칙에서 점점 멀어졌다. 학습 기반 모델은 자기가 실제로 가는 상황에서는 간결하게 행동하지만, 가지 않는 상황까지 물으면 점점 예측하기 어려워진다. 6자유도 재평가에서 같은 모델의 D^* 가 크게 달라진 것도 같은 맥락에서 읽을 수 있다. D^* 는 모델 하나의 고유한 값이 아니라 모델이 특정 환경에서 방문한 상황에 대한 값이다. 운용 관점에서는 평소에 겪지 않는 상황에서 인공지능이 어떻게 행동할지 예측하기 어렵다는 점이 더 중요한 경고가 될 수 있다.

5.3. 하이브리드 설계에 대한 시사점

두 모델을 섞으면 두 장점을 함께 얻는다는 기대는 네 결합 방식 모두에서 지지되지 않았다. 선형 혼합형은 두 지령이 다를 때 그 중간값을 내는데, 이 중간값은 규칙 쪽의 논리도 학습 쪽의 논리도 따르지 않는 새로운 행동이 된다. 감독형은 안전 규칙이 개입하는 순간 학습 모델의 전술을 끊었고, 잔차형의 작은 보정은 학습 상대에 맞

춘 미세 조정에 그치면서 규칙의 간결한 구조를 흐렸다. 게이팅형은 "이 상황에서는 규칙, 저 상황에서는 학습"을 가르도록 설계했지만 실제로는 시드마다 하나의 고정 비율로 수렴하여 비율을 학습한 선형 혼합형이 되었고, 설명하기 쉬운 두 정책(D* 3과 4)을 섞은 결과는 깊이 16의 트리로도 재현되지 않았다.

이 "섞으면 복잡해진다"는 관찰은 3자유도 환경에서 얻은 것이다. 6자유도 재평가에서는 하이브리드의 D*도 2~5로 작아졌다. 그러나 6자유도에서 하이브리드 네 모델은 BT-v2와의 직접 대결에서 모두 졌고(0.33~0.48) BT-v3 상대 점수도 BT-v2보다 낮아, 성능과 설명가능성을 함께 얻는 절충점은 두 환경 어디에서도 나타나지 않았다. 규칙과 학습을 합칠 때는 지령을 섞기보다, 규칙이 어떤 기동을 할지 고르고 학습은 그 기동 안의 세부 조종만 맡는 계층형 구조처럼 두 모델의 역할이 겹치지 않게 나누는 방식을 검토할 필요가 있다.

5.4. 군 운용에 주는 시사점

첫째, 설명가능성은 모델 종류로 가정하지 말고 행동으로 측정해야 한다. 유인기가 무인기를 감독하는 운용에서 조종사에게 필요한 것은 "이 인공지능이 다음에 무엇을 할지 예측할 수 있는가"이며, 이는 행동 기록으로 측정할 수 있다. 같은 구조의 신경망이라도 전술에 따라 3단계 규칙으로 설명되기도 하고 16단계로도 설명되지 않기도 했다.

둘째, 성능 평가는 평가 조건과 함께 보고해야 한다. 학습 기반 모델의 우위는 학습 상대와의 직접 대결, 120초 제한과 시간종료 체력 비교라는 규칙, 그리고 학습에 쓴 비행 모델 안에서 성립하였고, 보류 상대·다른 교전 규칙·6자유도 기체에서는 약해지거나 사라졌다. 학습 기반 모델은 주어진 규칙에서 가장 유리한 전술을 찾아내므로, 모의 평가의 조건이 실제 운용과 다르면 평가 결과가 실전 성능을 대표하지 못한다. 협동전투기의 자율 소프트웨어를 평가할 때도 훈련에 쓴 상대와 규칙 밖의 조건에서 따로 검증할 필요가 있다.

셋째, 안전 요구의 수준에 따라 구조를 골라야 한다. 안전규칙을 행동 전체에 명시한 BT-v3에서는 위반이 관측되지 않았지만, 학습 모델 위에 감독 규칙을 씌운 감독형은 위반을 크게 줄이면서도 0으로 만들지는 못했다. 감독 규칙이 개입하는 시점에 이미 회복하기 어려운 상태에 들어선 경우가 있었을 가능성이 있다. 한 번의 위반도 허용할 수 없는 규칙이라면 감독 조건의 여유와 기체의 회복 능력을 함께 검증해야 하며, 그 대가인 성능 손실과 설명 비용 증가도 함께 평가해야 한다.

넷째, 충분한 반복으로 평가해야 한다. 학습 기반 모델은 같은 조건에서도 시드마

다 전술이 달라지므로, 소수의 학습 결과로 모델 계열 전체를 판단하면 잘못된 결론에 이를 수 있다.

5.5. 연구의 한계

본 연구에는 다음의 한계가 있다. 첫째, 비행 모델의 단순화이다. 3자유도 점질량 모델은 받음각, 옆미끄럼, 실속, 무장 탄도를 모사하지 않고 롤 운동을 1차 지연으로만 근사한다. 비행역학 민감도 분석과 6자유도 재평가에서 강한 트레이드오프는 나타나지 않았지만, 6자유도에서 성능 순위는 유지되지 않았고 D* 순위도 부분적으로만 유지되었다. 따라서 성능과 개별 모델의 D* 값에 관한 결과는 3자유도 환경에 한정된다. 두 점검 모두 다시 학습하지 않은 평가이며, 6자유도에서 처음부터 학습한 모델도 같은 관계를 보이는지는 후속 연구로 남긴다.

둘째, 교전 형태와 상대가 한정되었다. 1대1 근접 기총 교전만 다루었고 가시거리 밖 교전, 다수기 교전, 미사일 교전은 다루지 않았다. 학습과 평가의 상대는 고정된 행동트리 2종이 기본이며, 전원 대전으로 보완했지만 자가 대전으로 학습한 모델은 포함하지 않았다.

셋째, 학습 기반 모델은 BT-v2의 복제본에서 출발했으므로 규칙과 무관하게 학습한 모델이 아니다. 무작위 초기화 학습(진화전략 2회, PPO)은 모두 회피로 수렴하였다. 이는 설계상의 선택이며, 그 덕분에 규칙과 같은 행동에서 출발해 갈라지는 과정을 관찰할 수 있었다.

넷째, D*는 같은 예산에서도 시드 간 표준편차가 4~5로 크고 전체 조건의 58%가 절단값(대부분 혼합 정책)이다. 이 때문에 순위 기반 통계를 쓰고 F(4), 공통 상태 D*를 함께 보고하였다. 자기 기록 D*와 공통 상태 D*의 상관이 0.27에 그친 것은 두 지표가 서로 다른 것을詹다는 뜻이며, 어느 쪽이 사람이 느끼는 설명가능성에 더 가까운지는 사람 평가로만 답할 수 있다.

다섯째, 사람 대상 평가가 없다. 사람이 모델의 다음 기동을 예측하는 이해도 실험은 설계와 문항까지 준비했으나 실시하지 못했다. D*는 기능 기반 지표이며, 사람의 실제 이해도와 관계는 검증되지 않았다. 여섯째, 잔차형과 게이팅형은 학습 시드 3개, 200세대로 본실험보다 작은 규모이고, 게이팅형은 학습 기반 모델 하나(시드 11)만 사용하였다. 일곱째, 규칙 기반 모델과 학습 기반 모델에 들인 개발 노력이 같다고 보장할 수 없으므로 절대적인 성능 순위는 일반화하지 않는다. 본 연구의 주장은 순위가 아니라 성능과 설명가능성 사이 관계의 형태에 있다.

6. 결론

본 연구는 1대1 근접 기총 공중전 모의 환경에서 규칙 기반 행동트리, 진화전략으로 학습한 신경망, 두 모델을 네 가지 방식으로 결합한 하이브리드를 같은 관측, 같은 지령, 같은 상대, 같은 지표로 비교하여 "성능이 높은 공중전 인공지능일수록 설명하기 어렵다"는 통념을 측정하였다. 설명가능성은 모델의 조종 기록을 95% 재현하는 결정트리의 최소 깊이(D^*)로 정의하였고, 학습 시드 20개, 282개 조건, 112,800 회 교전에 통제 조건과 강건성 점검을 더하였다. 결론은 다섯 가지다.

첫째, 성능과 설명가능성 사이에 강한 트레이드오프는 관측되지 않았다. 전체 순위 상관은 -0.02 였고 학습 시드 단위 분석과 혼합모형에서도 D^* 의 효과가 없었으며, 6자유도 재평가에서는 반대 방향의 관계가 나타났다. 다만 혼합 정책을 제외한 순수 모델 사이에서는 약한 양의 관계를 배제할 수 없다. 둘째, 학습 기반 모델은 학습 상대와의 직접 대결에서 규칙 기반 최강 모델을 이겼고 학습할수록 안전규칙도 더 잘 지켰지만, 보류 상대에 대해서는 규칙 기반 모델보다 약했고 우위는 교전 규칙과 비행역학에 의존하여 6자유도 F-16 재평가에서는 사라졌다. 셋째, 설명 비용을 가른 것은 모델 종류나 성능이 아니라 전술이었다. 같은 예산의 모델들이 '치고 빠지기'(D^* 중앙값 5)와 '추격 격추'(D^* 8~17)로 갈렸고, 전술 군집 안에서는 성능과 D^* 의 관계가 없었다. 넷째, 네 결합 방식의 하이브리드는 모두 성능과 설명가능성의 절충점이 되지 못했다. 다섯째, 안전규칙을 행동 전체에 명시한 규칙 기반 모델에서는 위반이 관측되지 않았지만, 학습 모델 위에 감독 규칙을 씌운 방식과 별점으로 학습한 모델은 위반을 크게 줄였을 뿐 0으로 만들지는 못했다.

처음 세운 가설로 돌아가면, H1은 설명 쪽만 지지되었고 성능 열세는 상대와 환경에 따라 뒤집혔다. H2는 부분적으로만 지지되었으며, H3은 네 결합 방식 모두에서 기각되었다. 이 결과는 공중전 인공지능을 도입할 때 설명가능성을 모델 종류로 가정하지 말고 실제 행동으로 측정해야 하며, 성능은 평가 조건과 함께 보고해야 함을 시사한다. 후속 연구로는 사람이 모델의 다음 기동을 예측하는 이해도 실험으로 D^* 와 사람 이해도의 관계를 검증하는 것, 6자유도 비행 모델에서 학습하고 미사일 교전과 다수기 교전으로 환경을 넓히는 것, 자가 대전으로 학습한 모델을 포함하는 것, 그리고 규칙과 학습의 역할을 겹치지 않게 나누는 계층형 하이브리드를 실험하는 것을 제안한다.

- 참 고 문 헌 -

- 배정호·강윤성·윤석민·김용덕·김성호. 2021. “커리큘럼 러닝을 이용한 항공기 강화학습.” 『정보과학회 논문지』, 제48권 제6호, pp. 707~712.
- 이민석·오지현·김천영·배정호·김용덕·지철규. 2022. “공대공 전투 모의를 위한 규칙기반 AI 교전 모델 개발.” 『한국군사과학기술학회지』, 제25권 제6호, pp. 637~647.
- 황인수·배정호. 2023. “커리큘럼을 이용한 투서클 기반 항공기 헤드온 공중 교전 강화학습 기법 연구.” 『한국군사과학기술학회지』, 제26권 제4호, pp. 352~360.
- 『스마트비즈』. 2026년 6월 9일. “KF-21 옆에 무인기 세운 KAI, 유·무인 공중전 체계로 답했다.” <https://www.smartbizn.com/news/articleView.html?idxno=145816> (검색일: 2026년 9월 28일)
- Alshiekh, Mohammed et al. 2018. “Safe Reinforcement Learning via Shielding.” *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32, No. 1.
- Army Recognition. 2026. “General Atomics YFQ-42A Collaborative Combat Aircraft Completes First Semi-Autonomous Mission.” (February 17).
<https://www.armyrecognition.com/news/aerospace-news/2026/general-atomics-yfq-42a-collaborative-combat-aircraft-completes-first-semi-autonomous-mission> (검색일: 2026년 9월 28일)
- Bastani, Osbert, Yewen Pu and Armando Solar-Lezama. 2018. “Verifiable Reinforcement Learning via Policy Extraction,” in Samy Bengio et al. (eds.), *Advances in Neural Information Processing Systems 31*, pp. 2494~2504. Red Hook, NY: Curran Associates.
- Berndt, Jon. 2004. “JSBSim: An Open Source Flight Dynamics Model in C++,” in *AIAA Modeling and Simulation Technologies Conference and Exhibit*, AIAA Paper 2004-4923. Providence, RI: AIAA.
- Burgin, George H. and Laurent B. Sidor. 1988. *Rule-Based Air Combat Simulation*. NASA Contractor Report 4160. Washington, D.C.: NASA Scientific and Technical Information Division (September).
- Colledanchise, Michele and Petter Ögren. 2018. *Behavior Trees in Robotics and AI: An Introduction*. Boca Raton: CRC Press.
- Craven, Mark W. and Jude W. Shavlik. 1996. “Extracting Tree-Structured Representations of Trained Networks,” in David S. Touretzky, Michael C. Mozer and Michael E. Hasselmo (eds.), *Advances in Neural Information Processing Systems 8*, pp. 24~30. Cambridge, MA: MIT Press.
- DARPA. n.d. “Air Combat Evolution (ACE).”
<https://www.darpa.mil/research/programs/air-combat-evolution> (검색일: 2026년 9월 30일)
- DARPA. 2024. “ACE Program Achieves World First for AI in Aerospace.” (April 17).
<https://www.darpa.mil/news/2024/ace-ai-aerospace> (검색일: 2026년 9월 30일)
- Doshi-Velez, Finale and Been Kim. 2017. “Towards A Rigorous Science of Interpretable Machine Learning.” arXiv:1702.08608.
- Efron, Bradley. 1979. “Bootstrap Methods: Another Look at the Jackknife.” *The Annals of Statistics*, Vol. 7, No. 1, pp. 1~26.
- Gunning, David and David W. Aha. 2019. “DARPA’s Explainable Artificial Intelligence (XAI)

- Program." *AI Magazine*, Vol. 40, No. 2, pp. 44~58.
- Holm, Sture. 1979. "A Simple Sequentially Rejective Multiple Test Procedure." *Scandinavian Journal of Statistics*, Vol. 6, No. 2, pp. 65~70.
- Jacobs, Robert A., Michael I. Jordan, Steven J. Nowlan and Geoffrey E. Hinton. 1991. "Adaptive Mixtures of Local Experts." *Neural Computation*, Vol. 3, No. 1, pp. 79~87.
- Johannink, Tobias et al. 2019. "Residual Reinforcement Learning for Robot Control," in *2019 International Conference on Robotics and Automation (ICRA)*, pp. 6023~6029. Piscataway, NJ: IEEE.
- Juozapaitis, Zoe, Anurag Koul, Alan Fern, Martin Erwig and Finale Doshi-Velez. 2019. "Explainable Reinforcement Learning via Reward Decomposition," in *Proceedings of the IJCAI 2019 Workshop on Explainable Artificial Intelligence*.
- Kong, Weiren, Deyun Zhou, Zhen Yang, Yiyang Zhao and Kai Zhang. 2020. "UAV Autonomous Aerial Combat Maneuver Strategy Generation with Observation Error Based on State-Adversarial Deep Deterministic Policy Gradient and Inverse Reinforcement Learning." *Electronics*, Vol. 9, No. 7, 1121.
- Kruskal, William H. and W. Allen Wallis. 1952. "Use of Ranks in One-Criterion Variance Analysis." *Journal of the American Statistical Association*, Vol. 47, No. 260, pp. 583~621.
- Lundberg, Scott M. and Su-In Lee. 2017. "A Unified Approach to Interpreting Model Predictions," in Isabelle Guyon et al. (eds.), *Advances in Neural Information Processing Systems 30*, pp. 4765~4774. Red Hook, NY: Curran Associates.
- McGrew, James S., Jonathan P. How, Brian Williams and Nicholas Roy. 2010. "Air-Combat Strategy Using Approximate Dynamic Programming." *Journal of Guidance, Control, and Dynamics*, Vol. 33, No. 5, pp. 1641~1654.
- Ng, Andrew Y., Daishi Harada and Stuart Russell. 1999. "Policy Invariance under Reward Transformations: Theory and Application to Reward Shaping," in *Proceedings of the Sixteenth International Conference on Machine Learning*, pp. 278~287. San Francisco: Morgan Kaufmann.
- Park, Hyunju, Byung-Yoon Lee, Min-Jea Tahk and Dong-Wan Yoo. 2016. "Differential Game Based Air Combat Maneuver Generation Using Scoring Function Matrix." *International Journal of Aeronautical and Space Sciences*, Vol. 17, No. 2, pp. 204~213.
- Pope, Adrian P. et al. 2021. "Hierarchical Reinforcement Learning for Air-to-Air Combat," in *2021 International Conference on Unmanned Aircraft Systems (ICUAS)*, pp. 275~284. Piscataway, NJ: IEEE.
- Ribeiro, Marco Tulio, Sameer Singh and Carlos Guestrin. 2016. "Why Should I Trust You?": Explaining the Predictions of Any Classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135~1144. New York: ACM.
- Rudin, Cynthia. 2019. "Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead." *Nature Machine Intelligence*, Vol. 1, No. 5, pp. 206~215.
- Saldiran, Emre, Mehmet Hasanzade, Gokhan Inalhan and Antonios Tsourdos. 2024. "Towards Global Explainability of Artificial Intelligence Agent Tactics in Close Air Combat." *Aerospace*, Vol. 11, No. 6, 415.
- Salimans, Tim, Jonathan Ho, Xi Chen, Szymon Sidor and Ilya Sutskever. 2017. "Evolution

- Strategies as a Scalable Alternative to Reinforcement Learning.” arXiv:1703.03864.
- Schuirman, Donald J. 1987. “A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability.” *Journal of Pharmacokinetics and Biopharmaceutics*, Vol. 15, No. 6, pp. 657~680.
- Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov. 2017. “Proximal Policy Optimization Algorithms.” arXiv:1707.06347.
- Schwarz, Gideon. 1978. “Estimating the Dimension of a Model.” *The Annals of Statistics*, Vol. 6, No. 2, pp. 461~464.
- Shaw, Robert L. 1985. *Fighter Combat: Tactics and Maneuvering*. Annapolis: Naval Institute Press.
- Wilcoxon, Frank. 1945. “Individual Comparisons by Ranking Methods.” *Biometrics Bulletin*, Vol. 1, No. 6, pp. 80~83.
- Wilson, Edwin B. 1927. “Probable Inference, the Law of Succession, and Statistical Inference.” *Journal of the American Statistical Association*, Vol. 22, No. 158, pp. 209~212.
- Yang, Qiming, Jiandong Zhang, Guoqing Shi, Jinwen Hu and Yong Wu. 2020. “Maneuver Decision of UAV in Short-Range Air Combat Based on Deep Reinforcement Learning.” *IEEE Access*, Vol. 8, pp. 363~378.

Explainability-Performance Trade-off in Combat AI: A Comparison of Rule-based, Learning-based, and Hybrid Models in a Simulated 1v1 Dogfight

Cadet 4th Class Park Yoonjoon

Cadet 4th Class Son Hyeongrae

Cadet 4th Class Lee Sungjae

Cadet 4th Class Lee Junseo

Cadet 4th Class Trinh Vu Tuan Dat

– Abstract –

This study tests the common belief that better-performing air-combat AI is harder to explain, using a one-on-one within-visual-range gun engagement simulator. Hand-written behavior trees, neural policies fine-tuned by evolution strategies, and hybrids that combine the two in four ways (fixed blending, rule-based supervision, residual correction, and learned gating) were compared under identical observations, commands, and opponents. Explainability was measured at the behavior level as the minimum depth of a decision tree that reproduces a policy's commands with 95% fidelity (D^*). Across 282 conditions and 112,800 engagements, no strong performance-explainability trade-off was observed (Spearman $\rho = -0.02$), although a weak positive relation could not be ruled out among non-hybrid policies. The cost of explanation was driven by tactics rather than by model family or performance. Learned policies beat the best behavior tree head-to-head, but the advantage weakened or vanished against a held-out opponent, under altered engagement rules, and in a six-degree-of-freedom F-16 re-evaluation. None of the four hybrid designs produced a favorable compromise. The results suggest that the explainability of air-combat AI should be measured from behavior rather than assumed from model type, and that performance should be reported together with the evaluation conditions.

Keywords : Air-Combat AI, Explainable AI, Behavior Tree, Hybrid Model, Surrogate Model

보안성 검토에 대한 저자 의견서

논문 저자	소속	생도대	계급	00기 생도 (0학년)	성명	김공군
논문 제목	공중전 인공지능 모델의 설명가능성과 전투성능 트레이드오프 분석					
저자 의견 1. 항공우주연구소 주관 '26년 공사 생도 안보 논문경진대회 참가를 위해 작성된 논문임. 2. 위 논문은 공개 제원 기반 모의실험으로 공중전 인공지능 모델의 설명가능성과 전투성능의 관계에 연구하는 내용으로, 보안 위규 사항을 포함하고 있지 않으며, 군 내부 기밀 유출 등 보안에 저촉한 사례가 없음을 확인함. 년 월 일 계급 성명 (서명)						

논문 유사도 검사 결과서

논문 제목 : 공중전 인공지능 모델의 설명가능성과 전투성능 트레이드
오프 분석

(Explainability-Performance Trade-off in Combat AI: A
Comparison of Rule-based, Learning-based, and Hybrid
Models in a Simulated 1v1 Dogfight)

KCI 논문 유사도 검사* 결과 붙임

- <https://check.kci.go.kr> (KCI 문헌 유사도 검사 서비스) 활용

* KCI 논문유사도 검사시스템은 국민 누구나 무료로 이용 가능한 시스템으로써
이용자가 업로드하는 문헌과 KCI에 등록되어 있는 약200만여건의 KCI 및 국내
학술대회 논문을 비교하여 유사도 검사결과를 보여주는 시스템입니다.

20 년 월 일

계급

성명

(서명)