

공중전 인공지능의 성능-설명가능성 트레이드오프 검증 *

- 규칙 기반 · 학습 기반 · 하이브리드 모델의 행동 수준 비교를 중
심으로 -

(Testing the Performance-Explainability Trade-off in
Air-Combat AI: A Behavior-Level Comparison of Rule-based,
Learning-based, and Hybrid Models)

4학년 생도 박 윤 준**

(Cadet 4th Class Park Yoonjoon)

4학년 생도 손 형 래***

(Cadet 4th Class Son Hyeongrae)

4학년 생도 이 성 재****

(Cadet 4th Class Lee Sungjae)

4학년 생도 이 준 서*****

(Cadet 4th Class Lee Junseo)

4학년 생도 뚜 언 닷*

(Cadet 4th Class Trinh Vu Tuan Dat)

* 본 논문은 한국해양연구소 기부로 시작된 2026년 공군사관학교 안보 논문경진대회를 위하여 제출된 논문임.

** Corresponding Author: 박윤준(Park Yoonjoon)

공군사관학교 생도대 6중대 컴퓨터과학과

E-mail: a7513714@afa.ac.kr

Tel: 043-000-0000

*** 공군사관학교 생도대 4중대 컴퓨터과학과

E-mail: a7513738@afa.ac.kr

Tel: 043-290-0000

**** 공군사관학교 생도대 2중대 컴퓨터과학과

E-mail: a7513771@afa.ac.kr

Tel: 043-290-0000

***** 공군사관학교 생도대 4중대 컴퓨터과학과

E-mail: a7513786@afa.ac.kr

Tel: 043-290-0000

* 공군사관학교 생도대 8중대 컴퓨터과학과

E-mail: a7513853@afa.ac.kr

Tel: 043-290-0000

- 요약 문 -

공중전 인공지능은 성능이 높을수록 판단 근거를 설명하기 어렵다는 통념이 있다. 본 연구는 이 성능-설명가능성 트레이드오프가 실제로 존재하는지를 1대1 근접 기층 공중전 모의실험에서 검증하였다. 규칙 기반 행동트리, 진화전략으로 학습한 신경망, 두 모델을 네 가지 방식으로 결합한 하이브리드를 같은 관측·지령·상대로 비교하고, 설명가능성은 모델의 조종 기록을 재현하는 결정트리의 최소 깊이로 측정하였다. 트레이드오프는 두 방법으로 검증하였다. 하나는 성능이 높은 모델일수록 설명 비용이 큰지를 보는 연관성 검정이고, 다른 하나는 설명 비용에 상한을 두었을 때 잃는 성능을 재는 제약 비용 분석이다. 282개 조건, 112,800회 교전의 결과, 성능과 설명 비용 사이에 강한 연관은 없었다($p = -0.02$). 설명 비용을 깊이 2 이하로 묶으면 성능 손실이 컸지만 깊이 5~6을 허용하면 손실은 대부분 사라졌다. 같은 학습 예산의 모델 사이에서 설명 비용을 가른 것은 성능이 아니라 전술이었으며, 네 결합 방식의 하이브리드는 어느 것도 절충점이 되지 못했다. 학습 기반 모델의 성능 우위는 학습 상대와의 대결에서만 뚜렷했고 보류 상대, 다른 교전 규칙, 6자유도 F-16 재평가에서는 약해지거나 사라졌다.

주제어 : 공중전 인공지능, 설명가능 인공지능, 트레이드오프, 행동트리, 대리모델

1. 서론

1.1. 연구 배경

2026년 2월 미 공군의 협동전투기(CCA: Collaborative Combat Aircraft) 시제기 YFQ-42A는 자율비행 소프트웨어를 탑재한 채 지상 운용자의 감독 아래 4시간이 넘는 반자율 임무비행을 수행하였다.¹⁾ 국내에서도 같은 해 6월 한국항공우주산업(KAI: Korea Aerospace Industries)이 KF-21과 협업 무인기를 연동한 유·무인 복합 공중전 체계를 공개하며, 유인 전투기가 후방에서 작전을 지휘하고 무인기가 전방의 위험 임무를 맡는 운용 개념을 제시하였다.²⁾ 2020년 미 국방고등연구계획국(DARPA: Defense Advanced Research Projects Agency)의 알파독파이트 트라이얼(AlphaDogfight Trials)에서 강화학습 기반 인공지능(AI: Artificial Intelligence)이 숙련 조종사를 이긴 지³⁾ 6년 만에, AI 조종은 시험 단계를 넘어 전력화 단계에 들어서고 있다.

유인기가 무인기를 지휘한다는 개념에는 지휘하는 조종사가 무인기의 AI가 왜 그렇게 기동했는지를 이해하고 감독할 수 있어야 한다는 전제가 깔려 있다. YFQ-42A 시험에서 비행 안전 기능과 상위 임무 자율 논리를 분리한 "감독된 자율(supervised autonomy)"이 강조된 것도 같은 맥락이다.⁴⁾ 판단 근거를 확인할 수 없는 모델은 성능이 높더라도 교전 권한을 위임받기 어렵다.

1.2. 문제 제기와 연구 목적

AI의 설명가능성을 논할 때 흔히 전제되는 것이 성능과 설명가능성의 트레이드오프이다. 사람이 규칙을 직접 작성한 행동트리(BT: Behavior Tree) 같은 규칙 기반 모델은 판단 근거를 그대로 읽을 수 있지만 설계자가 미리 떠올린 상황만 다루므로 성능이 낮고, 수만 번의 모의 교전으로 스스로 익힌 신경망 기반의 학습 모델은 성능

1) "General Atomics YFQ-42A Collaborative Combat Aircraft Completes First Semi-Autonomous Mission," *Army Recognition*, February 17, 2026. <https://www.armyrecognition.com/news/aerospace-news/2026/general-atomics-yfq-42a-collaborative-combat-aircraft-completes-first-semi-autonomous-mission> (검색일: 2026년 9월 28일)

2) "KF-21 옆에 무인기 세운 KAI, 유·무인 공중전 체계로 답했다," 『스마트비즈니스』, 2026년 6월 9일. <https://www.smartbizn.com/news/articleView.html?idxno=145816> (검색일: 2026년 9월 28일)

3) Adrian P. Pope et al., "Hierarchical Reinforcement Learning for Air-to-Air Combat," in *2021 International Conference on Unmanned Aircraft Systems (ICUAS)* (Piscataway, NJ: IEEE, 2021), pp. 275~284.

4) "General Atomics YFQ-42A Collaborative Combat Aircraft Completes First Semi-Autonomous Mission," 2026.

이 높지만 판단이 수천 개의 가중치에 흩어져 있어 설명할 수 없다는 것이다. 이 관점에서는 규칙이 판단의 뼈대를 잡고 학습이 부족한 부분을 보완하는 하이브리드 모델이 두 장점을 절충하는 해법으로 기대된다. 미 국방고등연구계획국의 설명가능 AI 사업도 학습 기법들의 성능과 설명가능성이 반비례하는 개념도에서 출발하였다.⁵⁾ 그러나 이 트레이드오프가 항상 존재하는 것은 아니라는 반론도 꾸준히 제기되어 왔다.⁶⁾

공중전 AI에서 이 트레이드오프를 검증하려 하면 두 가지 어려움이 있다. 첫째는 설명가능성을 무엇으로 재느냐이다. 설명가능성을 "모델 내부를 사람이 읽을 수 있는가"로 정의하면 행동트리는 정의상 설명 가능하고 신경망은 정의상 설명 불가능하므로, 설명가능성은 측정값이 아니라 모델 종류에 붙은 이름표가 된다. 이렇게 되면 "규칙 기반 모델보다 학습 모델이 강하다"는 성능 비교 결과가 곧바로 트레이드오프의 증거로 읽히고, 하이브리드가 얼마나 설명 가능한지는 쟁 방법이 없다. 둘째는 트레이드오프를 어떤 결과로 판정하느냐이다. 몇 개 모델의 점수와 설명가능성을 나란히 놓는 것만으로는 그 관계가 우연인지, 특정 상대나 교전 규칙에서만 나타나는지 알 수 없다.

본 연구는 이 두 어려움을 다음과 같이 다룬다. 설명가능성은 모델이 실제로 수행한 조종을 몇 단계의 if-then 규칙으로 재현할 수 있는가, 즉 행동 재현의 간결성으로 측정한다. 모델 내부가 아니라 행동 기록만으로 계산하므로 세 계열에 똑같이 적용할 수 있다. 트레이드오프는 성능이 높은 모델일수록 설명 비용이 큰지를 보는 연관성 검정과, 설명 비용에 상한을 두었을 때 잃는 성능을 재는 제약 비용 분석의 두 방법으로 판정하고, 성능은 학습 상대, 학습에 쓰지 않은 상대, 모델 전원 대전의 세 가지로 따로 정의하여 결론이 성능의 정의에 좌우되는지를 확인한다.

이에 따라 본 연구의 목적은 1대1 근접공중전(WVR: Within Visual Range) 모의 환경에서 규칙 기반·학습 기반·하이브리드 모델의 성능과 행동 수준 설명가능성을 같은 잣대로 측정하여, 성능-설명가능성 트레이드오프가 존재하는지를 검증하고 설명 비용을 결정하는 요인을 밝히는 것이다. 연구 질문(RQ: Research Question)은 세 가지이다. RQ1은 성능이 높은 모델일수록 행동을 재현하는 데 더 복잡한 규칙이 필요한가이다. RQ2는 모델 사이의 설명 비용 차이가 무엇으로 결정되는가, 곧 모델 계열

5) David Gunning and David W. Aha, "DARPA's Explainable Artificial Intelligence (XAI) Program," *AI Magazine*, Vol. 40, No. 2 (Summer 2019), pp. 44~58.

6) Cynthia Rudin, "Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead," *Nature Machine Intelligence*, Vol. 1, No. 5 (May 2019), pp. 206~215.

과 성능으로 정해지는가 아니면 다른 요인이 있는가이다. RQ3은 규칙과 학습을 결합한 하이브리드가 트레이드오프를 완화하는 절충점이 될 수 있는가이다.

1.3. 연구 범위와 구성

연구 범위는 F-16급 3자유도 점질량 모델을 사용한 1대1 근접 기총 교전이다. 학습 모델은 진화전략으로 학습한 다층 퍼셉트론이며, 비교 결과가 이 환경의 산물인지를 점검하기 위해 교전 규칙과 비행역학을 바꾼 재평가와 6자유도 F-16 모델에서의 교차 평가를 더하였다. 설명가능성은 사람 실험 없이 모델의 성질로 재는 기능 기반 지표로 측정하였으며, 사람이 그 규칙을 실제로 이해하는지는 다루지 않았다.

2장에서는 공중전 AI, 설명가능성의 측정, 트레이드오프의 검증 방법, 하이브리드 제어에 관한 선행연구를 검토한다. 3장에서는 모의 환경, 비교 모델, 측정 지표와 트레이드오프 검증 방법을 기술하고, 4장에서 결과를 제시한다. 5장에서 결과의 의미와 한계를 논의하고 6장에서 결론을 맺는다.

2. 이론적 배경 및 선행연구

2.1. 공중전 인공지능 연구

공중전 AI는 교범의 기본전투기동을 "조건이면 행동" 형태의 규칙으로 옮긴 모델에서 출발하였다. 미 항공우주국(NASA)의 적응형 기동 논리(AML: Adaptive Maneuvering Logic)는 지면 회피를 최우선으로 두고 상대를 향한 기수 지향과 리드·래그 추격을 차례로 판단하는 결정 계층을 갖추었으나,⁷⁾ 사람이 몇 번의 모의비행만으로 다음 기동을 예측할 수 있다는 비판을 받아 일부 기동을 난수로 고르도록 바뀌었다.⁸⁾ 국내에서도 행동트리와 퍼지 기반 상황 판단을 결합한 규칙 기반 교전 모델이 개발되었는데, 행동트리가 고른 전술 행위를 교전 중 화면에 보여 주어 판단 과정을 검증할 수 있다는 점을 기계학습 모델과 구별되는 장점으로 내세웠다.⁹⁾ 이 연구에서도 교전이 반복될수록 조종사가 AI의 기동에 적응하는 모습이 관찰되었다.¹⁰⁾ 30여 년의 간격을 둔 두 연구는 규칙 기반 모델의 투명성이 아군의 검증을 쉽게 하는

7) George H. Burgin and Laurent B. Sidor, *Rule-Based Air Combat Simulation*, NASA Contractor Report 4160 (Washington, D.C.: NASA Scientific and Technical Information Division, September 1988), pp. i, 3-4-3-5. <https://ntrs.nasa.gov/citations/19890018022> (검색일: 2026년 9월 30일)

8) Burgin and Sidor, 1988, pp. viii, 6-1-6-2.

9) 이민석·오지현·김천영·배정호·김용덕·지철규, “공대공 전투 모의를 위한 규칙기반 AI 교전 모델 개발,” 『한국군사과학기술학회지』, 제25권 제6호 (2022), pp. 639, 645.

10) 이민석 외, 2022, p. 644.

동시에 상대의 예측도 쉽게 만든다는 같은 현상을 보고한다.

기동 전략을 계산으로 찾으려는 시도는 군사 동적계획법을 거쳐¹¹⁾ 강화학습으로 이어졌다. 알파독파이트 트라이얼에서 계층형 강화학습 에이전트는 8개 팀 중 2위를 기록하며 미 공군 F-16 무기교관과정 수료 조종사를 이겼다.¹²⁾ 국내 연구는 주로 학습이 이루어지게 만드는 방법에 집중하여, 조준각 기반 커리큘럼으로 넓은 초기 상황에서 학습을 완료하거나¹³⁾ 투서클 기반 커리큘럼으로 규칙 기반 상대에게 거의 100%의 승률을 얻었다.¹⁴⁾ 후자에서 규칙 기반 모델은 학습 에이전트의 "성능 비교의 이정표"로 쓰였다.¹⁵⁾ 미 국방고등연구계획국의 공중전 진화(ACE: Air Combat Evolution) 사업은 2023년 AI가 조종하는 X-62A와 유인 F-16의 실제 가시거리 내 교전 시험을 수행하였고,¹⁶⁾ 전투 자율성에 대한 인간의 신뢰를 측정하고 보정하는 방법을 사업 목표로 명시하였다.¹⁷⁾

공중전 강화학습 에이전트의 설명가능성을 직접 다룬 연구로는 살디란(Emre Saldiran) 등의 연구가 있다. 이들은 보상 분해를 이용해 심층 Q-네트워크 에이전트가 어떤 보상을 중시했는지를 전술 영역별로 제시하였고, 결정트리로 정책을 단순화하는 방법은 성능을 맞추려고 트리를 깊게 하면 설명가능성의 이점이 사라진다는 이유로 배제하였다.¹⁸⁾ 그러나 트리를 얼마나 깊게 해야 하는지는 측정되지 않았다. 정리하면 공중전 AI는 승률과 타격량 같은 성능 지표로 평가되어 왔고, 설명은 규칙 모델 내부의 가시화나 특정 학습 구조에서만 쓸 수 있는 보상 분해로 제공되었다. 서로 다른 계열의 행동을 하나의 척도로 재고 그것을 성능과 나란히 놓은 연구는 확인되지 않는다.

11) James S. McGrew, Jonathan P. How, Brian Williams and Nicholas Roy, "Air-Combat Strategy Using Approximate Dynamic Programming," *Journal of Guidance, Control, and Dynamics*, Vol. 33, No. 5 (2010), pp. 1641~1654.

12) Pope et al., 2021.

13) 배정호·강운성·윤석민·김용덕·김성호, "커리큘럼 러닝을 이용한 항공기 강화학습," 『정보과학회논문지』, 제48권 제6호 (2021), pp. 707~712.

14) 황인수·배정호, "커리큘럼을 이용한 투서클 기반 항공기 헤드온 공중 교전 강화학습 기법 연구," 『한국군사과학기술학회지』, 제26권 제4호 (2023), p. 359.

15) 황인수·배정호, 2023, p. 356.

16) DARPA, "ACE Program Achieves World First for AI in Aerospace," April 17, 2024. <https://www.darpa.mil/news/2024/ace-ai-aerospace> (검색일: 2026년 9월 30일)

17) DARPA, "Air Combat Evolution (ACE)." <https://www.darpa.mil/research/programs/air-combat-evolution> (검색일: 2026년 9월 30일)

18) Emre Saldiran, Mehmet Hasanzade, Gokhan Inalhan and Antonios Tsourdos, "Towards Global Explainability of Artificial Intelligence Agent Tactics in Close Air Combat," *Aerospace*, Vol. 11, No. 6 (2024), 415, p. 3.

2.2. 설명가능성의 측정: 내재적 설명과 행동 수준 설명

설명가능 AI(XAI: Explainable Artificial Intelligence)의 방법은 결정트리나 규칙 목록처럼 구조 자체를 읽을 수 있는 모델을 처음부터 쓰는 내재적(intrinsic) 방법과, 이미 학습된 모델의 판단을 사후에 풀어내는 사후(post-hoc) 방법으로 나뉜다. 도시-벨레스(Finale Doshi-Velez)와 김(Been Kim)은 설명가능성의 평가를 실제 임무에서 사람과 함께 검증하는 응용 기반 평가, 단순화한 과제로 사람을 실험하는 사람 기반 평가, 사람 없이 모델의 성질로 재는 기능 기반 평가로 구분하였다.¹⁹⁾ 사후 방법 가운데 LIME과 SHAP은 모델 종류를 가리지 않고 개별 판단에 대한 입력의 기여도를 계산하며,²⁰⁾²¹⁾ 강화학습에서는 보상을 의미 있는 성분으로 나누어 에이전트의 선호를 보여주는 보상 분해가 제안되었다.²²⁾

그러나 이 기법들은 서로 다른 계열의 모델 가운데 어느 쪽의 행동이 더 간결하게 설명되는지를 비교하는 데는 맞지 않는다. LIME과 SHAP은 판단 하나하나에 대한 국소적 기여도를 주므로 모델 전체의 행동이 얼마나 단순한지를 하나의 수치로 나타내기 어렵고, 보상 분해는 가치 함수를 학습하는 에이전트에만 적용되어 행동트리나 진화전략으로 학습한 정책에는 쓸 수 없다. 이 공백을 메울 수 있는 방법이 대리모델(surrogate model)이다. 원 모델의 입력과 출력을 훑내 내는 결정트리를 따로 적합시키고 그 트리가 원 모델을 얼마나 충실하게 재현하는지를 보는 방식으로, 신경망에서 트리 구조를 추출하려는 연구에서 시작되었다.²³⁾ 바스타니(Osbert Bastani) 등은 이를 강화학습 정책에 적용해 신경망 정책을 결정트리 정책으로 추출하는 VIPER를 제안하였으나,²⁴⁾ 그 목적은 추출한 트리를 신경망 대신 사용하며 안전성을 검증하는

19) Finale Doshi-Velez and Been Kim, "Towards A Rigorous Science of Interpretable Machine Learning," arXiv:1702.08608 (2017). <https://arxiv.org/abs/1702.08608> (검색일: 2026년 9월 28일)

20) Marco Tulio Ribeiro, Sameer Singh and Carlos Guestrin, "Why Should I Trust You?: Explaining the Predictions of Any Classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (New York: ACM, 2016), pp. 1135~1144.

21) Scott M. Lundberg and Su-In Lee, "A Unified Approach to Interpreting Model Predictions," in Isabelle Guyon et al. (eds.), *Advances in Neural Information Processing Systems 30* (Red Hook, NY: Curran Associates, 2017), pp. 4765~4774.

22) Zoe Juozapaitis, Anurag Koul, Alan Fern, Martin Erwig and Finale Doshi-Velez, "Explainable Reinforcement Learning via Reward Decomposition," in *Proceedings of the IJCAI 2019 Workshop on Explainable Artificial Intelligence* (2019).

23) Mark W. Craven and Jude W. Shavlik, "Extracting Tree-Structured Representations of Trained Networks," in David S. Touretzky, Michael C. Mozer and Michael E. Hasselmo (eds.), *Advances in Neural Information Processing Systems 8* (Cambridge, MA: MIT Press, 1996), pp. 24~30.

24) Osbert Bastani, Yewen Pu and Armando Solar-Lezama, "Verifiable Reinforcement Learning via

데 있었고 서로 다른 계열의 설명가능성을 비교하지는 않았다.

본 연구는 이 발상을 측정 도구로 바꾼다. 각 모델의 행동 기록에 깊이를 늘려 가며 결정트리를 적합시키고, 원 행동을 목표 수준 이상으로 재현하는 데 필요한 최소 깊이를 그 모델의 설명 비용으로 삼는다. 이 지표는 모델 내부와 무관하게 행동 기록만으로 계산되므로 행동트리, 신경망, 하이브리드에 똑같이 적용된다. 그 대신 내재적 설명가능성과는 다른 것을 잴다. 내부를 그대로 읽을 수 있는 규칙 모델이라도 실제 기동이 복잡하면 깊은 트리가 필요하고, 내부를 읽을 수 없는 신경망이라도 실제 기동이 단순하면 얕은 트리로 재현된다. 또한 이 지표는 기능 기반 평가에 해당하므로 사람이 그 규칙을 실제로 이해하는지는 말해 주지 않는다. 본 연구가 이 지표를 설명 가능성 자체가 아니라 "행동 재현 간결성"으로 한정해 부르는 이유이다.

2.3. 트레이드오프의 정의와 검증 방법

"성능이 높은 모델일수록 설명하기 어렵다"는 명제는 설명가능 AI 논의의 출발점처럼 여겨져 왔다. 미 국방고등연구계획국의 설명가능 AI 사업은 신경망, 앙상블, 결정트리 같은 학습 기법을 성능과 설명가능성의 평면에 반비례 곡선으로 배치하고 둘을 함께 높이는 것을 목표로 삼았다.²⁵⁾ 반면 루딘(Cynthia Rudin)은 이 트레이드오프가 실증되지 않은 통념에 가깝고, 의미 있는 특징으로 구성된 문제에서는 해석 가능한 모델도 블랙박스 모델과 비슷한 성능을 내는 경우가 많다고 반박하였다.²⁶⁾ 세메노바(Lesia Semenova) 등은 비슷한 성능을 내는 모델이 많이 존재하는 문제일수록 그 가운데 단순한 모델도 존재할 가능성이 높다는 점을 이론적으로 보였다.²⁷⁾ 그런데 이 논쟁은 대부분 한 번의 분류나 예측을 내리는 정적 과업을 두고 이루어졌고, 매 순간 연속 지령을 내리는 공중전 같은 순차 의사결정 과업에서 트레이드오프를 측정한 사례는 드물다.

선행 논의를 종합하면 트레이드오프라는 주장은 서로 다른 두 가지 진술로 나뉜다. 하나는 모델 집단 전체에서 성능과 설명 비용이 함께 커진다는 연관성의 진술이다. 다른 하나는 설명 비용에 상한을 두면 도달할 수 있는 최고 성능이 낮아진다는 제약

Policy Extraction," in Samy Bengio et al. (eds.), *Advances in Neural Information Processing Systems 31* (Red Hook, NY: Curran Associates, 2018), pp. 2494~2504.

25) Gunning and Aha, 2019.

26) Rudin, 2019.

27) Lesia Semenova, Cynthia Rudin and Ronald Parr, "On the Existence of Simpler Machine Learning Models," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency* (New York: ACM, 2022).

비용의 진술이며, 루딘과 세메노바 등의 논의는 이 두 번째 진술을 겨냥한다. 두 진술은 서로 독립적이다. 성능과 설명 비용 사이에 전체적인 연관이 없어도 최고 성능의 모델이 모두 복잡하다면 제약 비용은 클 수 있고, 반대로 연관이 있어도 단순하면서 최고 성능에 가까운 모델이 하나라도 있다면 제약 비용은 작다. 본 연구는 두 진술을 각각 검정한다(3.5절).

2.4. 규칙과 학습의 결합

규칙과 학습의 결합은 트레이드오프를 피하는 실용적 방법으로 제안되어 왔다. 행동트리는 모듈 단위로 조립하기 쉽고 사람이 읽을 수 있어 게임 AI와 로봇 제어에서 널리 쓰이며 학습 모듈과 결합하기도 쉽다.²⁸⁾ 결합 방식은 목적에 따라 다양하다. 학습 정책의 행동을 감시하다가 안전 명세를 어길 때만 수정하는 안전 감독(shield),²⁹⁾ 기존 제어기의 출력 위에 학습 정책이 보정치만 더하는 잔차 학습,³⁰⁾ 상황에 따라 여러 전문가 모델의 비중을 게이트가 정하는 전문가 혼합³¹⁾이 대표적이다. 이 방식들은 각자의 목적에 따라 안전성, 학습 효율, 성능으로 평가되었을 뿐 결합한 결과가 얼마나 설명 가능한지는 평가되지 않았고, 서로 다른 결합 방식을 같은 과업에서 나란히 비교한 연구도 찾기 어렵다.

2.5. 선행연구와의 차별성

본 연구의 차별성은 세 연구 질문과 대응한다. RQ1에 대해, 공중전 AI 연구는 설명가능성을 정량적으로 측정하지 않았고 일반 설명가능 AI 연구는 트레이드오프를 정적 과업에서 논의하였다. 본 연구는 행동 재현 간결성이라는 계열 무관 지표를 공중전 과업에 적용하고, 트레이드오프를 연관성과 제약 비용의 두 진술로 나누어 성능의 정의를 바꿔 가며 검정한다. RQ2에 대해, 설명 비용이 무엇으로 결정되는지는 모델 계열을 전제로 가정되어 왔을 뿐 분석된 적이 없다. 본 연구는 같은 계열·같은 학습 예산 안에서 설명 비용이 갈리는 원인을 학습 과정과 전술 군집으로 분석한다. RQ3에 대해, 하이브리드 결합 방식은 각자 따로 평가되었다. 본 연구는 네 가지 결

28) Michele Colledanchise and Petter Ögren, *Behavior Trees in Robotics and AI: An Introduction* (Boca Raton: CRC Press, 2018).

29) Mohammed Alshiekh et al., "Safe Reinforcement Learning via Shielding," *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32, No. 1 (2018).

30) Tobias Johannink et al., "Residual Reinforcement Learning for Robot Control," in *2019 International Conference on Robotics and Automation (ICRA)* (Piscataway, NJ: IEEE, 2019), pp. 6023~6029.

31) Robert A. Jacobs, Michael I. Jordan, Steven J. Nowlan and Geoffrey E. Hinton, "Adaptive Mixtures of Local Experts," *Neural Computation*, Vol. 3, No. 1 (1991), pp. 79~87.

합 방식을 같은 잣대로 비교한다. <표 2-1>은 이를 요약한 것이다.

<표 2-1> 선행연구와 본 연구의 비교


연구	대상 모델	설명가능성의 측정	트레이드 오프 검정	결합 방식 비교
규칙 기반 교전 모델(이민석 외, 2022)	규칙 기반	행동트리 결정의 실시간 가시화(정성)	×	×
공중전 강화학습(포프 외, 2021; 황인수·배정호, 2023)	학습 기반(규칙 기반은 성능 기준선)	측정하지 않음	×	×
공중전 전역 설명(살디란 외, 2024)	학습 기반(DQN)	보상 성분별 기여	×	×
VIPER(바스타니 외, 2018)	학습 기반 → 결정트리 추출	추출한 트리의 성능·검증 가능성	×	×
트레이드오프 논쟁(루딘, 2019; 세메노바 외, 2022)	정적 분류·예측 모델	모델 구조의 단순성	정적 과업에서 논의	×
안전 감독·잔차 학습·전문가 혼합	하이브리드(각 1종)	측정하지 않음	×	×
본 연구	규칙 기반·학습 기반·하이브리드 4종	행동 재현 간결성(D*)	연관성·제약 비용	○

註: ○ 해당, × 해당 없음.
出處: 각 선행연구를 바탕으로 저자 작성.

3. 연구 방법

3.1. 연구 설계

본 연구는 모델링 및 시뮬레이션(M&S: Modeling and Simulation) 기반의 통제 실험이다. 규칙 기반·학습 기반·하이브리드 모델이 같은 모의 환경에서 같은 관측을 받아 같은 종류의 지령을 내도록 맞춘 뒤, 같은 상대와 같은 초기조건에서 교전시키고, 그 기록으로 성능과 설명 비용을 측정한다. 이렇게 얻은 모델별 두 값으로 트레이드 오프를 검정하고(RQ1), 설명 비용이 갈리는 원인을 분석하며(RQ2), 하이브리드의 위치를 판정한다(RQ3). 안전규칙 준수는 하이브리드 가운데 안전 감독 방식을 평가하기 위한 보조 지표로만 사용한다. 전체 흐름은 <그림 3-1>, 실험 변인은 <표 3-1>과 같다.



<그림 3-1> 연구 프레임워크

出處: 저자 작성.

<표 3-1> 실험 변인

구분	변인	수준
독립변인	모델 계열	규칙 기반(행동트리 3종), 학습 기반, 하이브리드
	하이브리드 결합 방식	선형 혼합형, 감독형, 잔차형, 게이팅형
	학습 예산	0(복제본)·100·200·300세대 ^a
종속변인	성능	학습 상대 점수, 보류 상대 점수, 전원 대전 점수
	설명 비용	대리 결정트리 최소 깊이 D*(95%, 90%), 깊이 4 충실도 F(4)
	보조 지표	안전규칙 위반율, 종료 사유
통제변인	모의 환경·교전 규칙	전 조건 동일(<표 3-2>)
	관측·지령	관측 20개, 지령 3개로 전 모델 동일
	평가 상대·초기조건	상대 2종, 고정된 초기조건 100개, 진영 교대

註: a: 잔차형·게이팅형은 100·200세대.

出處: 저자 작성.

3.2. 모의 환경

연구 계획 단계에서는 항공대 AI 파일럿 경진대회의 F-16 시뮬레이션 환경을 사용하려 하였다. 그러나 이 환경은 조종간·페달·스로틀을 직접 제어하는 고차원 입력

을 쓰고 교전 1회에 수 초가 걸려, 수만 회 교전이 필요한 학습과 10만 회가 넘는 평가를 기한 안에 수행할 수 없었다. 따라서 같은 교전 개념을 축소 재현한 전용 모의 환경을 구현하였다.³²⁾ 교전 1회의 계산 시간은 약 0.02초이다. <그림 3-2>는 이 환경에서 규칙 기반 모델 두 개가 교전한 기록을 3차원으로 나타낸 것이다.


기체는 F-16급 공개 제원을 사용한 3자유도 점질량 모델이다. 모든 모델은 원시 위치·속도 대신 교전 기하로 표현된 관측 20개(상대 거리, 기수-시선각(ATA: Antenna Train Angle), 애스펙트각(AA: Aspect Angle), 접근률, 고도차, 비에너지차, 양측 잔여 체력, 경과 시간 등)를 받고, 뱅크각·하중배수·스로틀의 지령 3개를 낸다. 세 계열이 같은 관측과 같은 지령을 공유한다는 점이 설명 비용 비교를 공정하게 만드는 전제이다. 주요 설정은 <표 3-2>와 같다.

<표 3-2> 모의 환경의 주요 설정

항목	값
기체 모델	3자유도 점질량, 질량 9,300 kg, 주익 면적 27.87 m ² , 최대 양력계수 1.6, 해면 최대추력 106 kN, 구조 한계 9 G
지령 응답	1차 지연(뱅크 0.35초, 하중배수 0.30초, 스로틀 1.2초)
시간 간격	적분 0.05초, 제어 주기 0.2초, 교전 제한 120초
기총	무장 유효 교전 구역(WEZ: Weapon Engagement Zone) 거리 120~1,200 m, 명중 원추 반각 3°→10°(시간에 따라 확대), 초당 체력 25 감소(체력 100)
종료 조건	격추, 지면 충돌(패), 거리 60 m 미만 공중 충돌(무승부), 120초 경과 시 잔여 체력 비교(같으면 무승부)
초기 조건	거리 1.5~3.5 km, 고도 3~5 km, 속도 180~260 m/s를 양측 동일하게, 기수 방위만 무작위
안전 규칙	최저 고도(하드텍) 1,000 m, 하중배수 8 G, 최소 이격 150 m(위반해도 교전은 계속되며 기록만 함)

出處: 저자 작성.

32) 모의 환경·비교 모델·분석 코드의 구현과 실험 실행, 원고 초안 작성에는 생성형 인공지능 도구 (Anthropic Claude)를 활용하였다. 연구 질문과 실험 설계, 결과의 해석, 최종 원고의 내용에 대한 책임은 저자에게 있다.



<그림 3-2> 모의 환경에서의 교전 기록

註: 청군 BT-v2와 홍군 BT-v3의 교전(초기조건 10055)으로, 76초에 청군이 격추로 승리하였다. 노란 점은 기총 유효 교전 구역(WEZ) 안에서 사격이 이루어진 구간이고, 회색 면은 하드택(1,000 m)이다.
 出處: 저자 작성.

점질량 모델은 받음각, 실속, 탄도를 모사하지 않고 롤 운동도 뱅크 지령의 1차 지연으로만 근사한다. 그럼에도 이 수준을 택한 것은 본 연구가 묻는 것이 조종면 조작이 아니라 "어느 쪽으로, 몇 G로 선회하고, 추력을 얼마나 쓰는가"라는 전술 판단 수준의 설명 비용이기 때문이다. 조종면 입력을 직접 내는 환경에서 대리모델을 적합시키면 자세 제어의 고주파 성분이 섞여 측정하려는 대상이 흐려진다. 공중전 기동 의사결정 연구에서도 같은 이유로 3자유도 질점 모델이 널리 쓰인다.³³⁾³⁴⁾³⁵⁾ 가용 하

33) Qiming Yang, Jiandong Zhang, Guoqing Shi, Jinwen Hu and Yong Wu, "Maneuver Decision of UAV in Short-Range Air Combat Based on Deep Reinforcement Learning," *IEEE Access*, Vol. 8 (2020), pp. 364~365.

34) Weiren Kong, Deyun Zhou, Zhen Yang, Yiyang Zhao and Kai Zhang, "UAV Autonomous Aerial Combat Maneuver Strategy Generation with Observation Error Based on State-Adversarial Deep Deterministic Policy Gradient and Inverse Reinforcement Learning," *Electronics*, Vol. 9, No. 7 (2020), 1121, p. 5.

35) Hyunju Park, Byung-Yoon Lee, Min-Jea Tahk and Dong-Wan Yoo, "Differential Game Based Air Combat Maneuver Generation Using Scoring Function Matrix," *International Journal of Aeronautical and Space Sciences*, Vol. 17, No. 2 (2016), p. 205.

중배수를 양력 한계와 구조 한계 중 작은 값으로 두었으므로 코너 속도나 에너지 손실에 따른 선회력 저하 같은 근접공중전의 핵심 성질은 모델 안에서 나타난다. 다만 비교 모델의 전술은 모두 이 역학에 맞춰져 있으므로, 단순화가 특정 계열에 유리하게 작용했을 가능성을 점검하기 위해 비행역학을 바꾼 재평가와 6자유도 F-16 모델 교차 평가를 수행하였다(3.5.3절).

3.3. 비교 모델

3.3.1. 규칙 기반 모델

행동트리³⁶⁾는 "이 조건이면 이 행동"이라는 규칙을 우선순위 순서로 엮은 나무 구조로, 매 제어 주기마다 위에서부터 조건을 확인해 처음 맞는 행동을 실행한다. 세 트리는 기본전투기동(BFM: Basic Fighter Maneuvers) 교범의 표준 전술³⁶⁾만을 사람이 규칙으로 옮겨 쓴 것으로, 데이터로 상수를 맞추지 않았으며 성숙도의 단계가 아니라 서로 다른 교리를 대표한다(<표 3-3>). BT-v3를 조종사의 말로 옮기면 "정면으로 빠르게 다가오면 옆으로 비켜라, 낮으면 먼저 고도를 회복하라, 사거리 안에 상대가 들어오면 상대 앞을 겨누고 8 G 안에서 당겨라, 그 밖에는 상대 쪽으로 선회하라"는 네 문장이 된다.

<표 3-3> 규칙 기반 모델

모델	노드 수	교리	규칙(우선순위 순)
BT-v1	8	수평 추격	정면 합류 회피, 기수 정렬 시 날개 수평·4 G, 그 밖에는 상대 쪽 75° 뱅크·4 G
BT-v2	5	3차원 최대 선회	정면 합류 회피, 양력 방향을 상대 쪽으로 돌리고 가용 최대 G·최대 추력
BT-v3	11	BT-v2 + 안전규칙	정면 합류 회피, 하드택+400 m 아래면 날개 수평·상승, 사거리 안이면 리드 추격(8 G 상한), 그 밖에는 BT-v2와 같은 추격(8 G 상한)

註: 정면 합류 회피는 거리 1 km 이내에서 서로 정면으로 빠르게 접근할 때 반대쪽으로 75° 뱅크해 비켜 가는 규칙이다. 이 규칙이 없을 때 순수 추격 트리끼리의 교전은 45~53%가 공중 충돌로 끝나 세 트리 모두에 추가하였다.

出處: 저자 작성.

3.3.2. 학습 기반 모델

학습 기반 모델은 관측 20개를 받아 지령 3개를 내는 다층 퍼셉트론(MLP: Multi-Layer Perceptron)이다(은닉층 32·32, 가중치 1,827개). 먼저 BT-v2가 교전한 기록 161,694개를 흉내 내도록 가중치를 맞추는 행동복제로 초기화하고(뱅크 지

36) Robert L. Shaw, *Fighter Combat: Tactics and Maneuvering* (Annapolis: Naval Institute Press, 1985).

령 재현도 R^2 0.95), 진화전략(ES: Evolution Strategies)³⁷⁾으로 다듬었다. 진화전략은 가중치를 조금씩 다르게 혼든 후보 32개를 각각 8회 교전시키고 잘 싸운 후보 쪽으로 가중치를 옮기는 과정을 한 세대로 삼아 반복하며, 갱신 전후를 같은 초기조건으로 비교해 나빠지면 갱신을 거부하는 수용 검사를 더하였다. 학습 상대는 BT-v1과 BT-v2를 번갈아 사용하였고 BT-v3는 학습에 쓰지 않았다. 학습 예산은 300세대, 학습 시드는 20개이다. 교전 결과를 하나의 수치로 평가하는 적합도는 가한 피해와 받은 피해의 차, WEZ 체류 시간, 종료 결과에 따른 보상(격추승 +10, 시간종료승 +5, 지면 충돌 -15 등), 상대를 향한 정도를 나타내는 포텐셜 항,³⁸⁾ 안전규칙 위반 벌점, 양측 무피해 시간종료 벌점의 합으로 정의하였다.

행동복제에서 출발한 것은 설계상의 선택이자 시행착오의 결과이다. 처음 적합도로 학습한 정책은 싸우지 않고 멀리 도망가 기수만 상대 쪽으로 두는 방식으로 점수를 챙겼고, 적합도를 고친 뒤에도 무작위 가중치에서 시작하면 회피로 수렴하였다. 교전을 시도하면 BT-v2에게 격추되어 큰 손실을 보고 도망가면 작은 손실만 보는 보상 구조에서 진화전략이 싸우는 정책을 우연히 발견하기 어렵기 때문이다. 행동복제로 시작하자 이번에는 진화전략의 갱신이 복제된 행동을 100세대 만에 지워 버려, 위의 수용 검사를 더해 해결하였다. 따라서 본 연구의 학습 기반 모델은 규칙과 무관하게 학습된 모델이 아니라 규칙 모델의 행동에서 출발해 학습으로 갈라져 나간 모델이다. 이 점은 결과 해석의 한계이지만(5.5절), 학습 예산을 0에서 늘려 가며 같은 출발점의 모델이 규칙에서 멀어질 때 성능과 설명 비용이 어떻게 변하는지를 관찰할 수 있게 해 준다.

3.3.3. 하이브리드 모델

하이브리드는 규칙 기반 지령과 학습 기반 지령을 합치는 방식에 따라 네 종류로 나누었다(<표 3-4>). 2.4절의 세 계보에 가장 단순한 선형 혼합을 기준으로 더한 구성이다. 감독형은 학습 모델이 무엇을 할지 정하고 규칙은 하지 말아야 할 것만 막는 방식이고, 잔차형은 규칙 지령 위에 학습 모델이 작은 보정치만 더하는 방식이며, 게이팅형은 작은 게이트 신경망이 상황마다 두 지령의 비율을 정하는 방식이다. 잔차형과 게이팅형은 선형 혼합형과 감독형의 결과를 본 뒤 "결합 방식을 잘못 골라서가

37) Tim Salimans, Jonathan Ho, Xi Chen, Szymon Sidor and Ilya Sutskever, "Evolution Strategies as a Scalable Alternative to Reinforcement Learning," arXiv:1703.03864 (2017). <https://arxiv.org/abs/1703.03864> (검색일: 2026년 9월 30일)

38) Andrew Y. Ng, Daishi Harada and Stuart Russell, "Policy Invariance under Reward Transformations: Theory and Application to Reward Shaping," in *Proceedings of the Sixteenth International Conference on Machine Learning* (San Francisco: Morgan Kaufmann, 1999), pp. 278~287.

아닌가"라는 반론을 확인하려고 추가한 확장 실험으로, 판정 기준은 결과가 나오기 전에 연구 기록에 정해 두었으며 규모는 본실험보다 작다.

<표 3-4> 하이브리드 결합 방식

방식	혼합 비율의 결정	지령	학습
선형 혼합형	사람이 α 를 고정	$a = (1-\alpha) \cdot a_{BT} + \alpha \cdot a_L$, $\alpha = 0.25 \cdot 0.5 \cdot 0.75$	학습 기반 모델과 함께, 300세대·20시드
감독형	사람이 쓴 안전 조건	안전 조건이면 BT-v3의 안전 규칙, 아니면 a_L (8 G 상한)	추가 학습 없음, 300세대 모델 20개에 적용
잔차형	규칙이 빠대, 학습은 보정	$a = a_{BT} + \beta \cdot \delta(o)$, $\beta = 0.35$	6만 학습, 200세대·3시드
게이팅형	게이트 신경망이 상황마다	$a = (1-g(o)) \cdot a_{BT} + g(o) \cdot a_L$	게이트만 학습, 200세대·3시드

註: a_{BT} 는 BT-v2의 지령, a_L 은 학습 기반 모델의 지령, o 는 관측이다. 뱁지 지령은 각도이므로 원형 평균-원형 합으로 계산한다. 잔차형의 $\beta = 0.35$ 는 뱁지 최대 $\pm 63^\circ$, 하중배수 최대 ± 1.6 G의 보정에 해당한다. 게이팅형의 a_L 은 학습 시드 11의 300세대 모델(20개 중 점수 2위, $D^* = 3$)을 고정해 사용하였다.

出處: 저자 작성.

3.3.4. 통제 조건

두 가지 반론을 확인하기 위한 통제 조건을 두었다. "규칙 기반 모델이 약한 것은 사람이 상수를 손으로 정했기 때문"이라는 반론에 대해서는, BT-v3와 구조는 같게 두고 상수 9개만 학습 기반 모델과 같은 진화전략·적합도·예산으로 최적화한 상수 최적화 행동트리(BTO)를 3시드 만들었다. 결과물은 여전히 사람이 읽을 수 있는 규칙이다. "학습 방법이 진화전략 하나뿐"이라는 반론에 대해서는 행동복제 없이 무작위 초기화에서 근위 정책 최적화(PPO: Proximal Policy Optimization)³⁹⁾로 150만 스텝 학습한 모델을 2시드 만들었다.

3.4. 측정 지표

3.4.1. 성능

교전 한 판의 결과를 승 1, 무 0.5, 패 0으로 매기고 그 평균을 점수로 삼는다. 0.5가 대등이다. 성능은 하나로 정의하지 않고 세 가지로 나누어 측정하였다. 학습 상대 성능은 학습에 사용한 BT-v2와의 대결 점수로, 학습 모델이 무엇을 목표로 최적화되었는지를 보여준다. 보류 상대 성능은 학습에 한 번도 쓰지 않은 BT-v3와의 대결 점수로, 특정 상대에 맞춰진 것이 아닌 일반적인 교전 능력을 나타낸다. 전원 대전

39) John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov, "Proximal Policy Optimization Algorithms," arXiv:1707.06347 (2017). <https://arxiv.org/abs/1707.06347> (검색일: 2026년 9월 30일)

성능은 학습 기반 모델 20개, 행동트리 3종, BTO 3개를 한 풀에 넣고 서로 전부 교전시킨 평균 점수로, 고정된 두 상대에 대한 결과가 모델 사이의 상대적 우열과 일치하는지를 확인한다. 성능을 이렇게 나눈 것은 트레이드오프의 검증이 "고성능 모델"의 존재를 전제하기 때문이다. 어떤 모델이 고성능인지가 평가 상대에 따라 달라진다면 트레이드오프의 판정도 그에 따라 달라질 수 있으므로, 세 정의 모두에서 같은 결론이 나오는지를 확인해야 한다. 두 상대에 대한 평균 점수는 보조로만 쓴다.

3.4.2. 설명 비용

각 모델이 교전 중 남긴 (관측, 지령) 기록에 깊이 d 인 결정트리 회귀모형을 적합시키고, 적합에 쓰지 않은 기록에서 원래 지령을 얼마나 재현하는지를 결정계수(R^2)로 측정하여 깊이 d 의 충실도 $F(d)$ 로 삼았다. 지령 3개의 R^2 는 각 지령의 분산으로 가중 평균하였는데, 스로틀을 항상 최대로 두는 모델처럼 변하지 않는 지령이 충실도를 부풀리는 것을 막기 위해서이다. 기록은 상대별 초기조건 30개의 교전에서 0.2초마다 수집하였고(모델당 약 28,000~35,000개), 70%로 트리를 적합하고 30%로 충실도를 계산하였다.

설명 비용 D^* 는 $F(d)$ 가 목표 충실도 이상이 되는 가장 작은 깊이이다. 깊이 d 인 결정트리는 "if-then 질문을 최대 d 번 연달아 던져 지령을 정하는 규칙"이므로, 목표 충실도를 0.95로 두면 D^* 는 "이 모델의 조종을 95% 재현하려면 규칙이 몇 단계 필요한가"를 뜻한다. 깊이 16까지 검사해 목표에 이르지 못하면 17로 기록하고 절단으로 표기한다. 주 지표는 95% 기준의 D^* 이며, 결론이 목표 충실도 하나에 좌우되지 않도록 90% 기준의 D^* 와 깊이 4에서의 충실도 $F(4)$ 를 함께 보고한다. 두 기준의 차이는 결과 해석에서 중요하다. 90% 기준에서는 전체 조건의 91%가 깊이 5 이하로 재현되었고 절단은 2%였던 반면, 95% 기준에서는 58%가 절단이었다. 모델 사이의 설명 비용 차이는 대부분 행동의 마지막 5~10%를 재현하는 데서 생긴다는 뜻이다.

이 지표는 모델의 내부가 아니라 행동을 잴다. "행동트리는 원래 트리라서 결정트리로 재현하기 쉽다"는 반론이 가능하지만, 노드 5개인 BT-v2는 양력 방향을 연속 함수로 계산하므로 $D^* = 4$ 였고 BT-v2를 흉내 낸 신경망 복제본은 $D^* = 2$ 였다. 트리 구조 자체가 유리하게 작용하지는 않았다.

3.4.3. 보조 지표

안전규칙 세 가지 가운데 하나라도 어긴 적분 스텝의 비율을 위반율로 정의하였다. 교전 1회는 최대 2,400스텝이므로 위반율 0.05는 2,400스텝 중 120스텝 동안 규칙을 어기고 있었다는 뜻이다. 위반율이 0인 경우는 평가 교전에서 위반이 관측되지 않았다는 뜻으로만 해석한다. 이와 함께 교전의 종료 사유(격추, 시간종료, 충돌)와

WEZ 체류 시간을 기록하여 전술 분석에 사용하였다.

3.5. 트레이드오프 검증 방법

3.5.1. 연관성 검증

첫 번째 검증은 모델 집단에서 성능이 높을수록 설명 비용이 큰지를 본다. 트레이드오프가 있다면 성능과 D^* 의 순위상관 ρ 는 양수여야 한다. 상관은 D^* 에 절단값이 있으므로 Spearman 순위상관을 쓰고, 성능 정의 세 가지와 설명 비용 정의 세 가지 (95%·90% 기준 D^* , $1-F(4)$)의 모든 조합에서 계산한다. 모델 집합은 전체 282개 조건과, 혼합 정책을 뺀 79개 조건(행동트리 3, BTO 9, 학습 기반 61, PPO 6)으로 나누어 본다. 전체 조건의 65%를 차지하는 선형 혼합형이 "점수는 중간, D^* 는 최대"인 한 덩어리를 이루어 전체 상관을 끌어내릴 수 있기 때문이다.

282개 조건은 같은 학습 시드에서 파생된 것이 많아 서로 독립이 아니다. 따라서 조건 단위 상관은 관계의 방향과 크기를 요약하는 데 쓰고, 통계적 판단은 학습 시드를 임의효과로 둔 선형 혼합모형과 학습 시드 단위 상관에 근거한다. "유의한 상관이 없다"를 넘어 "상관이 작다"고 말할 수 있는지는 부트스트랩 90% 신뢰구간이 ± 0.2 안에 들어오는지를 보는 동등성 검증(TOST: Two One-Sided Tests)으로 확인하였다.⁴⁰⁾⁴¹⁾ D^* 의 측정 잡음이 상관을 0 쪽으로 끌어내렸을 가능성은 전반과 후반 교전으로 나누어 켄 반분 신뢰도로 감쇠를 보정해 확인하였다.⁴²⁾

3.5.2. 제약 비용 분석

두 번째 분석은 설명 비용에 상한 k 를 두었을 때 잃는 성능을 쟀다. $D^* \leq k$ 인 모델 가운데 가장 강한 모델의 점수와 상한 없이 가장 강한 모델의 점수의 차를 k 의 제약 비용으로 정의한다. 트레이드오프가 있다면 k 가 작을수록 제약 비용이 크고, k 를 늘려도 비용이 쉽게 0이 되지 않아야 한다. 다만 수백 개 조건 가운데 최고점을 고르면 우연히 운이 좋았던 조건이 뿔혀 최고점이 부풀려진다. 이를 막기 위해 평가 초기조건 100개를 짝수와 홀수로 나누어, 한쪽에서 두 모델을 고르고 다른 쪽에서 점수 차를 쟀 뒤 양방향을 평균하였다. 두 모델의 점수 차가 0과 다른지는 같은 초기

40) Donald J. Schuurmann, "A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability," *Journal of Pharmacokinetics and Biopharmaceutics*, Vol. 15, No. 6 (1987), pp. 657~680.

41) Bradley Efron, "Bootstrap Methods: Another Look at the Jackknife," *The Annals of Statistics*, Vol. 7, No. 1 (1979), pp. 1~26.

42) Charles Spearman, "The Proof and Measurement of Association between Two Things," *The American Journal of Psychology*, Vol. 15, No. 1 (1904), pp. 72~101.

조건을 공유하는 대응 비교이므로 Wilcoxon 부호순위 검정⁴³⁾으로 판단하였다. 이 분석도 세 가지 성능 정의와 두 가지 목표 충실도에서 각각 수행하였다.

3.5.3. 평가 조건을 바꾼 재평가

두 검정은 본실험 환경에서 이루어지므로, 결론이 그 환경의 산물인지를 다시 학습하지 않은 재평가로 점검하였다. 학습 기반 300세대 모델 20개, 행동트리 3종, BTO 3개를 교전 규칙(제한시간 240초, 시간종료 무승부)이나 비행역학(최대 양력계수·최대추력·지령 지연 $\pm 20\%$, 롤 속도 상한 $180 \cdot 90^\circ/\text{s}$)을 바꾼 환경에서 같은 초기조건으로 다시 평가하였다. 또 31개 모델을 공개 비행역학 라이브러리 JSBSim의 6자유도 F-16 모델로 옮겨 평가하였다.⁴⁴⁾ 이때 모델이 낸 뱅크각·하중배수·스로틀 지령은 별도로 구현한 추종 제어기가 조종간 입력으로 바꾸며, D*는 두 환경 모두 모델이 낸 지령으로 계산하므로 정의가 같다. 6자유도 교차 평가의 판정 기준은 평가 전에 문서로 정해 두었다.

3.6. 평가 절차

모든 모델은 BT-v2와 BT-v3 두 상대와 교전한다. 초기조건은 평가용으로 고정한 100개를 쓰고, 같은 초기조건에서 청군과 홍군을 바꿔 한 번 더 교전시켜 한쪽 자리가 유리한 효과를 상쇄하였다. BT-v2끼리 교전시켰을 때 진영 교대 전에는 한쪽 점수가 0.59였으나 교대 후에는 0.500이 되어 이 설계가 초기조건 편향을 제거함을 확인하였다. 모델 하나는 상대 2종 $\times$ 초기조건 100개 $\times$ 진영 2 = 400회 교전으로 평가된다.

본실험은 규칙 기반 3개, 학습 기반과 선형 혼합형 244개(학습 예산 $100 \cdot 200 \cdot 300$ 세대 $\times \alpha$ 4수준 $\times$ 학습 시드 20개, 여기에 예산 0인 복제본 4개), 통제 조건과 감독형 35개(BTO 9, 감독형 20, PPO 6)의 282개 조건 $\times$ 400회 = 112,800회 교전이다. 잔차형·게이팅형 확장 실험은 두 방식 각 6조건에 비교 기준 6조건(규칙 기반 3개와 학습 시드 11의 순수 학습 기반·선형 혼합형(α 0.5)·감독형)을 더한 18조건 $\times$ 400회 = 7,200회 교전이며, 비교 기준 조건의 점수와 D*는 본실험과 소수점 셋째 자리까지 같았다. 확장 실험은 학습 시드가 3개뿐이므로 통계 검정 없이 기술적으로 비교한다. 점수의 신뢰구간은 Wilson 95% 구간,⁴⁵⁾ 여러 비교의 오류 누적은 Holm

43) Frank Wilcoxon, "Individual Comparisons by Ranking Methods," *Biometrics Bulletin*, Vol. 1, No. 6 (December 1945), pp. 80~83.

44) Jon Berndt, "JSBSim: An Open Source Flight Dynamics Model in C++," in *AIAA Modeling and Simulation Technologies Conference and Exhibit* (Providence, RI: AIAA, 2004), AIAA Paper 2004-4923.

보정⁴⁶⁾으로 처리하였다.

4. 연구 결과

4.1. 평가 상대에 따라 달라진 성능

트레이드오프를 검정하기에 앞서 각 계열의 성능을 세 가지 정의로 비교하였다 (<표 4-1>). 순수 학습 기반 모델은 학습 예산이 늘수록 학습 상대를 더 잘 이겼다. BT-v2와의 대결 점수는 행동복제 초기 모델(이하 복제본)의 0.438에서 300세대 0.687(표준편차 0.057)로 올랐고, 300세대 모델 20개 모두 0.5를 넘었으며 무승부를 뺀 승률은 20개 중 18개가 Holm 보정 후에도 0.5보다 유의하게 높았다. 학습 예산과 점수의 순위상관은 $\rho = 0.45$ ($p = 0.0003$)였고, 학습 시드를 임의효과로 둔 혼합모형에서도 예산의 효과가 유의하였다($p = 0.0001$).

보류 상대에 대한 결과는 달랐다. 300세대 모델의 BT-v3 상대 점수는 평균 0.746(0.60~0.84)으로 출발점인 복제본(0.840)보다 낮았고, 같은 상대에 대한 BT-v2의 점수(0.843)를 넘은 모델은 하나도 없었다. 보류 상대에게 가장 강한 모델은 상수만 최적화한 행동트리 BTO(0.882)였다. 학습 기반 모델은 학습 상대를 직접 이기는 법은 익혔지만, 제3의 상대를 다루는 능력에서는 규칙 기반 최강 모델을 넘지 못한 것이다. 전원 대전에서는 다시 학습 기반 모델 20개 모두(0.48~0.58)가 BT-v2(0.43)보다 높았다. 학습 모델이 고성능인지는 이처럼 무엇을 상대로 재느냐에 따라 달라졌으며, 4.5절에서 보듯 교전 규칙과 비행역학에도 의존하였다.

45) Edwin B. Wilson, "Probable Inference, the Law of Succession, and Statistical Inference," *Journal of the American Statistical Association*, Vol. 22, No. 158 (June 1927), pp. 209~212.

46) Sture Holm, "A Simple Sequentially Rejective Multiple Test Procedure," *Scandinavian Journal of Statistics*, Vol. 6, No. 2 (1979), pp. 65~70.

<표 4-1> 계열별 성능과 설명 비용

계열	모델 수	학습 상대(BT- v2)	보류 상대(BT- v3)	전원 대전	D* 95% 중앙값(범위)	D* 90% 중앙값
BT-v1	1	0.250	0.233	0.195	1	1
BT-v2	1	(0.500)	0.843	0.432	4	2
BT-v3	1	0.158	(0.500)	0.261	5	3
상수 최적화 행동트리(BTO)	3	0.321	0.882	0.400	3 (3~5)	3
복제본(학습 예산 0)	1	0.438	0.840	-	2	1
학습 기반(300세대)	20	0.687	0.746	0.546	6 (3~17)	2
무작위 초기화 PPO	6	0.390	0.380	-	5 (4~7)	3
선형 혼합형 α 0.25	20	0.531	0.707	-	17 (5~17)	3
선형 혼합형 α 0.5	20	0.586	0.691	-	17 (6~17)	4
선형 혼합형 α 0.75	20	0.687	0.755	-	17 (5~17)	4
감독형	20	0.487	0.600	-	11 (6~17)	4.5
잔차형(200세대)	3	0.565	0.690	-	6 (6~17)	3
게이팅형(200세대)	3	0.647	0.797	-	17	3

註: 점수는 계열 안 모델들의 평균이며 괄호 안 값은 자기 자신과의 대전이다. 선형 혼합형과 감독형은 300세대 학습 기반 모델에 적용한 값이다. 전원 대전은 학습 기반 20개, 행동트리 3종, BTO 3개의 26개 모델로 수행하였다. D* = 17은 깊이 16까지 목표 충실도에 이르지 못한 절단값이다.

出處: 저자 작성.

4.2. 트레이드오프 점정(RQ1)

4.2.1. 연관성 점정

<표 4-2>는 성능 정의와 설명 비용 정의의 조합별로 성능과 설명 비용의 순위상관을 구한 것이고, <그림 4-1>은 최종 예산 모델들의 점수와 D*를 한 평면에 나타낸 것이다. 트레이드오프가 있다면 모든 칸이 양수여야 한다. 282개 조건 전체에서는 아홉 조합 모두 ρ 가 $-0.13 \sim -0.01$ 로 0이거나 음수였다. 주 지표인 학습 상대 점수와 95% 기준 D*의 조합에서 $\rho = -0.02$ 였고, 90% 신뢰구간 $[-0.14, 0.09]$ 가 ± 0.2 안에 들어와 동등성 검정으로 "상관의 크기가 0.2보다 작다"가 성립하였다. 상대 2종 평균 점수로 보아도 $\rho = -0.02$, 학습 시드를 통째로 재추출한 클러스터 부트스트랩의 90% 구간은 $[-0.18, 0.15]$ 였다. 주 분석으로 정한 학습 시드 임의효과 혼합모형에서 학습 예산과 혼합계수를 함께 넣었을 때 D*의 계수는 0.001($p = 0.82$)이었고, 학습 시드 단위 순위상관은 -0.13 ($p = 0.59$)이었다. 반분 신뢰도는 D* 0.82, 점수 0.96이었으며 이로써 감쇠를 보정한 상관도 -0.02 였으므로, 측정 잡음이 상관을 0으로 끌어내린 것은 아니었다.

혼합 정책을 뺀 79개 조건에서는 성능 정의에 따라 방향이 갈렸다. 학습 상대 점


수를 쓰면 95% 기준 D^* 와 $p = 0.25$ ($p = 0.03$), $1-F(4)$ 와 0.23 ($p = 0.045$)으로 트레이드오프 방향의 약한 상관성이 나타났다. 그러나 보류 상대 점수를 쓰면 같은 조합이 -0.22 와 -0.25 로 반대 방향이 되었고, 90% 기준 D^* 로 재면 세 성능 정의 모두에서 음수였다. 전원 대전 점수와의 상관성은 $-0.15 \sim 0.17$ 로, 신뢰구간이 모두 0을 넘지 못하였다. 21개 조합 가운데 보정 전 $p < 0.05$ 인 것은 양의 방향과 음의 방향이 각각 두 개였고, 다중비교를 Holm 방식으로 보정하면 어느 것도 유의하지 않았다.

<표 4-2> 성능과 설명 비용의 순위상관

모델 집합	성능 정의	D^* 95%	D^* 90%	$1-F(4)$
전체(282)	학습 상대	$-0.02 [-0.14, 0.09]$	$-0.11 [-0.22, 0.00]$	$-0.01 [-0.12, 0.10]$
	보류 상대	$-0.07 [-0.18, 0.04]$	$-0.10 [-0.20, 0.00]$	$-0.11 [-0.22, 0.00]$
	상대 2종 평균	$-0.02 [-0.12, 0.08]$	$-0.13 [-0.23, -0.03]$	$-0.05 [-0.16, 0.05]$
혼합 제외(79)	학습 상대	$0.25 [0.04, 0.44]$	$-0.16 [-0.35, 0.02]$	$0.23 [0.01, 0.41]$
	보류 상대	$-0.22 [-0.40, 0.00]$	$-0.10 [-0.25, 0.06]$	$-0.25 [-0.44, -0.04]$
	상대 2종 평균	$0.17 [-0.03, 0.35]$	$-0.19 [-0.37, 0.00]$	$0.14 [-0.06, 0.33]$
전원 대전(26)	전원 대전 점수	$0.13 [-0.23, 0.44]$	$-0.15 [-0.45, 0.17]$	$0.17 [-0.19, 0.49]$

註: Spearman 순위상관 ρ 와 조건 부트스트랩 90% 신뢰구간이다. 양수가 트레이드오프 방향이다. $1-F(4)$ 는 깊이 4 트리로 재현하지 못한 비율로, 클수록 설명 비용이 크다. 혼합 제외는 행동트리 3, BTO 9, 학습 기반 61(예산 0~300세대), PPO 6개 조건이다.

出處: 저자 작성.



<그림 4-1> 최종 예산 모델의 성능-설명 비용 평면

註: 가로축은 상대 2중 평균 점수, 세로축은 D^* 이다. 같은 값의 점이 겹치지 않도록 세로 방향으로 작게 흘렜다. 학습 기반·선형 혼합형·감독형은 300세대, 잔차형·게이팅형은 200세대, PPO는 150만 스텝 모델이다.
出處: 저자 작성.

실험을 진행하며 학습 시드를 3개, 5개, 8개, 20개로 늘리는 동안 전체 순위상관은 0.38($p = 0.011$), 0.06, -0.16, -0.02로 움직였다. 시드 3개일 때는 통계적으로 유의한 트레이드오프가 관측되었으나 반복을 늘리자 사라졌다.

4.2.2. 제약 비용 분석

<표 4-3>은 설명 비용에 상한을 두었을 때 잃는 성능을 교차 검증으로 낸 결과이다. 95% 기준 D^* 를 2 이하로 묶으면 세 성능 정의 모두에서 손실이 0.15~0.34로 컸다. 깊이 2 이하인 모델은 행동트리 BT-v1과 복제본 정도뿐이기 때문이다. 상한을 3~5로 풀면 손실은 상대 2중 평균 기준 0.04, 학습 상대 기준 0.03~0.06으로 줄었으나, 보류 상대 기준으로는 0.11이 남았다. 상한을 6으로 풀면 상대 2중 평균과

보류 상대 기준의 손실은 0에 가까워졌고(-0.03, 0.01), 학습 상대 기준으로만 0.07의 손실이 남았다. 학습 상대에게 가장 강한 모델이 D* 17의 선형 혼합형(α 0.75)이었기 때문이다. 90% 기준 D*로 재면 상한 5 이상에서 세 성능 정의 모두 손실이 0이었고, 상한 2~4에서도 학습 상대 기준 0.07~0.08을 빼면 0.03 이하였다. 상한을 6으로 둔 상대 2종 평균에서 손실이 음수(-0.03)로 나온 것은 교차 검증을 하더라도 최고 모델을 고르는 과정에 0.03 안팎의 우연 변동이 남는다는 것을 보여 준다.

<표 4-3> 설명 비용 상한에 따른 성능 손실

성능 정의	D* ≤ 2	D* ≤ 3	D* ≤ 5	D* ≤ 6
학습 상대	0.338 ^a	0.055 ^a	0.028	0.065 ^a
보류 상대	0.150 ^a	0.108 ^a	0.108 ^a	0.013
상대 2종 평균	0.175 ^a	0.038 ^a	0.038 ^a	-0.033 ^a

註: 95% 기준 D*. 값은 평가 초기조건의 절반으로 'D* 상한 안의 최고 모델'과 '전체 최고 모델'을 고르고, 나머지 절반에서 켜 두 모델의 점수 차를 양방향으로 평균한 것이다. 양수는 상한 때문에 잃은 성능이다.

a: 초기조건 단위 Wilcoxon 부호순위 검정 $p < 0.05$.

出處: 저자 작성.

두 검정을 종합하면 이 과업에서 "성능이 높을수록 설명 비용이 크다"는 강한 트레이드오프는 나타나지 않았다. 다만 트레이드오프가 전혀 없는 것도 아니다. 설명 비용을 매우 엄격하게 묶으면 분명한 성능 손실이 있었고, 학습 상대 성능만 놓고 보면 혼합 정책이 없는 모델들 사이에서 약한 연관과 작은 손실이 남았다. 이 손실은 깊이 5~6을 허용하면 대부분 사라졌고, 학습에 쓰지 않은 상대나 전원 대전으로 성능을 재면 나타나지 않거나 반대 방향이었다.

4.3. 설명 비용의 결정 요인(RQ2)


4.3.1. 모델 계열

<표 4-1>에서 95% 기준 D*의 중앙값은 행동트리 1~5, BTO 3, 학습 기반 6, PPO 5였고 하이브리드는 11~17이었다. 계열 사이의 차이는 있었지만 범위가 겹쳤다. 학습 기반 모델 20개 가운데 9개는 D*가 5 이하였고, 점수 2위인 학습 시드 11의 모델은 D* = 3으로 BT-v2(4)보다 간결하였다. 가중치 1,827개로 이루어진 신경망의 조종이 if-then 규칙 3단계로 95% 재현된 것이다. 90% 기준에서는 계열 차이가 더 작아져 대부분의 계열이 중앙값 2~4에 모였다.

4.3.2. 학습량

학습 시드 12개를 25세대 간격으로 평가하면(<그림 4-2>) 점수는 복제본을 떠

난 직후인 25세대에 0.537로 내려갔다가 300세대 0.705까지 꾸준히 올랐다($p = 0.46$, $p < 0.0001$). 반면 자기 기록으로 쟁 D*는 복제본의 2에서 25세대에 7.2로 뛰어오른 뒤 300세대까지 6.2~8.6 사이에서 평평하였다($p = 0.04$, $p = 0.60$). 같은 시드 안에서 초기(50~100세대)와 후기(250세대 이상)의 D*는 7.8 대 8.4로 유의한 차이가 없었다(Wilcoxon $p = 0.73$). 설명 비용이 커진 것은 복제본을 떠나는 첫 순간에 한 번이었고, 그 뒤의 성능 향상은 설명 비용의 증가 없이 이루어졌다. 다만 모든 모델에 같은 관측 40,000개를 질의해 쟁 공통 상태 D*는 복제본의 4에서 275세대 16.0까지 대체로 올랐고, 그동안 모델이 실제로 방문하는 상황의 폭은 좁아졌다(예산과 방문 범위 $\rho = -0.32$, $p = 0.0001$). 학습 모델은 자기가 실제로 가는 상황에서는 간결하게 행동하지만, 가지 않는 상황까지 물으면 학습이 진행될수록 규칙에서 멀어졌다.



<그림 4-2> 학습 예산에 따른 점수와 D*의 변화


註: 학습 시드 8~19번(12개)의 25세대 간격 체크포인트를 상대 2종 × 초기조건 50개 × 진영 2 = 200회 교전으로 평가한 평균이다. 0세대는 본실험의 복제본 값이다.

出處: 저자 작성.


4.3.3. 전술

300세대 학습 기반 모델 20개는 점수가 비슷해도 D*가 3에서 17까지 갈렸고, 그 차이는 이긴 방식에 대응하였다. 다수인 16개는 교전 초반에 한 번 스치듯 사격해 체력 우위를 만든 뒤 상대와 어긋난 선회를 유지하며 다시 붙지 않고 시간종료 체력 우위로 이겼다(이하 '치고 빠지기'). 교전 규칙상 정당한 승리 방식이다. 이 16개의 D*는 중앙값 5였고 16개 중 15개가 3~9였다. 나머지 4개는 끝까지 붙어 격추로 이기는 비율이 26~35%였으며(이하 '추격 격추') D*는 8~17이었다. <그림 4-3>은 같은 상대와 교전한 두 전술의 궤적이다.

(a) 치고 빠지기
시간종료 : 120초 · 정군 승 · 남은 체력 청 100 / 홍 62



(b) 추격 격추
격추 : 108초 · 정군 승 · 남은 체력 청 100 / 홍 0



— 정군: 학습 기반 — 홍군: BT-v2 ● 시작 위치 ■ 종료 위치 ✱ 격추된 기체 ● WEZ 안(사격 중) — 하드택(1,000 m)

<그림 4-3> 두 전술의 교전 궤적

註: (a) 치고 빠지기(학습 시드 11, 초기조건 10054)는 초반에 한 번 사격한 뒤 다시 붙지 않아 시간종료 체력 우위(100 대 62)로 이겼고, (b) 추격 격추(학습 시드 1, 초기조건 10016)는 끝까지 추격하며 여러 번 사격해 108초에 격추하였다. 상대는 모두 BT-v2이며, 노란 점은 WEZ 안에서 사격이 이루어진 구간이다.
出處: 저자 작성.

이 구분이 결과를 보고 붙인 이름이 아님은 가우시안 혼합모형 군집으로 확인하였다. 300세대 모델 20개를 종료 사유 비율, WEZ 체류 시간, 교전 시간으로 군집화하자 BIC⁴⁷⁾가 3개 군집을 골랐고 사람이 나눈 두 전술과 같은 구분이 나왔다(<표 4-4>). 학습 기반과 하이브리드 264개 조건 전체로 넓히면 4개 군집이 선택되었고 군집 사이의 D^* 차이는 유의하였다(Kruskal-Wallis $H = 30.6, p < 0.0001$).⁴⁸⁾ 그러나 네 군집 각각의 안에서는 점수와 D^* 의 상관관계가 없었다($p = -0.17 \sim 0.08$, 모두 $p > 0.19$). 같은 전술을 쓰는 모델끼리는 더 강하다고 설명 비용이 커지지 않았다는 뜻이다. '치고 빠지기'가 적합도 설계(시간종료승 +5)의 산물인지 확인하려고 격추승 +25, 시간종료승 +1로 바꾼 적합도로 학습 시드 2개를 다시 학습하였는데, 격추 비율은 올랐지만 시간종료승이 여전히 60~96%로 주된 승리 방식이었다.

47) Gideon Schwarz, "Estimating the Dimension of a Model," *The Annals of Statistics*, Vol. 6, No. 2 (1978), pp. 461~464.

48) William H. Kruskal and W. Allen Wallis, "Use of Ranks in One-Criterion Variance Analysis," *Journal of the American Statistical Association*, Vol. 47, No. 260 (1952), pp. 583~621.

<표 4-4> 300세대 학습 기반 모델의 전술 군집

군집	모델 수	격추승 비율	시간종료 비율	점수	D* 평균(중앙값)
치고 빠지기	16	0.044	0.907	0.706	6.2 (5)
추격 격추 A	2	0.246	0.653	0.737	14.0 (14)
추격 격추 B	2	0.289	0.659	0.777	12.5 (12.5)

註: 종료 사유 비율, WEZ 체류 시간, 교전 시간을 표준화하여 가우시안 혼합모형으로 군집화하였고, 군집 수는 BIC가 최소인 3을 택하였다. 점수는 상대 2종 평균이다.

出處: 저자 작성.

4.4. 하이브리드 결합 방식(RQ3)

<표 4-5>는 네 결합 방식의 결과를, 결합에 쓰인 두 원 모델과 함께 정리한 것이다. 선형 혼합형은 학습 상대 점수에서 같은 예산의 순수 학습 기반 모델을 넘지 못했고(α 0.75만 비슷한 수준), 95% 기준 D*는 대부분 절단값이었다. 감독형은 위반율을 0.009로 낮추어 20개 중 16개에서 하드택 위반이 관측되지 않았지만, 점수는 학습 상대 0.687에서 0.487로, 보류 상대 0.746에서 0.600으로 떨어지고 D*는 평균 7.6에서 12.0으로 커졌다. 잔차형은 학습 상대 BT-v2에는 출발점보다 조금 강해졌으나 보류 상대에게는 약해졌고, 실제 지령으로 정규화 단위 0.06 안팎(뱅크각 약 11°)의 작은 보정만으로 D*가 BT-v2의 4에서 6, 17, 6으로 커졌다. 게이팅형은 같은 학습 모델을 고정 비율 0.5로 섞은 선형 혼합형보다 강하고 순수 학습 모델에 근접했지만, 95% 기준 D*는 세 모델 모두 17이었다. 평가 교전에서 게이트 값은 시드 별로 0.36, 0.59, 0.61에 머물렀고 한 교전 안의 표준편차는 0.03이었다. 게이트가 상황에 따라 규칙과 학습을 골라 쓰지 않고 시드마다 하나의 고정 비율을 학습한 것이다.

<표 4-5> 하이브리드와 원 모델의 비교

조건	학습 상대	보류 상대	D* 95%	D* 90%	위반율
(원 모델) BT-v2	(0.50)	0.84	4	2	0.100
(원 모델) 학습 기반 시드 11	0.72	0.83	3	2	0.049
선형 혼합형 시드 11, α 0.5	0.56	0.72	17	3	0.073
감독형 시드 11	0.47	0.71	17	4	0.008
잔차형 200세대(시드 0/1/2)	0.57/0.56/0.57	0.71/0.65/0.71	6/17/6	3/3/3	0.070/0.057/0.064
게이팅형 200세대(시드 0/1/2)	0.58/0.67/0.70	0.76/0.81/0.82	17/17/17	3/2/3	0.082/0.055/0.061

註: 잔차형·게이팅형은 학습 시드 3개, 200세대의 확장 실험이며, 같은 평가 실행에 포함된 원 모델과 비교

조건의 값은 본실험과 같았다.
出處: 저자 작성.

판정 기준은 하이브리드가 학습 기반에 가까운 점수와 규칙 기반 수준의 D^* 를 함께 갖는가였다. 95% 기준에서는 네 방식 모두 이 기준에 들지 못했다. 90% 기준에서는 하이브리드의 D^* 도 2~4로 원 모델과 비슷해졌으므로, 결합으로 늘어난 설명 비용은 행동의 대부분이 아니라 마지막 5~10%의 세부 행동에서 생긴 것이다. 그러나 이 기준에서도 하이브리드는 원 모델의 하나인 학습 기반 시드 11보다 점수가 높지 않고 D^* 가 작지도 않았다. 어떤 결합 방식도 두 원 모델 가운데 하나를 두 축에서 동시에 앞서지 못한 것이다. 잔차형과 게이팅형은 3시드 규모의 기술적 관찰이므로, 이 판정은 "본 실험 조건에서 네 결합 방식 모두 절충점이 관측되지 않았다"로 한정한다.

4.5. 평가 조건을 바꾼 재평가

4.5.1. 교전 규칙과 비행역학

학습 기반 300세대 모델 20개, 행동트리 3종, BTO 3개의 26개 모델을 교전 규칙이나 비행역학을 하나씩 바꾼 환경에서 다시 학습하지 않고 재평가하였다(<표 4-6>). 바꾸지 않은 설정으로 다시 실행하면 본실험이 교전 단위까지 그대로 재현되었다. 학습 기반 모델이 학습 상대와의 대결에서 앞서는 결과는 시간종료를 무승부로 처리한 규칙(평균 0.498)을 제외한 모든 설정에서 유지되었으나, 그 폭은 제한시간 240초(0.592), 최대 양력계수 -20% (0.592), 롤 속도 상한 $90^\circ/\text{s}$ (0.552)에서 크게 줄었다. 보류 상대에 대해서는 모든 설정에서 BT-v2가 학습 기반 평균보다 높았고, 제한시간을 240초로 늘리면 그 차이가 0.955 대 0.651로 벌어졌다. 시간이 길어지면 초반의 체력 우위로 버티는 '치고 빠지기'가 통하지 않기 때문이다. 비행역학을 바꾸었을 때 점수 순위(0.77~0.95)와 D^* 순위(0.76~0.92)는 대체로 유지되었으나 교전 규칙을 바꾸면 점수 순위가 크게 달라졌다(0.49, 0.23). 설정 안에서 26개 모델의 점수와 D^* 의 순위상관은 0.06~0.43으로 모두 양수였지만, 비행역학 설정 여덟 개에 Holm 보정을 적용하면 어느 것도 유의하지 않았다.

<표 4-6> 교전 규칙·비행역학을 바꾼 재평가

설정	학습 기반 vs BT-v2	학습 기반 vs BT-v3	BT-v2 vs BT-v3	점수 순위 유지	D* 순위 유지	설정 안 p (점수, D*)
본실험	0.687 (20)	0.746	0.843	-	-	0.22
제한시간 240초	0.592 (16)	0.651	0.955	0.49	0.77	0.20
시간종료 = 무승부	0.498 (4)	0.559	0.792	0.23	1.00	0.14
최대 양력계수 $\times 0.8$	0.592 (17)	0.693	0.925	0.78	0.89	0.07
최대 양력계수 $\times 1.2$	0.718 (20)	0.762	0.792	0.90	0.86	0.32
최대추력 $\times 0.8$	0.672 (20)	0.734	0.863	0.91	0.89	0.41 ^a
최대추력 $\times 1.2$	0.677 (20)	0.746	0.777	0.93	0.76	0.43 ^a
지령 지연 $\times 0.8$	0.714 (20)	0.773	0.912	0.92	0.91	0.06
지령 지연 $\times 1.2$	0.652 (20)	0.719	0.792	0.95	0.92	0.34
롤 속도 상한 180°/s	0.622 (19)	0.671	0.853	0.80	0.81	0.10
롤 속도 상한 90°/s	0.552 (17)	0.595	0.650	0.77	0.82	0.32

註: 학습 기반 점수는 300세대 모델 20개의 평균이며 괄호 안은 0.5를 넘은 모델 수이다. 순위 유지는 본실험과 해당 설정 사이의 26개 모델 순위상관이다. a: 보정 전 $p < 0.05$, Holm 보정 후 유의하지 않음.

出處: 저자 작성.

4.5.2. 6자유도 F-16 교차 평가

3자유도에서 학습한 31개 모델(4.5.1절의 26개와 선형 혼합형·감독형·잔차형·게이팅형·PPO 대표 각 1개)을 다시 학습하지 않고 JSBSim의 F-16 모델에서 평가하였다. 관측, 지령 변환, 초기조건, 교전 규칙은 같고 비행역학만 바뀐다. 계단 응답 시험에서 추종 제어기는 기체가 낼 수 있는 범위 안에서 지령을 오버슈트 2% 이내로 따랐지만, F-16 모델은 비행제어계와 받음각 제한 때문에 저속 롤 속도(180 m/s에서 약 77°/s)와 가용 하중배수(180 m/s에서 4.4 G)가 3자유도 모델보다 크게 낮았다. 평가 전에 정해 둔 판정 기준과 결과는 <표 4-7>과 같다.


<표 4-7> 6자유도 교차 평가의 사전 판정 기준과 결과

기준	지표	사전 기준	결과	판정
점수 순위 유지	p (3자유도 점수, 6자유도 점수)	0.7 이상	0.12 ($p = 0.52$)	유지되 지 않음
D* 순위 유지	p (3자유도 D*, 6자유도 D*)	0.7 이상	0.57 ($p = 0.0007$)	유지되 지 않음
트레이드오프 출현	6자유도 p (점수, D*)의 90% 구간 하한, 3자유도 대비 증가	하한 0 초과, 증가 0.2 초과	하한 -0.67, 증가 -0.60	출현하 지 않음
규칙 준수 구조	BT-v3·감독형의 하드텍 위반율	0	0, 0.0003	유지되 지 않음

註: 31개 모델 $\times$ 400회 교전. 판정 기준과 판정 코드는 평가 전에 기록하였다.

出處: 저자 작성.

성능 순위는 크게 달라졌다(<그림 4-4>). 학습 기반 모델은 BT-v2와의 대결에서 평균 0.371로 20개 모두 졌고 보류 상대 점수도 0.404로 BT-v2(0.787)에 크게 못 미쳤다. 3자유도에서 찾은 '치고 빠지기'가 통하지 않아 교전당 주는 피해가 20.6에서 4.1로 줄고 받는 피해가 6.0에서 16.8로 늘었으며, 행동트리 계열의 점수는 거의 그대로였다(행동트리 3종 평균 0.414 → 0.454, BTO 0.602 → 0.595). 트레이드 오프는 6자유도에서도 나타나지 않아, 같은 31개 모델의 점수와 D*의 순위상관은 3자유도 0.13(90% 구간 -0.20~0.44)에서 6자유도 -0.47(p = 0.008)로 오히려 반대 방향이 되었다. D* 순위는 부분적으로만 유지되었다. 대부분 모델의 D*가 작아졌고(학습 기반 평균 7.6 → 4.1), 3자유도에서 절단값이던 6개 모델이 2~8이 되었다. 지령의 분포는 두 환경에서 거의 같았으므로 차이는 모델이 방문한 상황의 분포에서 온 것으로 보이나, 원인은 확인하지 못했다.



<그림 4-4> 3자유도와 6자유도에서의 점수와 D* 비교

註: 점선은 두 환경의 값이 같은 선이다. 점수는 상대 2종 평균이다.
 出處: 저자 작성.

4.6. 결과의 종합

성능이 높을수록 설명하기 어렵다는 통념이 옳다면 본 실험에서는 성능과 설명 비

용의 양의 연관, 설명 비용을 제한할 때의 지속적인 성능 손실, 계열과 성능에 따라 정해지는 설명 비용, 그리고 두 장점을 절충하는 하이브리드가 관측되어야 한다. <표 4-8>은 이 기대와 관측을 대조한 것이다.

<표 4-8> 통념이 예측하는 결과와 관측 결과

연구 질문	통념이 옳다면	관측 결과
RQ1 연관성	성능이 높을수록 D*가 크다	전체 조건에서 0 또는 음수. 혼합 제외·학습 상대 기준에서만 약한 양의 연관(0.25), 보류 상대 기준은 반대 방향
RQ1 제약 비용	D*를 제한하면 성능을 계속 잃는다	깊이 2 이하에서는 큰 손실, 깊이 5~6을 허용하면 대부분 소멸
RQ2 결정 요인	D*는 모델 계열과 성능으로 정해진다	계열 간 범위가 겹치고, 같은 계열·예산 안에서 전술에 따라 3~17로 갈림. 전술 군집 안에서는 성능과 무관
RQ3 하이브리드	D*는 규칙 기반 수준, 성능은 중간	네 방식 모두 원 모델 하나를 두 축에서 앞서지 못함(잔차형·케이팅형은 3시드)
평가 조건	학습 모델이 고성능이다	학습 상대에서만 뚜렷하고 보류 상대·다른 교전 규칙·6자유도에서는 약화 또는 소멸

出處: 저자 작성.

5. 논의

5.1. 트레이드오프의 형태

본 연구의 결과는 성능과 설명가능성이 언제나 맞바뀌야 하는 관계라는 통념을 지지하지 않는다. 그렇다고 둘이 무관하다는 뜻도 아니다. 설명 비용을 매우 엄격하게 묶으면 성능을 잃었고, 그 손실은 깊이 5~6 수준의 규칙을 허용하면 대부분 사라졌다. 이 과업에서 최고 수준의 성능은 if-then 질문을 대여섯 번 이어 가는 규칙으로 재현되는 모델에서 이미 얻어졌고, 그 이상의 복잡성은 성능을 더해 주지 않았다. 근접공중전의 좋은 조종이 "상대가 어느 쪽에 있는가, 사거리 안인가, 고도가 충분한가" 같은 몇 개의 기하학적 판단으로 상당 부분 결정되기 때문으로 보인다. 신경망은 이 판단을 복잡한 방식으로 계산하지만 그 결과인 행동은 간결하게 요약될 수 있고, 반대로 행동트리도 연속 함수로 지령을 계산하면 요약에 여러 단계가 필요하다. 비슷한 성능의 모델이 많을수록 그 안에 단순한 모델이 있을 가능성이 높다는 세메노바 등의 논의와도 부합한다.

약한 트레이드오프가 나타난 조건이 학습 상대 성능에 한정되었다는 점도 의미가 있다. 혼합 정책을 뺀 모델들에서 학습 상대에 대한 점수는 설명 비용과 약하게 함께 커졌지만, 보류 상대에 대한 점수는 반대로 설명 비용이 작을수록 높았다. 특정 상대

를 이기는 데 맞춰진 세밀한 행동은 규칙으로 요약하기 어렵고, 처음 보는 상대에게도 통하는 행동은 오히려 단순했던 것이다. 트레이드오프가 성능 일반이 아니라 특정 상대에 대한 과적합과 함께 나타났을 가능성을 시사한다.

방법론적으로는 반복의 중요성을 확인하였다. 학습 시드가 3개일 때 관측된 유의한 트레이드오프($p = 0.38$)는 20개로 늘리자 사라졌다. 학습 모델은 같은 설정에서도 시드마다 전혀 다른 전술을 익히므로, 적은 반복으로 성능과 설명가능성의 관계를 주장하면 우연한 결과를 일반 법칙으로 오인할 수 있다.

5.2. '고성능' 판정의 조건 의존성

트레이드오프의 검증은 고성능 모델의 존재를 전제로 한다. 본 연구에서 학습 모델의 성능 우위는 학습 상대와의 대결, 120초 제한과 시간종료 체력 비교라는 교전 규칙, 학습에 쓴 3자유도 비행 모델 안에서만 뚜렷했고, 보류 상대·다른 교전 규칙·6자유도 F-16에서는 약해지거나 사라졌다. 학습 모델이 찾은 '치고 빠지기'는 주어진 교전 규칙에서 가장 유리한 전술이었지만 그 규칙 밖에서는 통하지 않았다. 따라서 본 연구는 "고성능 학습 모델도 설명 가능하다"고 주장하지 않는다. 본 연구가 말할 수 있는 것은, 어떤 정의로 성능을 재더라도 성능이 높은 모델이 설명 비용도 크다는 일관된 관계는 나타나지 않았고, 누가 고성능인가 자체가 평가 조건에 따라 바뀌었다는 것이다.

5.3. 설명 비용은 전술의 성질이다

같은 예산과 비슷한 점수에서 D^* 를 가른 것은 전술이었다. 추격 격추는 상대의 기동에 계속 반응해야 하므로 지령이 상황에 따라 잘게 나뉘고, 치고 빠지기는 한 번 사격한 뒤 정해진 선회를 유지하면 되기 때문이다. 전술 군집 안에서는 성능과 D^* 의 상관성이 없었으므로 설명 비용의 원인은 성능이 아니라 어떤 방식으로 이기는가에 있다. 학습 과정에서도 설명 비용은 복제본을 떠나 자기 전술을 갖는 순간에 한 번 커졌을 뿐 성능 향상과 함께 커지지 않았다.

다만 D^* 는 모델 하나의 고유한 값이 아니라 모델이 특정 환경에서 방문한 상황에 대한 값이다. 공통 상태 D^* 는 학습이 진행될수록 커졌고, 6자유도 재평가에서는 같은 모델의 D^* 가 크게 달라졌다. 학습 모델은 자기가 실제로 가는 상황에서는 간결하게 행동하지만 가지 않는 상황까지 물으면 예측하기 어려워진다. 운용 관점에서는 평소에 겪지 않는 상황에서 AI가 어떻게 행동할지가 더 중요한 문제일 수 있으며, 이는 D^* 가 설명가능성 자체가 아니라 주어진 환경에서의 행동 재현 간결성이라는 점을 다

시 확인시켜 준다.

5.4. 하이브리드 설계에 대한 시사점

두 모델을 결합하면 두 장점을 함께 얻는다는 기대는 네 결합 방식 모두에서 관측되지 않았다. 선형 혼합형은 두 지령이 다를 때 어느 쪽의 논리도 따르지 않는 중간 값을 냈고, 감독형은 규칙이 개입하는 순간 학습 모델의 전술을 끊었으며, 잔차형의 작은 보정은 학습 상대에 맞춘 미세 조정에 그치면서 규칙의 간결한 구조를 흐렸다. 게이팅형은 상황별 선택을 학습하도록 설계했지만 실제로는 고정 비율로 수렴하여 비율을 학습한 선형 혼합형이 되었다. 결합으로 늘어난 설명 비용은 90% 기준에서는 거의 사라지므로, 결합이 만든 것은 전혀 다른 행동이라기보다 세부 행동의 복잡성이다. 그럼에도 어떤 결합도 성능에서 이점을 주지 못했으므로 그 비용을 정당화하지 못했다. 규칙과 학습을 합칠 때는 지령을 섞기보다, 규칙이 어떤 기동을 할지 고르고 학습은 그 기동 안의 세부 조종만 맡는 계층형 구조처럼 두 모델의 역할이 겹치지 않게 나누는 방식을 검토할 필요가 있다.

5.5. 군 운용에 주는 시사점

첫째, 설명가능성은 모델 종류로 가정하지 말고 행동으로 측정해야 한다. 유인기가 무인기를 감독하는 운용에서 조종사에게 필요한 것은 AI가 다음에 무엇을 할지 예측할 수 있는가이며, 같은 구조의 신경망이라도 전술에 따라 3단계 규칙으로 재현되기도 하고 16단계로도 재현되지 않기도 했다. 둘째, 성능 평가는 평가 조건과 함께 보고해야 한다. 학습 모델은 주어진 규칙에서 가장 유리한 전술을 찾아내므로, 훈련에 쓴 상대와 규칙 밖의 조건에서 따로 검증하지 않으면 평가 결과가 실전 성능을 대표하지 못한다. 셋째, 안전 요구의 수준에 따라 구조를 골라야 한다. 안전규칙을 행동 전체에 명시한 BT-v3에서는 위반이 관측되지 않았지만, 학습 모델 위에 감독 규칙을 씌운 방식은 위반을 크게 줄이면서도 0으로 만들지 못했고 6자유도에서도 짧은 침범이 남았다. 한 번의 위반도 허용할 수 없는 규칙이라면 감독 조건의 여유와 기체의 회복 능력을 함께 검증해야 하며, 그 대가인 성능 손실과 설명 비용 증가도 함께 평가해야 한다.

5.6. 연구의 한계

본 연구의 결과는 다음의 범위 안에서 해석해야 한다. 3자유도 점질량 모델은 받음

각, 실속, 무장 탄도를 모사하지 않고 롤 운동을 1차 지연으로만 근사한다. 비행역학 민감도 분석과 6자유도 재평가에서 강한 트레이드오프는 나타나지 않았지만 6자유도에서 성능 순위는 유지되지 않았고 D* 순위도 부분적으로만 유지되었으므로, 성능과 개별 모델의 D* 값에 관한 결과는 3자유도 환경에 한정된다. 두 점점 모두 다시 학습하지 않은 평가이며, 6자유도에서 처음부터 학습한 모델도 같은 관계를 보이는지는 확인하지 못했다. 교전은 1대1 근접 기총 교전에 한정되었고, 학습과 평가의 상대는 고정된 행동트리 2종이 기본이며 자가 대전으로 학습한 모델은 포함하지 않았다.

학습 기반 모델은 BT-v2의 복제본에서 출발했으므로 규칙과 무관하게 학습한 모델이 아니라 규칙 모델을 학습으로 변형한 모델이다. 무작위 초기화 학습은 진화전략과 PPO 모두 회피로 수렴하여 비교 대상이 되지 못했다. D*는 같은 예산에서도 시드 간 표준편차가 4~5로 크고, 95% 기준에서 전체 조건의 58%가 절단값이며, 목표 충실도를 90%로 낮추면 계열 간 차이가 크게 줄어든다. 자기 기록 D*와 공통 상태 D*의 상관도 0.27에 그쳐, 어떤 상황에서 재느냐에 따라 값이 달라진다. 무엇보다 D*는 행동 재현의 간결성을 재는 기능 기반 지표이며 사람이 그 규칙을 실제로 이해하는지는 검증하지 않았다. 사람이 모델의 다음 기동을 예측하는 이해도 실험은 설계까지 준비하였으나 실시하지 못했다. 잔차형과 게이팅형은 학습 시드 3개, 200세대로 본실험보다 작은 규모이고 게이팅형은 학습 모델 하나만 사용하였다. 마지막으로 규칙 기반 모델과 학습 기반 모델에 들인 개발 노력이 같다고 보장할 수 없으므로, 본 연구의 주장은 절대적인 성능 순위가 아니라 성능과 설명 비용 사이 관계의 형태에 있다.

6. 결론

본 연구는 성능이 높은 공중전 AI일수록 설명하기 어렵다는 성능-설명가능성 트레이드오프가 실제로 존재하는지를 1대1 근접 기총 공중전 모의 환경에서 검증하였다. 규칙 기반 행동트리, 진화전략으로 학습한 신경망, 두 모델을 네 가지 방식으로 결합한 하이브리드를 같은 관측·지령·상대로 비교하였고, 설명가능성은 모델의 조종 기록을 재현하는 결정트리의 최소 깊이로 측정하였다. 트레이드오프는 모델 집단에서의 연관성과 설명 비용을 제한할 때의 성능 손실이라는 두 진술로 나누어, 성능을 학습 상대·보류 상대·전원 대전의 세 가지로 정의하여 검증하였다.

그 결과 성능이 높을수록 설명 비용이 크다는 강한 트레이드오프는 어떤 성능 정의에서도 관측되지 않았다. 설명 비용을 깊이 2 이하로 엄격하게 묶으면 성능 손실이

켰지만 깊이 5~6을 허용하면 손실은 대부분 사라졌고, 약한 트레이드오프는 학습 상대에 대한 성능에서만 나타났다. 같은 학습 예산의 모델 사이에서 설명 비용을 가른 것은 성능이 아니라 전술이었으며, 학습량이 늘어도 설명 비용은 복제본을 떠나는 순간 한 번 커졌을 뿐 성능과 함께 커지지 않았다. 네 결합 방식의 하이브리드는 어느 것도 원 모델을 두 축에서 동시에 앞서지 못했다. 또한 학습 모델의 성능 우위는 학습 상대와의 대결에서만 뚜렷했고 보류 상대, 다른 교전 규칙, 6자유도 F-16 재평가에서는 약해지거나 사라졌다.

이 결과는 공중전 AI를 도입하고 평가할 때 설명가능성을 모델 종류로 가정하지 말고 실제 행동으로 측정해야 하며, 성능은 평가 조건과 함께 보고해야 함을 시사한다. 후속 연구로는 사람이 모델의 다음 기동을 예측하는 이해도 실험으로 행동 재현 간결성과 사람의 이해도 사이의 관계를 검증하는 것, 6자유도 비행 모델에서 학습하고 미사일 교전과 다수기 교전으로 환경을 넓히는 것, 자가 대전으로 학습한 모델을 포함하는 것, 규칙과 학습의 역할을 겹치지 않게 나누는 계층형 하이브리드를 실험하는 것을 제안한다.

- 참 고 문 헌 -

- 배정호·강윤성·윤석민·김용덕·김성호. 2021. “커리큘럼 러닝을 이용한 항공기 강화학습.” 『정보과학회 논문지』, 제48권 제6호, pp. 707~712.
- 이민석·오지현·김천영·배정호·김용덕·지철규. 2022. “공대공 전투 모의를 위한 규칙기반 AI 교전 모델 개발.” 『한국군사과학기술학회지』, 제25권 제6호, pp. 637~647.
- 황인수·배정호. 2023. “커리큘럼을 이용한 투서클 기반 항공기 헤드온 공중 교전 강화학습 기법 연구.” 『한국군사과학기술학회지』, 제26권 제4호, pp. 352~360.
- 『스마트비즈』. 2026년 6월 9일. “KF-21 옆에 무인기 세운 KAI, 유·무인 공중전 체계로 답했다.” <https://www.smartbizn.com/news/articleView.html?idxno=145816> (검색일: 2026년 9월 28일)
- Alshiekh, Mohammed et al. 2018. “Safe Reinforcement Learning via Shielding.” *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 32, No. 1.
- Army Recognition. 2026. “General Atomics YFQ-42A Collaborative Combat Aircraft Completes First Semi-Autonomous Mission.” (February 17).
<https://www.armyrecognition.com/news/aerospace-news/2026/general-atomics-yfq-42a-collaborative-combat-aircraft-completes-first-semi-autonomous-mission> (검색일: 2026년 9월 28일)
- Bastani, Osbert, Yewen Pu and Armando Solar-Lezama. 2018. “Verifiable Reinforcement Learning via Policy Extraction,” in Samy Bengio et al. (eds.), *Advances in Neural Information Processing Systems 31*, pp. 2494~2504. Red Hook, NY: Curran Associates.
- Berndt, Jon. 2004. “JSBSim: An Open Source Flight Dynamics Model in C++,” in *AIAA Modeling and Simulation Technologies Conference and Exhibit*, AIAA Paper 2004-4923. Providence, RI: AIAA.
- Burgin, George H. and Laurent B. Sidor. 1988. *Rule-Based Air Combat Simulation*. NASA Contractor Report 4160. Washington, D.C.: NASA Scientific and Technical Information Division (September).
- Colledanchise, Michele and Petter Ögren. 2018. *Behavior Trees in Robotics and AI: An Introduction*. Boca Raton: CRC Press.
- Craven, Mark W. and Jude W. Shavlik. 1996. “Extracting Tree-Structured Representations of Trained Networks,” in David S. Touretzky, Michael C. Mozer and Michael E. Hasselmo (eds.), *Advances in Neural Information Processing Systems 8*, pp. 24~30. Cambridge, MA: MIT Press.
- DARPA. n.d. “Air Combat Evolution (ACE).”
<https://www.darpa.mil/research/programs/air-combat-evolution> (검색일: 2026년 9월 30일)
- DARPA. 2024. “ACE Program Achieves World First for AI in Aerospace.” (April 17).
<https://www.darpa.mil/news/2024/ace-ai-aerospace> (검색일: 2026년 9월 30일)
- Doshi-Velez, Finale and Been Kim. 2017. “Towards A Rigorous Science of Interpretable Machine Learning.” arXiv:1702.08608.
- Efron, Bradley. 1979. “Bootstrap Methods: Another Look at the Jackknife.” *The Annals of Statistics*, Vol. 7, No. 1, pp. 1~26.
- Gunning, David and David W. Aha. 2019. “DARPA’s Explainable Artificial Intelligence (XAI)

- Program.” *AI Magazine*, Vol. 40, No. 2, pp. 44~58.
- Holm, Sture. 1979. “A Simple Sequentially Rejective Multiple Test Procedure.” *Scandinavian Journal of Statistics*, Vol. 6, No. 2, pp. 65~70.
- Jacobs, Robert A., Michael I. Jordan, Steven J. Nowlan and Geoffrey E. Hinton. 1991. “Adaptive Mixtures of Local Experts.” *Neural Computation*, Vol. 3, No. 1, pp. 79~87.
- Johannink, Tobias et al. 2019. “Residual Reinforcement Learning for Robot Control,” in *2019 International Conference on Robotics and Automation (ICRA)*, pp. 6023~6029. Piscataway, NJ: IEEE.
- Juozapaitis, Zoe, Anurag Koul, Alan Fern, Martin Erwig and Finale Doshi-Velez. 2019. “Explainable Reinforcement Learning via Reward Decomposition,” in *Proceedings of the IJCAI 2019 Workshop on Explainable Artificial Intelligence*.
- Kong, Weiren, Deyun Zhou, Zhen Yang, Yiyang Zhao and Kai Zhang. 2020. “UAV Autonomous Aerial Combat Maneuver Strategy Generation with Observation Error Based on State-Adversarial Deep Deterministic Policy Gradient and Inverse Reinforcement Learning.” *Electronics*, Vol. 9, No. 7, 1121.
- Kruskal, William H. and W. Allen Wallis. 1952. “Use of Ranks in One-Criterion Variance Analysis.” *Journal of the American Statistical Association*, Vol. 47, No. 260, pp. 583~621.
- Lundberg, Scott M. and Su-In Lee. 2017. “A Unified Approach to Interpreting Model Predictions,” in Isabelle Guyon et al. (eds.), *Advances in Neural Information Processing Systems 30*, pp. 4765~4774. Red Hook, NY: Curran Associates.
- McGrew, James S., Jonathan P. How, Brian Williams and Nicholas Roy. 2010. “Air-Combat Strategy Using Approximate Dynamic Programming.” *Journal of Guidance, Control, and Dynamics*, Vol. 33, No. 5, pp. 1641~1654.
- Ng, Andrew Y., Daishi Harada and Stuart Russell. 1999. “Policy Invariance under Reward Transformations: Theory and Application to Reward Shaping,” in *Proceedings of the Sixteenth International Conference on Machine Learning*, pp. 278~287. San Francisco: Morgan Kaufmann.
- Park, Hyunju, Byung-Yoon Lee, Min-Jea Tahk and Dong-Wan Yoo. 2016. “Differential Game Based Air Combat Maneuver Generation Using Scoring Function Matrix.” *International Journal of Aeronautical and Space Sciences*, Vol. 17, No. 2, pp. 204~213.
- Pope, Adrian P. et al. 2021. “Hierarchical Reinforcement Learning for Air-to-Air Combat,” in *2021 International Conference on Unmanned Aircraft Systems (ICUAS)*, pp. 275~284. Piscataway, NJ: IEEE.
- Ribeiro, Marco Tulio, Sameer Singh and Carlos Guestrin. 2016. “‘Why Should I Trust You?’: Explaining the Predictions of Any Classifier,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 1135~1144. New York: ACM.
- Rudin, Cynthia. 2019. “Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead.” *Nature Machine Intelligence*, Vol. 1, No. 5, pp. 206~215.
- Saldiran, Emre, Mehmet Hasanzade, Gokhan Inalhan and Antonios Tsourdos. 2024. “Towards Global Explainability of Artificial Intelligence Agent Tactics in Close Air Combat.” *Aerospace*, Vol. 11, No. 6, 415.
- Salimans, Tim, Jonathan Ho, Xi Chen, Szymon Sidor and Ilya Sutskever. 2017. “Evolution

- Strategies as a Scalable Alternative to Reinforcement Learning.” arXiv:1703.03864.
- Schuirman, Donald J. 1987. “A Comparison of the Two One-Sided Tests Procedure and the Power Approach for Assessing the Equivalence of Average Bioavailability.” *Journal of Pharmacokinetics and Biopharmaceutics*, Vol. 15, No. 6, pp. 657~680.
- Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford and Oleg Klimov. 2017. “Proximal Policy Optimization Algorithms.” arXiv:1707.06347.
- Schwarz, Gideon. 1978. “Estimating the Dimension of a Model.” *The Annals of Statistics*, Vol. 6, No. 2, pp. 461~464.
- Semenova, Lesia, Cynthia Rudin and Ronald Parr. 2022. “On the Existence of Simpler Machine Learning Models,” in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. New York: ACM.
- Shaw, Robert L. 1985. *Fighter Combat: Tactics and Maneuvering*. Annapolis: Naval Institute Press.
- Spearman, Charles. 1904. “The Proof and Measurement of Association between Two Things.” *The American Journal of Psychology*, Vol. 15, No. 1, pp. 72~101.
- Wilcoxon, Frank. 1945. “Individual Comparisons by Ranking Methods.” *Biometrics Bulletin*, Vol. 1, No. 6, pp. 80~83.
- Wilson, Edwin B. 1927. “Probable Inference, the Law of Succession, and Statistical Inference.” *Journal of the American Statistical Association*, Vol. 22, No. 158, pp. 209~212.
- Yang, Qiming, Jiandong Zhang, Guoqing Shi, Jinwen Hu and Yong Wu. 2020. “Maneuver Decision of UAV in Short-Range Air Combat Based on Deep Reinforcement Learning.” *IEEE Access*, Vol. 8, pp. 363~378.

Testing the Performance-Explainability Trade-off in Air-Combat AI: A Behavior-Level Comparison of Rule-based, Learning-based, and Hybrid Models

Cadet 4th Class Park Yoonjoon
Cadet 4th Class Son Hyeongrae
Cadet 4th Class Lee Sungjae
Cadet 4th Class Lee Junseo
Cadet 4th Class Trinh Vu Tuan Dat

– Abstract –

It is widely assumed that better-performing air-combat AI is harder to explain. This study tests whether such a performance-explainability trade-off exists in a simulated one-on-one within-visual-range gun engagement. Hand-written behavior trees, neural policies fine-tuned by evolution strategies, and hybrids that combine the two in four ways were compared under identical observations, commands, and opponents. Explainability was measured as the minimum depth of a decision tree that reproduces a policy's commands, which we interpret as behavioral conciseness rather than human understanding. The trade-off was tested in two ways: whether higher-performing policies require deeper trees, and how much performance is lost when tree depth is capped. Performance was defined separately against the training opponent, a held-out opponent, and a round-robin pool. Across 282 conditions and 112,800 engagements, no strong association between performance and explanation cost was found (Spearman $\rho = -0.02$). Capping depth at two cost substantial performance, but allowing five to six levels removed most of the loss. Among policies trained with the same budget, explanation cost was determined by tactics rather than performance, and none of the four hybrid designs outperformed one of its parent models on both axes. The learned policies' advantage held mainly against the training opponent and weakened or vanished against a held-out opponent, under altered engagement rules, and in a six-degree-of-freedom F-16 re-evaluation.

Keywords : Air-Combat AI, Explainable AI, Trade-off, Behavior Tree, Surrogate Model

보안성 검토에 대한 저자 의견서

논문 저자	소속	생도대	계급	00기 생도 (0학년)	성명	김공군
논문 제목	공중전 인공지능의 성능-설명가능성 트레이드오프 검증					
저자 의견 1. 항공우주연구소 주관 '26년 공사 생도 안보 논문경진대회 참가를 위해 작성된 논문임. 2. 위 논문은 공개 제원 기반 모의실험으로 공중전 인공지능 모델의 설명가능성과 전투성능의 관계를 연구하는 내용으로, 보안 위규 사항을 포함하고 있지 않으며, 군 내부 기밀 유출 등 보안에 저촉한 사례가 없음을 확인함. 년 월 일 계급 성명 (서명)						

논문 유사도 검사 결과서

논문 제목 : 공중전 인공지능의 성능-설명가능성 트레이드오프 검증

(Testing the Performance-Explainability Trade-off in Air-Combat AI: A Behavior-Level Comparison of Rule-based, Learning-based, and Hybrid Models)

KCI 논문 유사도 검사* 결과 붙임

- <https://check.kci.go.kr> (KCI 문헌 유사도 검사 서비스) 활용

* KCI 논문유사도 검사시스템은 국민 누구나 무료로 이용 가능한 시스템으로써 이용자가 업로드하는 문헌과 KCI에 등록되어 있는 약200만여건의 KCI 및 국내 학술대회 논문을 비교하여 유사도 검사결과를 보여주는 시스템입니다.

20 년 월 일

계급

성명

(서명)